

生成式人工智能基础小书：直观的数学入门

The Little Book of Generative AI Foundations: An Intuitive
Mathematical Primer

Tianhua Chen

计算与工程学院
哈德斯菲尔德大学

`t.chen@hud.ac.uk`

预印本版本

2026 年 9 月 8 日

前言

生成式人工智能（Generative artificial intelligence）近年来发展迅速，新模型、新系统与新应用以惊人的速度不断涌现。然而，在这快速变化的表象之下，许多核心思想其实建立在一小部分数学原理之上：潜变量、似然、变分界、可逆变换、随机加噪过程、分数场、对抗比较，以及能量地形。

本书，《生成式人工智能基础小书：直观的教学入门》（The Little Book of Generative AI Foundations: An Intuitive Mathematical Primer），旨在为读者提供一条紧凑而严谨的路径来贯通这些思想。它并不试图穷尽罗列每一种现代架构、实现细节或最先进的技术改进，而是聚焦于使各大类生成模型（generative model）得以被理解的数学基础。其目标是在不削弱数学实质的前提下，让这些基础更易于接受。本书定位为奠基性质的入门读物，面向希望从第一性原理出发理解生成式建模的、具有数学好奇心的研究者、从业者与学生。

因此，书名中的“小”应从涵盖范围而非深度的角度来理解。本书在内容取舍上是刻意精选的，但在所选范围之内，论述是刻意细致的。核心思想一步步展开，目的在于让底层的数学结构清晰可见，而不是将模型当作黑盒配方来对待。本书的目标是奠基而非追踪前沿：已经身处研究前沿的读者可能会觉得许多主题似曾相识，但本书的设计意图是使这些主题背后的数学逻辑变得明晰、直观且连贯。

参考文献的选取同样刻意聚焦。其作用是支撑正文中主要的历史脉络与技术关联，而不是把本书变成一部大型综述式的文献目录。

方法与结构

本书的中心目标是通过一条连贯的数学脉络将各大类生成模型联系起来。章节顺序的安排以让数学尽可能自然、紧凑地展开为准，而非严格遵循历史年代顺序。各模型的引入次序保证后面的思想建立在前面思想之上，使读者能够看清潜变量、变分目标、扩散过程、分数场、精确密度模型、对抗学习与基于能量的建模（energy-based modelling）彼此之间的关联。

论述遵循一个简单的原则：数学工具在理解某个建模思想需要用到它时才引入。因此，所需的线性代数、概率论、微积分、高斯代数以及密度变换工具都被嵌入到建模叙事之中，而不是被剥离成冗长的预备性综述。

本书包含的推导超出一部高层概览严格所需的数量。这是有意为之：生成式建模中的许多思想，在把它们数学目标逐层拆解之后会变得更加清晰。推导一步一步展开，必要时概念随用随引或随用随复，使数学始终保持与建模直觉的关联，而非沦为孤立的技术段落。

本书从主成分分析（PCA）与自编码器（autoencoder）开始，借助它们引入线性变换、投影、重构与潜变量结构。随后，概率主成分分析（Probabilistic PCA, PPCA）将这些思想转化为书中第一个潜变量生成模型。

下一个阶段展开变分生成式建模。证据下界 (Evidence Lower Bound, ELBO)、期望最大化 (Expectation–Maximisation, EM) 算法与变分推断首先通过概率潜变量引入, 随后扩展到变分自编码器。

接着本书转向扩散模型。去噪扩散概率模型首先以离散时间序列潜变量模型的形式引入, 其后介绍连续时间生成式建模所需的微积分, 再之后是扩散的基于分数的视角: 生成由学习到的分数场与逆向时间随机动力学所引导。

接下来的一章研究精确密度模型, 包括归一化流与自回归分解。这些模型展示了如何通过设计使似然保持可处理, 或是借助可逆变换, 或是借助概率的链式法则。

最后一章则超越可处理的似然。该章引入生成对抗网络 (GAN)、Wasserstein GAN 与基于能量的模型 (Energy-Based Model, EBM), 展示生成式学习如何通过比较、几何差异度量或标量能量地形进行, 而非依赖显式的似然评估。

起源与版本

本书是作为一项独立撰写的学术项目而开发的, 其动因在于作者长期以来的一个兴趣: 让现代生成式人工智能的数学基础更加透明、更易获取。本书并非在资助研究项目、受托机构产出、正式的课程模块开发活动或任何特定模块/项目的官方课程文档框架下开发。

本手稿源自一项关于现代生成式建模的概率与数学基础的更广泛的独立项目。其中部分思想的早期短篇版本曾以预印本形式发表, 先是作为 SSRN 预印本, 随后以修订形式作为 arXiv 预印本发表 [6, 5]。本书将这一思路扩展为一部更完整的数学入门读物, 对从经典潜变量模型通往现代生成式人工智能的基础作了更系统的论述。

本手稿为本书的第二个预印本版本。与第一个版本相比, 本版在全书中增加了可视化讲解, 并对正文作了少量澄清。它仍是一部撰写中的预印本, 未来可能继续修订、更正、澄清或补充内容。一个修订版本或将提交正式出版。

使用许可

本手稿以预印本形式提供, 供学术阅读、引用、研究参考与学习之用。欢迎读者引用本书, 并在注明出处的前提下将其作为研究、学习与教学的参考资源。

对本材料进行实质性的复制、改编、再分发, 或将其转化为衍生性的教学、培训或课程资源, 须获得作者许可, 除非适用的版权例外条款或未来版本随附的独立许可协议另有允许。

致谢

本书源自我持续不断的努力: 从第一性原理出发去理解并阐释现代生成式人工智能的数学基础。许多解释是在反复尝试把线性代数、概率论、变分推断、随机建模与现代深度生成模型的思想串联成连贯叙事的过程中变得更加清晰的。

我感谢更广泛的学术界, 他们的论文、著作、讲义与讨论塑造了本手稿得以孕育的更广阔背景。文中尚存的任何错误、遗漏或不清晰之处, 均由本人负责。

Tianhua Chen
2026 年 9 月 8 日

github.com/aaronshan

目 录

前言	i
1 线性代数基础：从主成分分析 (PCA) 到自编码器	1
概述	1
概念地图	1
1.1 矩阵作为线性变换：基方向、投影与复合	2
1.2 特征向量、特征值与矩阵的固有坐标系	6
1.3 基于方差最大化的主成分分析	8
1.4 PCA 作为基变换：相似变换与 SVD	11
1.5 从 PCA 到自编码器：重构、子空间与流形	16
总结与参考文献	21
2 概率主成分分析：通往潜变量生成建模的桥梁	22
概览	22
概念导览	22
2.1 概率 PCA 的表述	23
2.2 PPCA 为何解析可处理	25
2.3 学习 PPCA：三种优化视角	29
2.4 Jensen 不等式与证据下界	31
2.5 期望最大化：最大化下界	34
总结与参考文献	38
3 变分自编码器：从概率潜变量到变分推断	39
概述	39
概念图	39
3.1 从自编码器到变分自编码器	40
3.2 从不可解析求解的似然到 ELBO	44
3.3 学习变分自编码器：重参数化与优化	48
总结与参考文献	50
4 去噪扩散概率模型	51
概述	51
概念图	51
4.1 前向扩散过程：从数据到噪声	52
4.2 反向过程与 ELBO 表述	55

4.3 从扩散 ELBO 到逐时间步的目标	59
4.4 从真实反向后验到 DDPM 学习	64
小结与参考文献	70
5 连续时间生成建模的微积分基础	71
概览	71
概念地图	72
5.1 从离散更新到连续运动	72
5.2 确定性密度演化	79
5.3 随机密度演化与福克-普朗克方程	86
总结与参考文献	90
6 基于分数的生成建模与连续时间扩散	91
概览	91
概念图谱	92
6.1 从分数函数到朗之万采样	93
6.2 学习分数: Fisher 散度与分数匹配	97
6.3 稳定学习: 通过加噪实现的去噪分数匹配	101
6.4 从多尺度分数学习到连续时间扩散	106
6.5 经由分数视角看离散扩散模型	111
总结与参考文献	113
7 精确密度模型: 归一化流与自回归分解	115
概述	115
概念图	115
7.1 归一化流: 通过可逆变换实现精确密度	116
7.2 实践中的归一化流: 耦合层与组合	122
7.3 作为生成模型的自回归分解	127
小结与参考文献	131
8 超越似然: 生成对抗网络与基于能量的模型	133
概述	133
概念图	133
8.1 生成对抗网络: 通过比较进行学习	134
8.2 几何优化与 Wasserstein GAN	139
8.3 基于能量的模型: 基础与学习	144
8.4 能量梯度、分数场与扩散	148
小结与参考文献	152
结语	153
A 高斯代数与配方法	154
B 扩散模型逆过程后验的推导	157
参考文献	160

第 1 章 1

线性代数基础：从主成分分析（PCA）到自编码器

概述

主成分分析（Principal Component Analysis, PCA）是进入本书的一个平易且自然的切入点，主要有两个原因：

- 搭建通向概率模型与生成模型的桥梁。作为一种广为人知的降维技术，PCA 为本书后续发展的若干思想提供了自然的垫脚石。它的重构表述自然地引出自编码器（autoencoder），其中压缩与重构直接从数据中学习得到。其概率扩展——概率 PCA（Probabilistic PCA, PPCA）——随后从生成建模的视角重新阐述这一人们熟悉的确定性方法。这一进程——从代数投影，到重构，再到概率潜变量建模——预示了变分自编码器（Variational Autoencoder, VAE）与扩散模型（diffusion model）等现代框架所使用的技术，在这些框架中，类似的原则以更灵活、更具表达力的形式再次出现。
- 重温核心线性代数概念。PCA 自然地展示了线性代数中的关键思想——投影、基变换、特征值与特征向量——它们支撑着本书其余部分中的许多构造。生成模型运行在高维空间中，数据在其中用矩阵来表示和变换。协方差矩阵、方差分析、矩阵分解以及基变换等概念反复出现，成为理解数据结构的工具。

基于这些原因，PCA 是本书理想的起点。

概念地图


本章展开为一段从基本线性变换到 PCA、再从 PCA 到自编码器的导引之旅。每一步的选择都是为了建立直觉、自然地衔接后续内容，并为后续章节发展的概率生成模型做好准备。

- 我们首先将矩阵理解为变换。矩阵-向量乘法的引入不是作为一种机械规则，而是作为一种理解向量与坐标系如何被重塑的方式。这一几何视角提供了 PCA 所需的直觉，更广泛地说，也为后续生成模型中反复出现的、基于变换的视角提供了直觉。
- 接着我们发展矩阵乘法的两种互补视角，并将它们与 PCA 联系起来。列组合视角展示矩阵如何定义输出由以构造的新方向，而行点积视角则用投影与对齐来解释乘法。这两种思想共同预示了 PCA 的两个核心角色：基变换，以及通过投影度量变异。

- 下一步，PCA 被表述为对方差最大方向的搜索，特征值与特征向量则作为求解这一问题的关键工具登场。通过将数据投影到候选方向并度量其散布程度，PCA 成为一个优化问题。由于协方差矩阵是对称的，其特征向量构成一组标准正交基，在该基下重写目标函数即可看出：方差最大的方向就是最大特征值所对应的特征向量。
- 然后我们将这一论证扩展到完整的降维与重构。前若干个特征向量定义了一组有序的正交主方向，每个方向在可能范围内捕获尽可能多的剩余方差。这自然地引出投影、重构以及方差贡献率（explained variance ratio），从几何与实践两个层面理解 PCA 如何压缩数据。
- 本章随后揭示 PCA 作为基变换的更深结构。将协方差矩阵对角化被解释为一个相似变换：它在保持总方差不变的同时，把方差重新组织到与主方向对齐的去相关坐标之中。这一视角也为奇异值分解（SVD）等更广泛的矩阵分解提供了自然入口。
- 最后，重点从方差转向重构，搭建起从 PCA 到自编码器的桥梁。PCA 被重新解释为一个最小化重构误差的编码器-解码器模型；随后线性自编码器恢复出同样的最优子空间，而非线性自编码器则将这一思想从线性子空间扩展到弯曲的流形。这一进程既揭示了确定性重构模型的力量，也暴露了其局限，从而为下一章发展的概率潜变量模型做了铺垫。

本章的轨迹在下图中作了可视化总结：从基本线性变换，经 PCA 与重构，到本书稍后使用的自编码器桥梁。

Linear algebra foundations at a glance



1.1 矩阵作为线性变换：基方向、投影与复合

矩阵最好被理解为作用于向量的变换的表示，而不仅仅是数字表格。矩阵指定了一个线性变换：一种以保持加法与缩放的方式移动向量的规则。理解矩阵如何作用于向量是一项基础技能：不仅对 PCA 这类线性方法如此，对由一系列线性与非线性变换构建而成的更复杂的生成模型也是如此。

1.1.1 矩阵作为基方向的变换

标准基与恒等变换。 我们从最简单的情形开始。在二维空间中，标准（恒等）基向量为

$$\hat{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \hat{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

$\mathbb{R}^2$ 中的每个向量都可以唯一地写成这两个方向的线性组合。

将这些基向量按列排成矩阵，便得到恒等矩阵

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

它表示使所有向量保持不变的变换。从几何上看，恒等变换保持每个向量不变，因此保持方向、长度与角度。

示例：一个 90° 旋转。 为了说明矩阵如何能动地变换空间，考虑

$$R = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}.$$

该矩阵的列展示了基向量如何被变换：

$$\hat{e}_1 \mapsto \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \hat{e}_2 \mapsto \begin{bmatrix} -1 \\ 0 \end{bmatrix}.$$

每个基方向都逆时针旋转了 90° 。由于每个向量都由这些基向量构成，同一旋转被均匀地施加于整个平面。

这个例子说明了线性代数的一条中心原则：

一个线性变换完全由它把基向量送到哪里所决定。

旋转之外：一般线性变换。 矩阵并不需要描述旋转。它的列不必正交，也不必具有单位长度。

例如，考虑

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}.$$

这里，第一个基向量保持不变，而第二个基向量从 $\begin{bmatrix} 0 \\ 1 \end{bmatrix}$ 被送到 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。这个变换对应于一个剪切（shear）：一条轴被倾斜，另一条保持固定。

尽管旋转与剪切各有不同，两者的描述方式完全相同：指定基向量如何被映射。一旦这一点确定，变换对其他所有向量的作用也就完全确定了。

图 1.1 使这种基向量视角变得直观：变换后的基向量决定了整个坐标网格如何被矩阵搬运。




图 1.1: **Basis directions determine the transformation.** The faint dashed lines show the original coordinate grid, while the transformed grid is drawn with solid lines. The arrows $A\hat{e}_1$ and $A\hat{e}_2$ are the transformed basis directions and the columns of A . A rotation preserves the square grid, whereas a shear tilts one family of grid lines; once the transformed basis directions are fixed, every other vector follows by linear combination.

下面我们转向这些变换如何通过矩阵乘法作用于任意向量。

1.1.2 矩阵乘法的两种视角

矩阵-向量乘法：列组合视角。 设 A 是列为 v_1 和 v_2 的矩阵。对于向量 $x = \begin{bmatrix} a \\ b \end{bmatrix}$ ，矩阵-向量乘法给出

$$Ax = av_1 + bv_2.$$

这一表达式揭示了矩阵乘法的第一种基本解释。矩阵的列定义了一组新方向，向量的分量则说明如何组合这些方向。因此，用矩阵乘向量就是把输出构造成矩阵各列方向的加权组合。

这一解释与向量本身的构造方式直接相连。任何向量都可以写成

$$x = a\hat{e}_1 + b\hat{e}_2,$$

即标准基向量的组合。矩阵-向量乘法只是把这些标准基方向替换为 A 的各列所编码的、变换后的坐标方向。

一般情形下，同一思想依然适用：

$$Ax = \sum_{j=1}^n x_j a_j,$$

其中 a_j 表示 A 的第 j 列。

矩阵-向量乘法：行乘列视角。理解矩阵-向量乘法还有第二种同等重要的方式。我们可以不关注列，而是考察输出向量的各个分量。

在这一视角下， Ax 的第 i 个分量由 A 的第 i 行与输入向量的点积得到。这种行乘列计算并非任意的数值规则——它具有清晰的几何意义。

为什么点积编码投影

余弦相似度。两个向量 v_1 和 v_2 之间的余弦相似度为

$$\cos \theta = \frac{v_1^\top v_2}{\|v_1\| \|v_2\|},$$

其中 θ 是它们之间的夹角。

标量投影。重排该表达式可得 v_1 在 v_2 方向上的标量投影：

$$\text{proj}_{v_2}(v_1) = \frac{v_1^\top v_2}{\|v_2\|}.$$

该量度量 v_1 有多少落在 v_2 方向上。

作为缩放投影的点积。点积因此可以写成

$$v_1^\top v_2 = \|v_2\| \times (\text{projection of } v_1 \text{ onto } v_2).$$

若 v_2 具有单位长度，点积就等于标量投影。

向量投影。将标量投影乘以 v_2 的单位方向，便得到相应的向量投影：

$$\text{proj}_{v_2}(v_1) = \frac{v_1^\top v_2}{\|v_2\|^2} v_2.$$

它给出 v_1 沿 v_2 方向分量的向量表示。

盒中的讨论表明，行乘列计算中出现的点积具有几何解释：它是投影或对齐程度的度量。从这个角度看， Ax 的每个分量记录了输入向量与 A 的某个行方向的对齐强度。

推广到矩阵-矩阵乘法。同样的思想自然地推广到矩阵-矩阵乘法。两个矩阵相乘对应于两个线性变换的复合。

乘积 AB 可以逐列理解：

$$AB = [Ab_1 \ Ab_2 \ \cdots \ Ab_p],$$

其中 B 的每一列都由 A 单独变换。等价地，作用于向量 v 时，乘积 AB 表示两次相继的变换：

$$(AB)v = A(Bv).$$

向量先被 B 变换，其结果再被 A 变换。每个阶段又都可以通过上面引入的列组合与行乘列视角来理解。

这些视角共同构成了直接支撑 PCA 表述的线性代数基础，并且在我们构建更具表达力的生成模型的过程中会反复出现：

- 列描述变换如何重塑空间，
- 列组合解释变换后的向量如何被构造，
- 逐行点积揭示投影如何被提取，
- 矩阵-矩阵乘法把变换串联在一起。

1.2 特征向量、特征值与矩阵的固有坐标系

在深入 PCA 之前，我们引入另一个理解矩阵如何作用于空间的基本工具。上一节中，我们把矩阵解释为通过沿不同方向进行混合、拉伸与投影来重塑向量的线性变换。为了更精确地刻画这种作用，我们现在寻找使变换尽可能简单的方向。

特征向量与特征值恰好提供了这样的语言。它们刻画矩阵的特殊方向——在变换下不与其他方向混合、而是被映射为自身标量倍数的方向。

特征值与特征向量。 给定方阵 $A \in \mathbb{R}^{d \times d}$ ，若非零向量 $v \in \mathbb{R}^d$ 满足

$$Av = \lambda v$$

则称其为 A 的特征向量，其中标量 $\lambda \in \mathbb{R}$ 称为对应的特征值。该方程告诉我们：当 A 作用于 v 时，输出仍位于 v 所张成的同一条直线上；其大小按 $|\lambda|$ 缩放，若 $\lambda < 0$ 则方向反转。

对一般向量而言，乘以 A 可能会旋转、拉伸、剪切该向量，或以其他方式扭曲其方向。因此，特征向量刻画的是变换下不与其他方向混合的方向：输出仍在同一条直线上，仅相差标量因子 λ 。于是，特征向量可以看作 A 所定义的变换下纯缩放的方向。

特征分解：在固有坐标系中表示矩阵。 若矩阵 $A \in \mathbb{R}^{d \times d}$ 有 d 个线性无关的特征向量，我们可以把它们组装成矩阵 V 的列，并把相应的特征值放到矩阵 Λ 的对角线上。

具体地，若 $v_1, v_2, \dots, v_d$ 是 A 的特征向量，对应的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_d$ ，那么

$$A[v_1 \ v_2 \ \cdots \ v_d] = [Av_1 \ Av_2 \ \cdots \ Av_d] = [\lambda_1 v_1 \ \lambda_2 v_2 \ \cdots \ \lambda_d v_d].$$

写成紧凑的矩阵形式，这一关系可表示为

$$AV = V\Lambda,$$

其中

$$V = [v_1 \ v_2 \ \cdots \ v_d], \quad \Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_d \end{bmatrix}.$$

整理该表达式，便得到特征分解

$$A = V\Lambda V^{-1}.$$

直觉：特征分解作为基变换

线性代数的一个核心思想是：同一个向量可以用不同的坐标系来描述。特征分解通过引入一个新基使矩阵的作用变得特别简单，从而把这一点明确化。

矩阵 V 把 A 的特征向量收集为其列。这些特征向量定义了一组新的坐标轴——空间的一个特征向量基。在该基下写下一个向量，就是用它沿这些优先方向的坐标来描述它。

坐标变换。给定标准基下表示的向量 x ，我们通过

$$x_{\text{eig}} = V^{-1}x.$$

来变换坐标。该操作不改变向量本身，只改变向量的表示，将其转换为特征向量坐标。

特征基下的简单作用。一旦在特征向量基下表示， A 的作用就变得尤为简单：每个坐标独立缩放，缩放因子由相应的特征值给出，正如对角矩阵 Λ 所刻画的：

$$x_{\text{eig}} \mapsto \Lambda x_{\text{eig}}.$$

返回原始基。经过这一缩放后，我们通过

$$x' = V(\Lambda x_{\text{eig}}),$$

把结果转换回原坐标系，从而在标准基下重构该向量。

把各步骤综合起来，分解 $A = V\Lambda V^{-1}$ 可以读作

$$x \xrightarrow{V^{-1}} \text{change of basis} \xrightarrow{\Lambda} \text{independent scaling} \xrightarrow{V} \text{return to original basis}.$$

特征分解因此表明：一旦选对了坐标系，矩阵的作用就是简单的缩放。

对称矩阵的特殊情形。对一般方阵而言，特征分解在实数范围内可能不存在，或者可能涉及复特征值，或者线性无关的特征向量数目不足。然而，当 A 是实对称矩阵 ($A = A^T$) 时，情形要简单得多。

此时，若干重要性质成立：

- A 的所有特征值都是实数。
- 存在一个正交矩阵 U ，其各列为 A 的特征向量，使得

$$A = U\Lambda U^T,$$

其中 U 的列具有单位长度且相互正交，即 $U^T U = I$ 。

这一特殊结构意味着对称矩阵总可以通过一次标准正交基变换实现对角化，因此坐标变换本身保持长度与角度。我们很快会看到，这一性质对 PCA 至关重要，因为经验协方差矩阵总是对称的。

有了这些工具，我们现在可以着手表述并求解 PCA 问题了。

1.3 基于方差最大化的主成分分析

主成分分析 (PCA) [33, 18] 通过引入一个适配数据结构的新坐标系, 为数据降维提供了一种系统化方法。其核心思想是找出数据变化程度最大的新坐标轴。通过让这些轴与最大散布的方向对齐, PCA 揭示了数据在哪里最具信息量, 并使我们在结构损失尽可能小的情况下获得低维表示。

PCA 背后的直觉可以概括为两条关键原则:

1. 方差即信息量。数据沿之呈现高方差的方向往往能更清晰地区分数据点, 因此携带更多有用的结构信息。方差很小的方向对区分数据的贡献较小。
2. 序贯正交最大化。PCA 首先识别能捕获尽可能大方差的单一方向。随后的方向在与已选方向保持正交的前提下, 尽可能多地捕获剩余方差。

1.3.1 PCA 的表述

数据中心化与投影方差的定义。 为了便于表述 PCA, 我们首先对数据中心化, 使数据云位于原点处。给定数据点 $\{x^{(i)}\}_{i=1}^n \subset \mathbb{R}^d$, 我们假设

$$\frac{1}{n} \sum_{i=1}^n x^{(i)} = 0.$$

这一步中心化确保变异性是相对于数据中心来度量的, 而不受任意偏移的影响。

正如前文在介绍投影与点积时所讨论的, 沿某一方向的变异性可以通过考察数据在该方向上投影的强弱来理解。设 $v \in \mathbb{R}^d$ 为表示候选投影方向的单位向量, 即 $\|v\| = 1$ 。对数据点 $x^{(i)}$, 其在 v 上的标量投影为

$$v^\top x^{(i)},$$

因为 v 具有单位长度。相应的向量投影为

$$(v^\top x^{(i)}) v.$$

这再次表明: 当 v 是单位向量时, 点积给出到该方向的标量投影。

由于数据已经中心化, 投影标量值的均值也为零:

$$\frac{1}{n} \sum_{i=1}^n v^\top x^{(i)} = v^\top \left(\frac{1}{n} \sum_{i=1}^n x^{(i)} \right) = 0.$$

为了量化这些投影值的散布程度, 我们度量它们相对于该均值的方差。因此, 数据沿方向 v 投影后的方差为

$$\text{Var}(v^\top X) = \frac{1}{n} \sum_{i=1}^n (v^\top x^{(i)})^2.$$

从几何上看, 投影更大、更分散的方向对应更高的方差。

协方差矩阵形式。 投影方差可以用矩阵记号紧凑地写成：

$$\text{Var}(v^\top X) = \frac{1}{n} \sum_{i=1}^n v^\top x^{(i)} (x^{(i)})^\top v = v^\top \left(\frac{1}{n} \sum_{i=1}^n x^{(i)} (x^{(i)})^\top \right) v.$$

括号内的矩阵就是经验协方差矩阵，

$$\Sigma = \frac{1}{n} \sum_{i=1}^n x^{(i)} (x^{(i)})^\top.$$

因此，数据沿方向 v 投影后的方差为

$$\text{Var}(v^\top X) = v^\top \Sigma v.$$

PCA 问题因此是在单位长度约束下最大化该量：

$$\max_{v \in \mathbb{R}^d} v^\top \Sigma v \quad \text{subject to} \quad v^\top v = 1.$$

1.3.2 求解 PCA 的优化问题

协方差矩阵 Σ 按其构造是对称的。如上一节所述，对称矩阵容许正交特征分解：

$$\Sigma = U \Lambda U^\top, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d),$$

其中 U 的列是标准正交特征向量，特征值按

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0.$$

排序。

为求解该优化问题，我们在这个特征向量坐标系中表达目标函数。

第一步：基变换到特征向量坐标。 沿用先前引入的基变换解释，我们把方向向量 v 在特征向量基下表示为

$$\tilde{v} = U^\top v.$$

由于 U 正交，有 $U^\top = U^{-1}$ ，因此该操作只是把 v 的坐标从标准基变换到特征向量基。

正交变换还保持向量长度：

$$\tilde{v}^\top \tilde{v} = (U^\top v)^\top (U^\top v) = v^\top U U^\top v = v^\top v.$$

因此，单位长度约束 $v^\top v = 1$ 变为

$$\tilde{v}^\top \tilde{v} = 1.$$

第二步：目标函数的对角化。 将特征分解代入目标函数可得

$$v^\top \Sigma v = v^\top U \Lambda U^\top v = (U^\top v)^\top \Lambda (U^\top v) = \tilde{v}^\top \Lambda \tilde{v}.$$

由于 Λ 是对角矩阵，该表达式简化为

$$\tilde{v}^\top \Lambda \tilde{v} = \sum_{i=1}^d \lambda_i \tilde{v}_i^2.$$

这明确地显示：沿方向 v 捕获的方差是特征值的加权和，权重由 v 与各特征向量的对齐强度决定。

第三步：方差的界。 由于 $\tilde{v}_i^2 \geq 0$ 且 $\sum_{i=1}^d \tilde{v}_i^2 = 1$ ，目标函数是特征值的加权平均：

$$\sum_{i=1}^d \lambda_i \tilde{v}_i^2 \leq \lambda_1 \sum_{i=1}^d \tilde{v}_i^2 = \lambda_1.$$

任何由较小特征值构成的组合都无法超过最大的特征值。

第四步：最优方向。 只有当全部权重都放在最大特征值上时，上界才能取到：

$$\tilde{v} = [1, 0, \dots, 0]^\top.$$

变换回原坐标即得

$$v = U\tilde{v} = u_1,$$

即最大特征值 λ_1 所对应的特征向量。

因此，最大化投影方差的方向恰好是协方差矩阵的主特征向量，且最大方差等于 λ_1 。

后续主成分。 于是第一主成分就是 u_1 。其余分量通过在强制与已选方向正交的前提下重复上述优化得到。第 k 个主成分是对应第 k 大特征值的特征向量 u_k ，满足

$$u_k^\top u_j = 0 \quad \text{for all } j < k.$$

从几何上看，每个新的主方向在与先前方向保持正交的同时，捕获尽可能多的剩余变异性。由于这些方向是协方差矩阵的正交特征向量，所得到的主成分坐标互不相关。协方差矩阵的特征分解自然地提供了这样一组有序且标准正交的方向。

1.3.3 用于降维的 PCA

识别出主成分之后，PCA 便提供了一个具体的降维流程：把数据投影到低维子空间，并且（如有需要）再重构回原空间。

设

$$U_k = [u_1 \ u_2 \ \dots \ u_k] \in \mathbb{R}^{d \times k}$$

表示由前 k 个主成分（即协方差矩阵 Σ 对应最大特征值 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$ 的特征向量）构成的矩阵。PCA 通过仅用这 k 个捕获最大方差的方向来表示数据点 $x \in \mathbb{R}^d$ ，从而降低其维数。

投影（编码）。 x 的低维表示通过将其投影到主成分子空间得到：

$$z = U_k^\top x \in \mathbb{R}^k.$$

向量 z 包含 x 沿各主方向的坐标，构成数据的压缩表示。

重构（解码）。仅用这 k 个分量得到的 x 的近似，通过把低维表示映射回原空间获得：

$$\hat{x} = U_k z = U_k U_k^\top x.$$

该操作取 x 在主成分空间中的坐标，并通过组合 U_k 中的各主方向，在原特征空间中重构出一个向量。由于只保留了前 k 个分量，这一重构过程不可避免地会丢失一些信息。

值得注意的是，当 $k = d$ 时，有 $U_k \in \mathbb{R}^{d \times d}$ 且

$$U_k U_k^\top = I,$$

此时重构是精确的。而当 $k < d$ 时， $U_k U_k^\top$ 不再是恒等矩阵， $\hat{x}$ 只是原数据点的近似。

方差贡献率。实践中，量化降维后保留了多少总变异性十分重要。为此最常用的度量是方差贡献率（explained variance ratio）。

原始数据集的总方差为

$$\sum_{i=1}^d \lambda_i,$$

而前 k 个主成分捕获的方差为

$$\sum_{i=1}^k \lambda_i.$$

因此， k 维表示所保留的方差比例为

$$\text{Explained Variance Ratio} = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i},$$

它为选择分量个数提供了一个有原则的、数据驱动的判据，在实践中被广泛使用。

现在我们转而更细致地考察 PCA 的结构。这将说明为什么方差贡献率是量化降维保留信息量的一个有原则的方式，也将揭示我们在下一节要探讨的 PCA 的更深层本质。

1.4 PCA 作为基变换：相似变换与 SVD

我们现在从一个更深的结构视角重新审视 PCA。上一节中，PCA 作为方差最大化问题的解而出现。这里我们表明，同一过程也可以理解为一种使协方差矩阵对角化、并沿正交方向重新组织方差的基变换。这一视角解释了为什么总方差得以保持、为什么特征值自然地量化沿主方向捕获的方差，以及为什么 PCA 产生互不相关的坐标。

这一视角也自然地引出奇异值分解（Singular Value Decomposition, SVD），它把同样的几何思想推广到协方差矩阵之外、乃至非方阵非对称矩阵之外。尽管 SVD 对 PCA 的基本表述并非必需，它提供了一个更宽广的线性代数视角，在本书后续内容中始终有用。

为发展这一解释，我们从两个关键概念入手：矩阵的迹与相似变换。

1.4.1 迹、相似变换与方差保持

协方差矩阵的迹。对任意方阵 $A \in \mathbb{R}^{d \times d}$ ，迹定义为其对角元素之和：

$$\text{Tr}(A) = \sum_{i=1}^d a_{ii}.$$

当 A 是协方差矩阵 Σ 时，每个对角元素 σ_{ii} 是第 i 个坐标的方差。于是，

$$\text{Tr}(\Sigma) = \sum_{i=1}^d \Sigma_{ii} = \sum_{i=1}^d \text{Var}(X_i),$$

这正是数据集在所有坐标上的总方差。

这一观察对 PCA 十分重要。尽管基变换可能改变方差在各个坐标上的分布，总方差却保持不变。迹提供了一种表达总方差的紧凑方式。

相似变换。前文我们看到，在可逆矩阵 A 所定义的新基下表示向量，对应于一次坐标变换，

$$v_A = A^{-1}v.$$

同样的思想也适用于线性变换本身。当线性变换 T 在这个新基下表示时，其矩阵表示变为

$$T_A = A^{-1}TA,$$

这被称为相似变换 (similarity transformation)。该表达式表示的是同一个线性变换，只是写在了由基 A 决定的另一坐标系中，如下方推导所示。

为什么 $T_A = A^{-1}TA$

若 $v_A = A^{-1}v$ 表示向量 v 在 A 定义的新基下的坐标，那么线性变换 T 在该坐标系中必须具有相应的表示 T_A 。两个矩阵描述的是同一个几何变换，因此把 T_A 作用于坐标向量 v_A 所得的结果，必须与在原坐标中先作用 T 再换基的结果相同：

$$v'_A = T_A v_A, \quad v'_A = A^{-1}(Tv).$$

由于这两种流程在 A 坐标下必须给出同一向量，代入 $v_A = A^{-1}v$ 使得

$$T_A A^{-1}v = A^{-1}Tv \quad \text{for all } v.$$

两边左乘 A ，得

$$AT_A A^{-1} = T, \quad \implies \quad T_A = A^{-1}TA.$$

基变换下迹的不变性。迹的一个关键代数性质是其循环恒等式，

$$\text{Tr}(BC) = \text{Tr}(CB),$$

只要矩阵乘积 BC 与 CB 有定义，它就成立。

把这一性质与相似变换 $T_A = A^{-1}TA$ 相结合，便得

$$\text{Tr}(T_A) = \text{Tr}(A^{-1}TA) = \text{Tr}(T).$$

这表明迹在相似变换下保持不变。因此，尽管基变换可能重新分配各坐标上方差的表达方式，它保持了方差的总量。

1.4.2 PCA 作为相似变换

我们现在从基变换的视角重新审视 PCA。对单个数据点 $x \in \mathbb{R}^d$ ，其低维表示通过向主成分方向投影得到，即 $z = U_k^\top x$ 。在整个数据集的层面，把中心化后的数据点按行收集到矩阵 X 中，应用 PCA 对应于线性变换 $Z = XU$ ，其中 U 是以协方差矩阵 Σ 的特征向量为列的正交矩阵。

我们现在考察这一基变换如何影响数据的协方差结构。

变换后数据的协方差。 变换后数据的协方差矩阵为

$$\tilde{\Sigma} = \text{Cov}(Z) = \text{Cov}(XU).$$

一般地，随机向量 Y 的协方差可以写成

$$\text{Cov}(Y) = \mathbb{E}[(Y - \mathbb{E}[Y])^\top (Y - \mathbb{E}[Y])].$$

在我们的设定中，数据已经中心化，故 $\mathbb{E}[X] = 0$ 。由于 U 是固定的线性变换，这蕴含

$$\mathbb{E}[Z] = \mathbb{E}[XU] = \mathbb{E}[X]U = 0.$$

因此，变换后数据的协方差简化为

$$\tilde{\Sigma} = \mathbb{E}[(Z - \mathbb{E}[Z])^\top (Z - \mathbb{E}[Z])] = \mathbb{E}[Z^\top Z].$$

代入 $Z = XU$ 得

$$\tilde{\Sigma} = \mathbb{E}[(XU)^\top (XU)] = U^\top \mathbb{E}[X^\top X]U = U^\top \Sigma U.$$

PCA 之前与之后。现在我们可以明确陈述这一核心的结构性结果：

$$\text{Cov}(X) = \Sigma, \quad \text{Cov}(Z) = U^\top \Sigma U.$$

也就是说，PCA 通过

$$\Sigma \mapsto U^\top \Sigma U,$$

来变换协方差矩阵，这恰好是对原协方差矩阵的一次相似变换。

相似变换的推论。 由于相似变换保持迹，我们有

$$\text{Tr}(\Sigma) = \text{Tr}(U^\top \Sigma U) = \text{Tr}(\Lambda),$$

其中 $\Sigma = U\Lambda U^\top$ 是协方差矩阵的特征分解。

这刻画了 PCA 的几何意义。在 PCA 之前，协方差矩阵 Σ 可能包含非对角项，反映各坐标之间的相关性。换到特征向量基之后，协方差变为对角的：

$$U^\top \Sigma U = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d).$$

因此，变换后的坐标互不相关，且每个主方向上的方差以相应特征值的形式直接出现在对角线上。

PCA 既不创造方差，也不销毁方差。它只是在与数据自然方向对齐的坐标系中重新表达同一总方差。由迹给出的总方差保持不变，而其分布则从相关的坐标被重新组织到正交的主方向上。

这也解释了为什么方差贡献率具有如此自然的形式。保留前 k 个主成分所保留的方差为 $\sum_{i=1}^k \lambda_i$ ，总方差为 $\sum_{i=1}^d \lambda_i$ 。因此 $\frac{\sum_{i=1}^k \lambda_i}{\sum_{i=1}^d \lambda_i}$ 度量了丢弃其余方向之后所保留的总方差比例。

图 1.2 直接展示了这一坐标变换：同一数据云在主成分坐标下变为轴对齐，同时其总方差保持不变。




图 1.2: PCA diagonalises covariance by changing basis. The same data are shown in the original and principal-component coordinates. In the new basis, the principal directions become the coordinate axes, covariance between the coordinates vanishes, and total variance is preserved.

1.4.3 从特征分解到奇异值分解

上面的讨论表明，PCA 可以理解为一种使协方差矩阵对角化、并沿正交方向重新组织方差的基变换。这自然引出一个更宽泛的问题：

如果我们想要理解的矩阵不是协方差矩阵、不是对称的、甚至不是方阵，会怎样？

奇异值分解 (SVD) 提供了相应的一般性框架 [41]。

特征分解基于关系 $Av = \lambda v$ ，它识别的是在缩放意义下被映射到自身的方向。沿这些方向，变换尤为简单：输出仍在同一条直线上，被缩放 λ 倍。

这一视角威力强大，但也有局限。它只适用于方阵，而且一般还需要附加条件才能保证一个完整且性质良好的实分解。

SVD 推广了这一思想。它不再要求方向被矩阵保持不变，而是提出一个更灵活的问题：哪些正交的输入方向被映射到哪些正交的输出方向，它们又被拉伸了多少？

SVD 视角。 对实矩阵 $A \in \mathbb{R}^{m \times n}$ ，奇异值分解形如

$$A = USV^\top,$$

其中 $V \in \mathbb{R}^{n \times n}$ 包含标准正交的输入方向； $U \in \mathbb{R}^{m \times m}$ 包含标准正交的输出方向；而 $S \in \mathbb{R}^{m \times n}$ 是“矩形意义下对角”的矩阵，其主对角线上为非负元素 $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$ 。

这些量满足

$$Av_i = \sigma_i u_i, \quad A^\top u_i = \sigma_i v_i,$$

其中 v_i 是右奇异向量， u_i 是相应的左奇异向量， σ_i 是相应的奇异值。

从几何上看，SVD 表明每个正交输入方向 v_i 被映射到正交输出方向 u_i ，并按相应的奇异值 σ_i 缩放。与特征分解不同，输入与输出方向不必重合，这正是 SVD 对任何实矩阵（包括矩形矩阵与非对称矩阵）都存在的原因。特征分解于是表现为一个特殊情形：当 A 对称时，输入与输出方向重合 ($U = V$)，奇异值变为特征值的绝对值。

SVD 强化了贯穿本书的一个主题：一旦选择了合适的坐标系或分解，复杂的线性变换往往变得容易理解得多。PCA 通过旋入特征向量基，对协方差矩阵实现了这一点。SVD 则把同样的哲学推广到任意矩阵。

即使后续模型超越了线性变换，这种结构化的思维习惯依然重要。我们不断地寻求使复杂操作分解为更简单、更可解释的组件的表示。从这个意义上说，SVD 不仅仅是一种数值工具，更是支撑 PCA 的同一几何思想在概念上的延伸。

秩一结构与矩阵的几何

SVD 最具启发性的解释之一是它的秩一展开：

$$A = \sum_{i=1}^r \sigma_i u_i v_i^\top,$$

其中秩 r 是构造该矩阵所需的独立方向的个数。

每一项 $\sigma_i u_i v_i^\top$ 都是一个秩一变换 (rank-one transformation)，由两个向量的外积构成。从几何上看，它执行一个简单的三步操作：

$$\text{project onto } v_i \rightarrow \text{scale by } \sigma_i \rightarrow \text{reorient along } u_i.$$

由于 $v_i^\top x$ 是标量，输出 $u_i v_i^\top x$ 总是单一向量 u_i 的标量倍。因此所有可能的输出都位于同一个固定方向上，该变换只能张成一维的输出空间，故其秩为一。这表明，任何矩阵都可以理解为这些基本外积变换的叠加，每一项捕获一个独立的作用模式。

1.5 从 PCA 到自编码器：重构、子空间与流形

在前几节中，PCA 主要通过方差最大化的视角来展开：我们寻找数据散布最大的方向，并把这些方向用作新的坐标系。这一视角揭示了 PCA 如何重组数据，使其最具信息量的变化显式化。

然而，还有另一种同样自然、而且极其直观的方式来理解同一方法。与其问哪些方向能捕获最多的方差，我们可以提出一个重构问题：

如果把数据压缩为 k 维表示再重构，哪个 k 维表示损失的信息最少？

这一重新表述把 PCA 从一个特征值问题变为一个逼近问题。几何没有改变，但重点从捕获方差转移到了最小化重构误差。这一转变十分重要，因为重构（而非方差最大化）成为自编码器以及许多后续表示学习模型背后的组织原则。

1.5.1 从方差最大化到重构。

设 $U_k = [u_1, \dots, u_k] \in \mathbb{R}^{d \times k}$ 表示以协方差矩阵前 k 个特征向量为列的矩阵。对中心化后的数据点 $x_i \in \mathbb{R}^d$ ，PCA 给出低维表示

$$z_i = U_k^\top x_i,$$

它记录了 x_i 沿各主方向的坐标。由该表示重构得到

$$\hat{x}_i = U_k z_i = U_k U_k^\top x_i,$$

这正是 x_i 到 U_k 的列所张成的 k 维子空间的正交投影。

一旦原数据点 x_i 与其重构 $\hat{x}_i$ 都已得到，信息损失的自然度量就是二者之差。这引出平方重构误差

$$\|x_i - \hat{x}_i\|^2 = \|x_i - U_k U_k^\top x_i\|^2.$$

对所有数据点求和，得到总重构损失

$$L(U_k) = \sum_{i=1}^n \|x_i - U_k U_k^\top x_i\|^2.$$

从这一视角看，PCA 可以表述为

$$\min_{U_k^\top U_k = I_k} \sum_{i=1}^n \|x_i - U_k U_k^\top x_i\|^2,$$

它所问的是：

哪个标准正交的 k 维子空间，能使数据先压缩再重构所造成的失真最小？

这一重构表述与前面 PCA 的方差最大化视角完全等价，并与经典的最佳低秩逼近视角密切相关 [20]。尽管目标函数的写法不同，两种表述恢复的都是同一个由协方差矩阵前若干特征向量张成的最优 k 维子空间。

图 1.3 在二维情形下展示了这一等价性：主方向同时产生最宽的投影坐标与最小的正交重构残差。




图 1.3: PCA links maximal projected variance and minimal reconstruction error. The same centred dataset is projected onto a non-principal direction and the leading principal direction. The principal direction gives greater projected variance and smaller orthogonal reconstruction residuals. Residual segments are shown for only a subset of points for clarity.

这一视角尤其有价值，因为它把 PCA 重塑为一对映射：

$$x \longrightarrow z = U_k^\top x \longrightarrow \hat{x} = U_k z.$$

也就是说，PCA 可以看作一个编码器（encoder）后接一个解码器（decoder），二者均为线性映射且由解析确定。

自编码器作为可学习的编码器-解码器模型。一旦 PCA 用重构形式表达，一个自然的推广便随之出现。与其从特征向量解析地推导编码器与解码器，我们可以尝试通过最小化重构误差直接从数据中学习它们，由此得到自编码器的视角 [3, 15]。

形式上，自编码器引入两个参数化映射。给定输入 $x \in \mathbb{R}^d$,

- 编码器把输入压缩为一个潜表示

$$z = q_\phi(x) \in \mathbb{R}^k, \quad k < d,$$

其中 q_ϕ 由 ϕ 参数化；

- 解码器从该潜码重构输入：

$$\hat{x} = p_\theta(z),$$

其中 p_θ 由 θ 参数化。

二者共同定义了熟悉的编码器-解码器流程

$$x \longrightarrow z = q_\phi(x) \longrightarrow \hat{x} = p_\theta(z).$$

参数 (ϕ, θ) 随后通过最小化重构误差学习得到，例如

$$\min_{\phi, \theta} \|p_\theta(q_\phi(x)) - x\|^2,$$

或在整个数据集上，

$$\min_{\phi, \theta} \sum_{i=1}^n \|p_\theta(q_\phi(x_i)) - x_i\|^2.$$

这一目标函数直接对应 PCA 的重构表述：

$$\min_{U_k^\top U_k = I_k} \sum_{i=1}^n \|U_k U_k^\top x_i - x_i\|^2.$$

本质区别在于：在 PCA 中，编码器与解码器是与标准正交特征向量绑定在一起的固定线性映射；而在自编码器中，它们被视为可学习的函数。

1.5.2 线性自编码器何时能恢复 PCA?

线性自编码器与 PCA 之间的联系是经典性的 [3]。但仅凭这一联系本身，并不能保证会恢复出 PCA。要精确恢复 PCA，有两个结构性因素至关重要。

1. 线性。 设编码器与解码器均为线性：

$$q_\phi(x) = W_q x, \quad p_\theta(z) = W_p z,$$

其中矩阵为 $W_q \in \mathbb{R}^{k \times d}$ 和 $W_p \in \mathbb{R}^{d \times k}$ 。此时重构变为

$$\hat{x} = W_p W_q x.$$

在这种情况下，模型仍处于 PCA 的几何框架之内：所有重构都落在 $\mathbb{R}^d$ 的一个 k 维线性子空间中。

若引入非线性激活函数，这一限制便消失了。模型于是可以表示弯曲的非线性结构，而不再局限于单一的平坦子空间。因此，若目标是停留在经典 PCA 框架之内，线性是本质的。

2. 子空间与基。 PCA 不仅仅是识别出一个 k 维子空间，而是用主特征向量给出的标准正交基来识别它。相比之下，线性自编码器并不被迫学习一个标准正交基。仅最小化重构误差并不强加正交性。

这一区别重要而微妙。降维的关键几何对象不是某个特定的基，而是该基所张成的子空间。

子空间与列空间。 给定向量组 $\{v_1, \dots, v_k\} \subset \mathbb{R}^d$ ，它们的张成 (span) 为

$$\text{Span}(v_1, \dots, v_k) = \left\{ \sum_{i=1}^k \alpha_i v_i : \alpha_i \in \mathbb{R} \right\}.$$

不同的向量组可以张成完全相同的子空间。例如，

$$\text{Span}\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}\right) = \text{Span}\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) = \mathbb{R}^2.$$

当把向量收集为矩阵 $A \in \mathbb{R}^{d \times k}$ 的列时，它们的张成被称为 A 的列空间 (column space, 或值域):

$$\mathcal{R}(A) = \{Az : z \in \mathbb{R}^k\}.$$

这才是对降维真正重要的几何对象。PCA 用标准正交基 $U_k = [u_1, \dots, u_k]$ 识别出最优的 k 维子空间。线性自编码器则可以用一个不同的、一般而言非正交的基来识别同一子空间。

重构损失下的子空间恢复。 对线性自编码器，

$$\hat{x} = W_p W_q x,$$

每个重构都位于 W_p 的列空间中:

$$\hat{x} \in \mathcal{R}(W_p).$$

若模型在平方重构误差下被训练到最优，那么该列空间恢复的是与 PCA 相同的最优 k 维子空间，即使基向量本身各不相同。

这一区别至关重要：PCA 为最优子空间选定了特定的标准正交基，而线性自编码器只需恢复子空间本身。从重构的视角看，这就足够了。两个不同的基——无论正交与否——只要张成同一组方向，就表示同一个几何对象。

如果之后需要一个标准正交基，总可以通过对学习到的解码矩阵进行正交化来获得。更一般地，任何张成某个子空间的满秩向量组，都可以用标准过程（如 Gram-Schmidt 正交化、QR 分解或相关矩阵分解）转换为同一子空间的标准正交基。

例如，QR 分解

$$W_p = QR,$$

(其中 $Q^T Q = I_k$) 产生矩阵 Q ，其各列恰好构成与 W_p 所张成子空间完全相同的标准正交基。关键在于：正交化改变的是表示子空间所用的基，而不改变子空间本身。

1.5.3 从线性子空间到非线性流形

自编码器的真正威力，在允许编码器与解码器为非线性时才显现出来。在线性情形下，若解码器形如

$$p_\theta(z) = W_p z,$$

则所有重构都位于单一线性子空间

$$\{\hat{x} = W_p z : z \in \mathbb{R}^k\}.$$

之中。无论潜码 z 如何变化，输出始终被限制在 $\mathbb{R}^d$ 内一张平坦的 k 维曲面上。

若解码器变为非线性，这一几何结构就发生了根本性的变化。可能的重构集合变为

$$\mathcal{M}_\theta = \{p_\theta(z) : z \in \mathbb{R}^k\},$$

它不再局限于线性子空间。相反，它可以形成嵌入在环境空间中的弯曲低维曲面。这样的曲面被称为流形 (manifold)。

因此，非线性自编码器以一种深刻的方式推广了 PCA。它学习的不是单一的平坦子空间，而是一个能够更灵活地适应数据内在结构的弯曲流形。

图 1.4 区分了两个容易混淆的想法：线性自编码器可以使用不同的基，却张成与 PCA 相同的子空间；而非线性解码器通过允许弯曲的重构流形，改变了几何结构本身。




图 1.4: **From PCA subspaces to learned manifolds.** PCA represents a linear subspace using a particular orthonormal basis. A linear autoencoder can recover the same optimal subspace using a different, generally non-orthogonal decoder basis; the basis vectors need not match PCA even when the represented plane does. Once the decoder is nonlinear, the reconstruction set is no longer restricted to one flat subspace and can instead form a curved low-dimensional manifold.

非线性编码器与解码器。 实践中，非线性自编码器通常用神经网络来实现。编码器可以取形式

$$z = q_\phi(x),$$

其中 q_ϕ 是仿射映射与非线性激活函数的复合，解码器类似地取形式

$$\hat{x} = p_\theta(z).$$

整体结构仍为

$$x \longrightarrow z \longrightarrow \hat{x},$$

但容许的变换类要比 PCA 中的丰富得多。

这一过渡——从线性子空间到非线性流形——是自编码器成为现代表示学习重要工具的关键原因之一。PCA 由此表现为一个大得多的重构式模型家族中最简单的成员：线性、正交、且可解析求解。

为什么确定性自编码器还不是生成模型。 尽管表达能力更强，确定性自编码器仍然缺失生成建模的一个关键成分：

对潜变量如何生成数据的概率化描述。

确定性自编码器把每个输入 x 映射到单一潜码 z ，再映射到单一重构 $\hat{x}$ 。这无法提供有原则的方式来

- 为潜表示赋予概率，
- 通过从指定分布中抽取潜变量来生成新样本，
- 或通过基于似然的原则来训练模型。

要获得这些能力，我们必须超越确定性重构模型，引入概率潜变量模型。这一过渡直接通向概率 PCA (PPCA)，随后通向变分自编码器 (VAE)，其中重构被保留下来，但被嵌入到一个概率框架之中。

从这个视角看，路径已经清晰。PCA 通过方差最大化引入线性子空间。其重构表述自然地引出自编码器。线性自编码器恢复出与 PCA 相同的最优子空间，而非线性自编码器则把这一思想推广到流形。但要抵达现代生成建模，我们必须再往前走一步，为潜表示配备概率分布。

下一章将以概率 PCA 开始这一过渡。

总结与参考文献

本章介绍了 PCA 所需的线性代数思想，并用它们搭建起从经典降维到自编码器的桥梁。

我们首先把矩阵解释为线性变换，强调基变换、点积与投影是支撑 PCA 的几何语言。这自然地引出特征向量与特征值，它们刻画了矩阵作用最为简单的那些特殊方向。

利用这些工具，PCA 先被发展为方差最大化，随后被发展为使协方差矩阵对角化的基变换。这两种视角阐明了为什么主成分是前若干特征向量、为什么特征值度量所捕获的方差，以及 PCA 如何通过投影与重构实现降维。

本章随后把重点从方差转向重构。把 PCA 重新塑形为线性编码器-解码器模型，直接架起了通往自编码器的桥梁。线性自编码器恢复出与 PCA 相同的最优子空间，而非线性自编码器则把这一思想从平坦子空间扩展到弯曲流形。

本章内容取材自线性代数、矩阵分解与降维中的标准思想。关于底层的线性代数与矩阵视角，一部有用的广泛参考是 Strang [41]，而 Jolliffe 与 Cadima [20] 提供了关于 PCA 及其解释的现代综述。关于历史背景，PCA 的经典起源可追溯到 Pearson [33] 与 Hotelling [18]。线性自编码器与 PCA 之间的联系由 Baldi 与 Hornik [3] 讨论，而深度自编码器则由 Hinton 与 Salakhutdinov [15] 显著发展。

第 2 章 2

概率主成分分析：通往潜变量生成建模的桥梁

概览

从确定性的表示学习迈向概率生成建模，概率主成分分析 (Probabilistic Principal Component Analysis, PPCA) 是继 PCA 与自编码器 (autoencoder) 之后的自然下一步，主要原因有二：

- 引入概率潜变量建模。在上一章中，PCA 与自编码器展示了如何通过低维结构来表示数据，但它们本质上仍是确定性的。PPCA 引入了将在本书其余部分反复出现的关键概率要素：潜变量 (latent variable) 上的先验、给定潜在成因后观测的条件分布、用于学习的边际似然，以及用于推断的后验分布。从这个意义上说，PPCA 是本书中的第一个概率潜变量模型。
- 提供通往现代生成模型的解析可处理桥梁。由于 PPCA 是线性且高斯的，其所有核心量仍可用闭式形式推导。这种罕见的可处理性使它成为理想的桥梁模型：它让我们能够在一个每一步在数学上都保持透明的环境中，研究基于似然的学习、后验推断、Jensen 不等式 (Jensen's inequality)、证据下界 (Evidence Lower Bound, ELBO) 以及期望最大化 (Expectation Maximisation, EM) 算法。这些思想稍后将在更具表达力但更难处理的模型 (例如变分自编码器 (Variational Autoencoder, VAE)) 中重新出现。


概念导览

本章以一场从确定性降维到概率潜变量建模的导览之旅展开。

- 我们首先将 PPCA 表述为 PCA 的概率扩展。引入一个潜变量，作为观测数据的隐藏低维成因；高斯噪声则把确定性的 PCA 重构转变为关于可能观测的一个完整生成分布。
- 接着我们推导观测数据的边际似然。由于 PPCA 是线性且高斯的，潜变量可以被精确地积分掉，结果表明观测数据本身服从一个高斯分布，其协方差将潜在结构与各向同性噪声分离开来。

- 在显式获得边际似然之后，我们考虑三种优化视角。PPCA 可以通过直接的解析极大似然、通用的基于梯度的优化或 EM 算法来学习。这一比较既说明了 PPCA 为何异常易于处理，也说明了为什么 EM 是对后续内容而言在概念上最重要的路径。
- 随后本章从精确的 PPCA 迈向一般的潜变量设定。Jensen 不等式被引入，作为把不可处理的对数似然替换为可处理的下界的关键数学工具，并由此得到 ELBO。
- 接下来我们推导 EM，作为迭代最大化该下界的方法。E 步更新潜变量分布，M 步更新模型参数。在 PPCA 中，该过程得到与精确解析推导相同的解，但此时它被理解作为一种更一般的推断原理的一部分。
- 最后，我们指出 PPCA 的一个遗留局限，它引出下一章的内容。尽管 PPCA 引入了潜变量上的先验，但它并未显式地对推断出的潜空间进行正则化以使其与该先验对齐。这一局限直接指向变分自编码器（VAE）——在那里，概率推断与潜空间正则化被统一到同一个学习目标之中。

PPCA 的主要概率关系在下方以图示方式总结。



2.1 概率 PCA 的表述

在上一章中，PCA 与自编码器引入了这样一种思想：高维数据可以通过低维潜结构来表示。然而，两者本质上都仍是确定性的：一旦选定某个潜在表示，重构便固定不变。迈向生成建模的关键一步，是超越这种确定性图景，允许一个潜点对应的不再是单个观测，而是可能观测上的一个分布。

概率主成分分析（PPCA） [42] 是本书中使这一转变显式化的最简单模型。它保留了 PCA 的线性潜结构，但将其嵌入到一个概率生成过程之中，从而成为潜变量生成模型的第一个具体例子。

作为潜变量生成模型的 **PPCA**。在正式引入模型之前，值得停下来琢磨一下潜变量这个术语。*latent*（潜）一词的含义就是隐藏：它指的是一个不被直接观测、但被假定隐藏在数据背后并解释其部分结构的变量。在 PPCA 中，观测向量 $\mathbf{x}$ 是我们看到的数据点，而 $\mathbf{z}$ 是我们不直接观测的低维隐藏表示。模型假设 $\mathbf{x}$ 由 $\mathbf{z}$ 生成，而不是把 $\mathbf{x}$ 当作孤立的对象。这

一转变——从只看观测数据，到观测数据由隐藏成因生成——正是潜变量生成建模的定义性思想之一。

PPCA 的生成过程由两步组成：

1. 从一个标准高斯先验中采样潜在向量

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

2. 通过施加线性变换、添加均值偏移并注入高斯噪声 ϵ 来生成观测：

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \alpha^2 \mathbf{I}).$$

其中，

- $\mathbf{z} \in \mathbb{R}^k$ 是潜变量，
- $\mathbf{x} \in \mathbb{R}^d$ 是观测数据点，
- $\mathbf{W} \in \mathbb{R}^{d \times k}$ 将潜在坐标映射到观测空间，
- $\boldsymbol{\mu} \in \mathbb{R}^d$ 是数据的均值，
- α^2 控制各向同性的观测噪声。

这个模型已经包含了后续许多生成模型的核心要素：潜变量上的先验、把潜变量映射到观测的规则，以及可能输出上的概率分布。相对 PCA 的关键新意在于，潜在表示不再精确地决定单个点。取而代之，它决定的是可能观测分布的中心。

观测的条件分布。 尽管生成方程

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \epsilon$$

看起来与确定性映射类似，但由于随机噪声项的存在，其含义在根本上是概率性的。在给定的潜在向量 $\mathbf{z}$ 的条件下，观测是高斯的：

$$\mathbf{x} \mid \mathbf{z} \sim \mathcal{N}(\mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \alpha^2 \mathbf{I}).$$

这是核心的概率转变：一旦 $\mathbf{z}$ 固定， $\mathbf{W}\mathbf{z} + \boldsymbol{\mu}$ 决定的是观测分布的均值，而非单个重构。图 2.1 展示了 $k = 1$ 、 $d = 2$ 这一简单情形下的几何图像。随着 z 变化，条件均值在观测空间中描绘出一条直线，而各向同性高斯噪声则在每个均值周围生成可能的观测。因此，潜变量控制在低维子空间中的位置，而噪声允许观测偏离该子空间。




图 2.1: **From latent coordinates to probabilistic observations.** Selected latent coordinates are shown under the prior $p(z) = \mathcal{N}(0, 1)$, mapped to conditional means $\mathbf{W}z + \boldsymbol{\mu}$ in observation space, and then used as the centres of isotropic conditional distributions $p(\mathbf{x} | z) = \mathcal{N}(\mathbf{W}z + \boldsymbol{\mu}, \alpha^2 \mathbf{I})$. Panel (c) shows samples conditional on the three selected latent values, not the marginal $p(\mathbf{x})$.

与 PCA 的联系：零噪声极限。此时自然要问：PPCA 与经典 PCA 有何关联？答案在零噪声极限下最为清晰。回顾 PPCA 模型：

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \alpha^2 \mathbf{I}).$$

当观测噪声趋于零 $\alpha^2 \rightarrow 0$ 时，条件分布

$$p(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \alpha^2 \mathbf{I})$$

越来越集中在它的均值附近。在极限情形下，随机性消失，每个潜在坐标 $\mathbf{z}$ 映射到单个确定性点：

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu}.$$

从这个意义上说，PCA 可以理解为 PPCA 的零噪声极限。潜子空间保留了下来，但围绕它的概率性散布消失了。因此，PPCA 把 PCA 作为特殊极限情形包含进来，同时添加了本质上全新的东西：重构周围的不确定性。

下一节中我们将看到，PPCA 仍然异常易于处理：因为模型是线性且高斯的，边际似然 $p(\mathbf{x})$ 仍可以解析地推导出来。

2.2 PPCA 为何解析可处理

在把 PPCA 表述为潜变量生成模型之后，下一个问题是如何用数据来拟合它。在 PCA 中，我们搜索方差最大的方向；在自编码器中，我们最小化重构误差。相比之下，PPCA 是概率模型，因此自然的拟合原则是最大化观测数据在模型下的似然。

2.2.1 从似然到边际化

假设我们观测到一个数据集

$$\{\mathbf{x}_1, \dots, \mathbf{x}_N\}.$$

数据集在 PPCA 下的对数似然是

$$\sum_{i=1}^N \log p(\mathbf{x}_i).$$

除以 N 并写成平均对数似然通常更为方便，

$$\frac{1}{N} \sum_{i=1}^N \log p(\mathbf{x}_i),$$

它也可以表示为在经验数据分布下的期望：

$$\mathbb{E}_{q(\mathbf{x})} [\log p(\mathbf{x})].$$

这里， $q(\mathbf{x})$ 就是把相等质量赋予每个观测数据点的经验分布。因此，在 $q(\mathbf{x})$ 下取期望不过是对训练样本求平均，这一记号在本书后面更一般的概率设定中会经常出现。

PPCA 的目标函数因此是

$$\max_{\mathbf{W}, \boldsymbol{\mu}, \alpha} \mathbb{E}_{q(\mathbf{x})} [\log p(\mathbf{x}; \mathbf{W}, \boldsymbol{\mu}, \alpha)].$$

这里边际似然依赖于模型参数 $(\mathbf{W}, \boldsymbol{\mu}, \alpha)$ 。不过，为了避免记号过于繁重，当含义清楚时，我们通常会省略这一依赖而直接写 $p(\mathbf{x})$ 。

这里的关键量是边际似然 $p(\mathbf{x})$ ，由全概率公式，它通过对潜变量积分得到：

$$p(\mathbf{x}) = \int p(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}.$$

为什么最大化对数似然？

我们最大化对数似然而非似然本身，是因为它在数值上更安全、代数上更简单。对于独立的数据点，

$$L = \prod_{i=1}^N p(\mathbf{x}_i), \quad \log L = \sum_{i=1}^N \log p(\mathbf{x}_i).$$

对数把许多小概率的乘积变成求和，避免了数值下溢，并给出更容易分析和优化的可加形式。

$$\frac{1}{N} \sum_{i=1}^N \log p(\mathbf{x}_i) = \mathbb{E}_{q(\mathbf{x})} [\log p(\mathbf{x})].$$

乍一看，这个边际似然似乎难以计算。将 PPCA 模型代入得

$$p(\mathbf{x}) = \int \mathcal{N}(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \alpha^2 \mathbf{I}) \mathcal{N}(\mathbf{z} | \mathbf{0}, \mathbf{I}) d\mathbf{z}.$$

由于 $\mathbf{z}$ 的取值范围是一个连续的潜空间，似乎精确求值这个积分应当是不可处理的。在大多数潜变量模型中，这种直觉是对的。PPCA 的特殊之处恰恰在于，其线性—高斯结构使这一边际化在解析上仍然可行。

为什么线性高斯模型在解析上易于处理

- 线性变换保持高斯性。若一个随机向量是高斯的，则其任意仿射变换也是高斯的。
- 独立高斯变量之和仍是高斯的。若两个高斯随机变量相互独立，则它们的和仍是高斯的。
- 积分掉高斯潜变量后仍是高斯的。若 $(\mathbf{x}, \mathbf{z})$ 上的联合分布是高斯的，则对 $\mathbf{z}$ 边际化后， $\mathbf{x}$ 的分布仍是高斯的。

这些事实使我们无需对积分进行暴力显式计算，就能确定 $\mathbf{x}$ 的分布。

2.2.2 推导并解释边际分布

回顾 PPCA 的生成方程：

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \alpha^2 \mathbf{I}),$$

其中假设潜变量 $\mathbf{z}$ 与噪声项 $\boldsymbol{\epsilon}$ 相互独立。这表明 $\mathbf{x}$ 由高斯潜变量的仿射变换加上一个独立的高斯噪声项构成。由于高斯变量的仿射变换仍是高斯的，且独立高斯变量之和仍是高斯的，可知 $\mathbf{x}$ 本身也必定是高斯的。

同一边际分布也可以通过展开联合密度

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x} | \mathbf{z})p(\mathbf{z})$$

然后利用所谓的配方法 (completing the square) 对 $\mathbf{z}$ 积分推导出来。这条代数路线在附录 A 中有回顾，其中同样的思想被用来说明高斯联合密度如何导出高斯的边际分布与后验分布。眼下，我们使用基于高斯变量仿射变换的更简单的分布论证。

我们现在可以直接计算其均值与协方差。

均值。 取期望得

$$\mathbb{E}[\mathbf{x}] = \mathbb{E}[\mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}] = \mathbf{W} \mathbb{E}[\mathbf{z}] + \boldsymbol{\mu} + \mathbb{E}[\boldsymbol{\epsilon}] = \boldsymbol{\mu},$$

因为 $\mathbb{E}[\mathbf{z}] = \mathbf{0}$ 且 $\mathbb{E}[\boldsymbol{\epsilon}] = \mathbf{0}$ 。

协方差。 利用

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon},$$

并注意到常数偏移 $\boldsymbol{\mu}$ 不影响协方差，我们有

$$\text{Cov}[\mathbf{x}] = \text{Cov}[\mathbf{W}\mathbf{z} + \boldsymbol{\epsilon}].$$

为了更明确地展开，回顾一般恒等式

$$\text{Cov}[a + b] = \text{Cov}[a] + \text{Cov}[b] + \text{Cov}[a, b] + \text{Cov}[b, a].$$

取 $a = \mathbf{Wz}$ 、 $b = \epsilon$ 应用上式得

$$\text{Cov}[\mathbf{x}] = \text{Cov}[\mathbf{Wz}] + \text{Cov}[\epsilon] + \text{Cov}[\mathbf{Wz}, \epsilon] + \text{Cov}[\epsilon, \mathbf{Wz}].$$

由于 $\mathbf{z}$ 与 ϵ 相互独立，交叉协方差项消失：

$$\text{Cov}[\mathbf{Wz}, \epsilon] = \mathbf{0}, \quad \text{Cov}[\epsilon, \mathbf{Wz}] = \mathbf{0}.$$

因此

$$\text{Cov}[\mathbf{x}] = \text{Cov}[\mathbf{Wz}] + \text{Cov}[\epsilon].$$

现在使用线性变换下协方差的标准规则：

$$\text{Cov}[\mathbf{Wz}] = \mathbf{W} \text{Cov}[\mathbf{z}] \mathbf{W}^\top.$$

于是，

$$\text{Cov}[\mathbf{x}] = \mathbf{W} \text{Cov}[\mathbf{z}] \mathbf{W}^\top + \text{Cov}[\epsilon].$$

最后，代入

$$\text{Cov}[\mathbf{z}] = \mathbf{I}, \quad \text{Cov}[\epsilon] = \alpha^2 \mathbf{I},$$

得

$$\text{Cov}[\mathbf{x}] = \mathbf{W} \mathbf{W}^\top + \alpha^2 \mathbf{I}.$$

综合以上，观测的边际分布是

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{W} \mathbf{W}^\top + \alpha^2 \mathbf{I}).$$

这是 PPCA 的关键解析结果：潜变量被精确地积分掉，所得的观测上的边际分布仍是高斯的。

解释协方差结构。 $\mathbf{W} \mathbf{W}^\top$ 项是被映射的潜在变差在观测空间中贡献的协方差，因为

$$\text{Cov}(\mathbf{Wz}) = \mathbf{W} \text{Cov}(\mathbf{z}) \mathbf{W}^\top = \mathbf{W} \mathbf{W}^\top.$$

它是低秩的，

$$\text{rank}(\mathbf{W} \mathbf{W}^\top) \leq k,$$

因此由潜变量引起的变异性被限制在 d 维观测空间中至多 k 维的子空间内。若

$$\mathbf{W} = [\mathbf{w}_1 \ \mathbf{w}_2 \ \cdots \ \mathbf{w}_k], \quad \mathbf{W} \mathbf{W}^\top = \sum_{j=1}^k \mathbf{w}_j \mathbf{w}_j^\top,$$

则结构化协方差可视为与各潜在方向相关联的秩一贡献之和。

相比之下， $\alpha^2 \mathbf{I}$ 在每个观测空间方向上贡献相同的方差。因此，PPCA 既通过 $\mathbf{W} \mathbf{W}^\top$ 建模沿潜子空间的变异性，又通过各向同性噪声建模其周围的变异性。图 2.2 以图示方式总结了这一分解，把潜变量引起的结构与各向同性观测噪声分离开来。




图 2.2: **Covariance decomposition in PPCA.** For the illustrated case $k = 1$ and $d = 2$, $\mathbf{W}\mathbf{W}^\top$ is rank one and contributes variance only along $\text{span}(\mathbf{W})$, while $\alpha^2 \mathbf{I}$ is isotropic and full rank. Their sum is the full-rank marginal covariance, combining variation along and around the latent subspace. Solid and dashed geometry show one- and two-standard-deviation extents.

下一节中，我们从 $p(\mathbf{x})$ 的形式转向学习的问题。既然边际似然已显式可得，我们就可以问：参数 $(\mathbf{W}, \boldsymbol{\mu}, \alpha)$ 如何由数据估计。

2.3 学习 PPCA：三种优化视角

推导出边际分布

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}, \mathbf{W}\mathbf{W}^\top + \alpha^2 \mathbf{I}),$$

之后，我们现在可以从表示转向学习。PPCA 的参数 $(\mathbf{W}, \boldsymbol{\mu}, \alpha)$ 通过最大化观测数据集的对数似然来拟合：

$$\max_{\mathbf{W}, \boldsymbol{\mu}, \alpha} \mathbb{E}_{q(\mathbf{x})} [\log p(\mathbf{x})].$$

此时自然产生一个问题：

既然似然已显式可得，我们应当如何优化它？

思考这个问题有三种有用的方式。第一种利用 PPCA 特殊的解析结构。第二种使用通用的基于梯度的优化。第三种，期望最大化 (EM)，尤为重要，因为它揭示了更深的潜变量原理，这些原理随后将引出变分推断 (variational inference) 与 VAE。

2.3.1 直接的解析极大似然

由于 $\mathbf{x}$ 的边际分布是高斯的，PPCA 提供了一条异常优雅的学习路径。原则上，可以显式写出对数似然，对参数求导，令所得导数为零，并求解驻点：

$$\nabla_{\mathbf{W}} \log p(\mathbf{x}) = 0, \quad \nabla_{\boldsymbol{\mu}} \log p(\mathbf{x}) = 0, \quad \frac{\partial}{\partial \alpha} \log p(\mathbf{x}) = 0.$$

这是经典的极大似然（maximum likelihood）策略。它的吸引力显而易见：如果这些方程可以精确求解，那么模型参数就能直接用数据的经验协方差结构表示出来。

对 PPCA 而言，这条路线之所以行得通，是因为模型从头到尾都保持线性与高斯。最终解可以写成闭式形式，并与样本协方差矩阵的特征结构密切相关。这也是 PPCA 之所以是重要教学模型的一个原因：它是一个真正的潜变量生成模型，却仍然容许精确的极大似然解。

与此同时，这条路线也暴露出一个局限。尽管优雅，直接的解析优化强烈依赖于模型足够简单、使得各导数能够被精确求解。一旦潜变量模型变成非线性或非高斯的，这条闭式路线通常会失效。此外，即使解析解存在，求出它可能仍需要诸如矩阵求逆或特征分解这类计算昂贵的操作，在高维情形尤甚。

2.3.2 基于梯度的优化

第二种可能，是把对数似然简单地当作一个目标函数，用梯度上升进行数值优化。在这种观点下，参数按如下方式迭代更新：

$$\theta \leftarrow \theta + \eta \nabla_{\theta} \mathbb{E}_{q(\mathbf{x})} [\log p(\mathbf{x}; \theta)],$$

其中 $\theta = \{\mathbf{W}, \boldsymbol{\mu}, \alpha\}$ ， η 是步长。

这是最一般的优化视角。与直接的解析极大似然不同，它不要求最优参数本身可用闭式求解。相反，它把 PPCA 当作任何其他可微概率模型一样，利用梯度迭代地攀爬似然曲面。

在 PPCA 中，边际似然 $p(\mathbf{x})$ 显式可得，因此其梯度也可以显式计算。与解析路线的区别因此不在于梯度回避了似然本身，而在于它回避了必须以闭式精确求解优化问题。更一般地，即使参数不存在精确的闭式解，只要目标函数或其梯度可以计算——或至少可以近似——基于梯度的方法仍然可用。

这一视角值得强调，因为它预示了大多数现代生成模型的训练方式。在后续章节中，当闭式解不再可用时，基于梯度的优化将成为默认的计算工具。

然而，就 PPCA 这一特定情形而言，梯度上升并非最具启发性的路线。它当然可以应用，但它并未利用模型特殊的潜变量结构。它也没有揭示，为什么潜变量模型常常通过后验推断而不仅仅是直接优化来处理。为此，我们需要第三种视角。

2.3.3 期望最大化（EM）

第三条路线是期望最大化（EM）算法 [7]。与直接的解析优化不同，EM 不试图一步求解似然。与通用的梯度上升不同，它不把潜变量仅仅当作黑箱目标函数里隐藏的干扰变量。相反，它与模型的潜变量结构协同工作。

基本思想很简单。虽然边际似然

$$\log p(\mathbf{x}) = \log \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z}$$

可能难以直接优化，但联合分布

$$p(\mathbf{x}, \mathbf{z})$$

往往形式简单得多。EM 利用这一点，在两个任务之间交替进行：

- 在当前参数下估计潜变量；
- 利用这些估计更新参数。

在 PPCA 中，EM 并非严格必需，因为模型已经可以解析求解。但它仍然极具价值。它揭示了潜变量模型的一般优化原理，而且这一原理在精确解不复存在时依然成立。

从更宽广的视角看，PPCA 之所以格外有价值，是因为它是少数几个所有核心概率量都能显式写出的潜变量模型之一：先验 $p(\mathbf{z})$ 、条件分布 $p(\mathbf{x} | \mathbf{z})$ 、边际似然 $p(\mathbf{x})$ ，以及后验 $p(\mathbf{z} | \mathbf{x})$ 。在更复杂的模型中，这些同样的量仍然核心，但它们不再保持解析可处理。特别地，学习由边际似然 $p(\mathbf{x})$ 驱动，而推断依赖后验 $p(\mathbf{z} | \mathbf{x})$ 。这正是 EM 如此重要的原因：它提供了一种结构化的方式，在潜变量问题的这两个方面之间交替进行。

对后续内容更重要的是，EM 自然引出两个更深刻的思想：引入一个关于潜变量的辅助分布，以及用一个可迭代优化的下界替换难以处理的对数似然。这些思想并非 PPCA 独有。它们属于潜变量建模的一般理论，并且当我们稍后研究变分推断时，会以更一般的形式重新出现。

出于这个原因，我们现在转向 EM 背后的数学基础：Jensen 不等式与证据下界 (ELBO)。

2.4 Jensen 不等式与证据下界

要理解 EM 为什么如此重要，我们现在需要退后一步，提出一个更一般的问题。当边际似然

$$p(\mathbf{x}; \theta) = \int p(\mathbf{x}, \mathbf{z}; \theta) d\mathbf{z}$$

不再解析可处理时，我们该怎么办？PPCA 的特殊之处在于这个积分仍可精确计算。大多数潜变量模型没有这种幸运。在更一般的设定中，潜变量可能经由非线性变换、非高斯条件分布或两者兼有地进入，边际似然便不再能写成闭式。

这正是 Jensen 不等式登场之处。它提供了一种系统性的方法，把难以处理的对数似然替换为可处理的下界。这个下界就是证据下界 (ELBO)，它是 EM 以及后续章节引入的更多生成模型的核心思想之一。

2.4.1 从边际似然到 Jensen 不等式

潜变量结构并非 PPCA 独有。更一般地，许多生成模型假设数据分两个阶段产生：

1. 从先验 $p(\mathbf{z})$ 采样一个潜变量 $\mathbf{z}$ ；
2. 从条件分布 $p(\mathbf{x} | \mathbf{z}; \theta)$ 生成一个观测 $\mathbf{x}$ 。

相应的边际似然是

$$p(\mathbf{x}; \theta) = \int p(\mathbf{x} | \mathbf{z}; \theta) p(\mathbf{z}) d\mathbf{z} = \int p(\mathbf{x}, \mathbf{z}; \theta) d\mathbf{z}.$$

对于数据集 $\{\mathbf{x}^{(i)}\}$, 极大似然学习变为

$$\max_{\theta} \sum_i \log p(\mathbf{x}^{(i)}; \theta) = \max_{\theta} \sum_i \log \int p(\mathbf{x}^{(i)}, \mathbf{z}; \theta) d\mathbf{z}.$$

困难在于这个表达式的形式: 潜变量必须被积分掉, 而对数位于积分之外。在 PPCA 中, 线性—高斯结构使我们得以绕开这一障碍。一般地, 我们需要一种更系统性的工具。

这个工具从 Jensen 不等式开始。回顾: 凸函数向上弯曲, 因此连接其图像上任意两点的直线位于图像上方。凹函数向下弯曲, 因此连接任意两点的直线位于图像下方。对随机变量 X 与凸函数 f , Jensen 不等式指出

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)].$$

若 f 是凹的, 不等号方向反转:

$$f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)].$$

在当前语境下, 我们关心的函数 f 具体来说就是对数。由于 $\log$ 是凹的,

$$\log \mathbb{E}[X] \geq \mathbb{E}[\log X].$$

这正是我们需要的形式。在潜变量模型中, 成问题的量通常是

$$\log \int (\dots) d\mathbf{z},$$

或等价地 $\log \mathbb{E}[\cdot]$, 其中对数位于一个积分或期望之外。Jensen 不等式允许我们把这个对数移到期望内部, 用精确性换取一个更容易处理的下界。

2.4.2 推导证据下界

要应用 Jensen 不等式, 我们首先把边际似然改写为一个期望。设 $Q(\mathbf{z})$ 是潜变量上的任意概率分布, 满足

$$\int Q(\mathbf{z}) d\mathbf{z} = 1.$$

于是

$$p(\mathbf{x}; \theta) = \int p(\mathbf{x}, \mathbf{z}; \theta) d\mathbf{z} = \int Q(\mathbf{z}) \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} d\mathbf{z} = \mathbb{E}_{\mathbf{z} \sim Q} \left[\frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

取对数得

$$\log p(\mathbf{x}; \theta) = \log \mathbb{E}_{\mathbf{z} \sim Q} \left[\frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

乍看之下这像是一个纯粹的代数技巧, 但它是关键一步。分布 $Q(\mathbf{z})$ 是一个自由选取的辅助分布, 其引入是为了让边际似然能够表示为一个期望。一旦做到这一点, Jensen 不等式便可用。

现在我们可以对改写后的边际似然应用 Jensen 不等式:

$$\log p(\mathbf{x}; \theta) = \log \mathbb{E}_{\mathbf{z} \sim Q} \left[\frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

由于对数是凹的，Jensen 不等式给出

$$\log \mathbb{E}_{\mathbf{z} \sim Q} \left[\frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right] \geq \mathbb{E}_{\mathbf{z} \sim Q} \left[\log \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

因此，

$$\log p(\mathbf{x}; \theta) \geq \mathbb{E}_{\mathbf{z} \sim Q} \left[\log \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

这个下界称为证据下界 (ELBO):

$$\mathcal{L}(Q, \theta; \mathbf{x}) = \mathbb{E}_{\mathbf{z} \sim Q} \left[\log \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} \right].$$

展开分数的对数可得等价形式

$$\mathcal{L}(Q, \theta; \mathbf{x}) = \mathbb{E}_Q [\log p(\mathbf{x}, \mathbf{z}; \theta)] - \mathbb{E}_Q [\log Q(\mathbf{z})].$$

这个表达式更容易处理，因为对数现在直接作用于期望内部的联合密度，而不是位于一个难以处理的积分之外。因此，它对迭代优化友好得多。

这是本节的核心结果。我们不必直接最大化一般难以处理的量 $\log p(\mathbf{x}; \theta)$ ，而是可以最大化一个可处理的下界，它依赖于两个对象：模型参数 θ 与辅助分布 $Q(\mathbf{z})$ 。

2.4.3 下界何时取等?

下界只有在我们理解它何时紧致时才有用。对 Jensen 不等式而言，当凹函数——在我们的情形中是对数——的参数关于求平均的变量为常数时，等号成立。这里求平均的变量是 $\mathbf{z}$ ，因此等号恰在如下条件满足时取到：

$$\frac{p(\mathbf{x}, \mathbf{z}; \theta)}{Q(\mathbf{z})} = c \quad \text{for all } \mathbf{z},$$

其中 c 是某个与 $\mathbf{z}$ 无关的常数。

移项得 $Q(\mathbf{z}) \propto p(\mathbf{x}, \mathbf{z}; \theta)$ 。为确定归一化常数，对两边关于 $\mathbf{z}$ 积分。由于 $Q(\mathbf{z})$ 是合法的概率分布， $\int Q(\mathbf{z}) d\mathbf{z} = 1$ 。

因此，

$$p(\mathbf{x}; \theta) = \int p(\mathbf{x}, \mathbf{z}; \theta) d\mathbf{z} = c \int Q(\mathbf{z}) d\mathbf{z} = c.$$

所以常数必须是

$$c = p(\mathbf{x}; \theta).$$

把它代回等号条件得

$$Q(\mathbf{z}) = \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{p(\mathbf{x}; \theta)} = p(\mathbf{z} | \mathbf{x}; \theta),$$

这恰好是潜变量的真实后验分布。

因此，恰好在 $Q(\mathbf{z}) = p(\mathbf{z} | \mathbf{x}; \theta)$ ，即当辅助分布与潜变量上的真实后验相匹配时，ELBO 恰好等于真实的对数似然。这是一个关键要点：ELBO 并非一个随意的代理目标。它的紧致程度由 $Q(\mathbf{z})$ 对真实后验的逼近程度控制。

这一视角也澄清了 PPCA 在本章中的角色。PPCA 的特殊之处不在于它回避了潜变量问题，而在于它精确地解决了这个问题。它的后验 $p(\mathbf{z} | \mathbf{x})$ 是可处理的，其边际似然 $p(\mathbf{x})$ 也可以解析计算。因此，PPCA 并不严格需要 ELBO。

然而，ELBO 框架揭示了 PPCA 所例示的更一般原理。同样的潜变量结构在更复杂的模型中依然存在，但精确后验与精确边际似然不再可得。ELBO 正是让我们在精确高斯计算失效时仍能继续前进的装置。

现在我们可以引入期望最大化算法了。ELBO 依赖于两个相互耦合的成分：辅助分布 $Q(\mathbf{z})$ 与模型参数 θ 。这自然启发一种交替策略：先改进 $Q(\mathbf{z})$ 使下界尽可能紧，再改进 θ 使下界本身变大。

这种交替逻辑正是 EM 所形式化的内容。下一节中，我们将展示 EM 如何作为一个迭代最大化 ELBO 的过程而出现，以及在 PPCA 这一特殊情形下，它如何重现我们此前通过精确高斯计算得到的同一个解。

2.5 期望最大化：最大化下界

潜变量模型中的根本困难是边际对数似然

$$\log p(\mathbf{x}; \theta) = \log \int p(\mathbf{x}, \mathbf{z}; \theta) d\mathbf{z},$$

其中对数位于对隐藏变量 $\mathbf{z}$ 的边际化之外。这使得直接优化变得困难，即使联合分布 $p(\mathbf{x}, \mathbf{z}; \theta)$ 本身形式相对简单。

ELBO 通过引入下界解决这一问题：

$$\mathcal{L}(Q, \theta; \mathbf{x}) = \mathbb{E}_Q[\log p(\mathbf{x}, \mathbf{z}; \theta)] - \mathbb{E}_Q[\log Q(\mathbf{z})],$$

该下界依赖于两个相互耦合的对象：辅助分布 $Q(\mathbf{z})$ 与模型参数 θ 。这自然启发一种交替优化策略：

如果我们固定其中之一，能否改进另一个？

这一交替思想正是 EM 所形式化的内容。从高层次看，其合理性在于：一旦两个量之一被固定，ELBO 就成为仅关于另一个的优化问题。EM 利用这种可分离的结构，在改进潜在分布与改进模型参数之间交替进行。

2.5.1 EM 的两个步骤

EM 的每次迭代由两个阶段组成。

E 步（期望步）。 固定当前参数 $\theta^{(t)}$ ，选取使 ELBO 尽可能紧的分布 $Q(\mathbf{z})$ 。由上一节可知，下界最紧当

$$Q(\mathbf{z}) = p(\mathbf{z} | \mathbf{x}; \theta^{(t)}).$$

因此 E 步取

$$Q^{(t)}(\mathbf{z}) = p(\mathbf{z} | \mathbf{x}; \theta^{(t)}).$$

用文字说，E 步在当前参数值下计算潜变量上的后验分布。

这也澄清了一个重要要点。在标准 EM 中，E 步假设后验 $p(\mathbf{z} | \mathbf{x}; \theta^{(t)})$ 足够可处理、能够被精确计算。PPCA 即是如此，这也是 EM 能够直接应用于 PPCA 的原因。然而更一般地，后验往往没有闭式形式。在那些设定中，我们不能把 Q 设为精确后验，而必须用近似来替代。这正是从 EM 走向变分推断的那一步。

值得注意的是，后验可处理并不自动意味着整个优化问题可以闭式求解。对 EM 而言，关键要求是后验 $p(\mathbf{z} | \mathbf{x}; \theta)$ 、或至少在其下所需的期望，能够在当前参数值下计算。这就足以完成 E 步。不过，由此得到的参数更新仍可能需要通过 M 步迭代地获得，而非由单次直接的解析解给出。

PPCA 的特殊之处在于，包括边际似然与后验在内的多个核心量都解析可处理，而且模型还容许闭式的极大似然解。在许多其他模型中，即使后验对 EM 而言足够可处理，完整的参数优化问题仍可能需要迭代过程。

M 步（最大化步）。 固定 $Q^{(t)}$ ，通过关于 θ 最大化 ELBO 来更新模型参数：

$$\theta^{(t+1)} = \arg \max_{\theta} \mathcal{L}(Q^{(t)}, \theta; \mathbf{x}).$$

由于熵项

$$-\mathbb{E}_{Q^{(t)}}[\log Q^{(t)}(\mathbf{z})]$$

不依赖于 θ ，这等价于最大化

$$\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{Q^{(t)}}[\log p(\mathbf{x}, \mathbf{z}; \theta)].$$

这个量常被称为期望完整数据对数似然。

合在一起，两步给出 EM 的更新模式：

E-step: $Q^{(t)}(\mathbf{z}) = p(\mathbf{z} \mathbf{x}; \theta^{(t)}),$ M-step: $\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{Q^{(t)}}[\log p(\mathbf{x}, \mathbf{z}; \theta)].$

为什么 EM 不会降低似然。EM 的单调性直接来自两个优化步骤以及 ELBO 的下界性质。首先，E 步之后，下界在当前参数处取等：

$$\mathcal{L}(Q^{(t)}, \theta^{(t)}; \mathbf{x}) = \log p(\mathbf{x}; \theta^{(t)}).$$

其次，固定 $Q^{(t)}$ ，M 步选取不会降低该下界的参数：

$$\mathcal{L}(Q^{(t)}, \theta^{(t+1)}; \mathbf{x}) \geq \mathcal{L}(Q^{(t)}, \theta^{(t)}; \mathbf{x}).$$

最后，由于 ELBO 是对数似然的下界，

$$\log p(\mathbf{x}; \theta^{(t+1)}) \geq \mathcal{L}(Q^{(t)}, \theta^{(t+1)}; \mathbf{x}).$$

把这些关系结合起来便表明，一次完整的 EM 迭代不会降低观测数据对数似然。图 2.3 以几何方式展示了同一论证：下界的交替收紧与抬高。




图 2.3: **EM as alternating optimisation of the ELBO**. In the E-step, Q is set to the exact posterior, making the ELBO tight at the current parameters. Holding this bound fixed, the M-step updates the parameters to raise it. The inequality below shows why one full iteration cannot decrease the observed-data log-likelihood. The curves are schematic.

2.5.2 将 EM 应用于 PPCA

在 PPCA 中，潜变量后验是可处理的，因此 EM 可以显式地执行。这使 PPCA 成为格外有用的例子：它展示了一般的基于 ELBO 的算法在一个简单的线性—高斯模型中如何退化为闭式更新。

对 PPCA 而言，潜变量的后验分布是高斯的。这来自与推导边际分布相同的线性—高斯结构，配方推导见附录 A。该后验为

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}), \alpha^2 \mathbf{M}^{-1}), \quad \mathbf{M} = \mathbf{W}^\top \mathbf{W} + \alpha^2 \mathbf{I}.$$

图 2.4 把目前 PPCA 中出现的四个概率对象汇总在一起：先验 $p(\mathbf{z})$ 、条件分布 $p(\mathbf{x} | \mathbf{z})$ 、边际分布 $p(\mathbf{x})$ ，以及后验 $p(\mathbf{z} | \mathbf{x})$ 。




图 2.4: **Four probabilistic views of the same PPCA model.** The prior $p(z)$ describes latent coordinates; fixing z^* gives $p(\mathbf{x} | z^*)$; integrating over z gives the marginal $p(\mathbf{x})$; and observing $\mathbf{x}^*$ gives the posterior $p(z | \mathbf{x}^*)$. The true generating z^* is shown in the posterior panel; observation noise means it need not equal the posterior mean. In PPCA, all four distributions are Gaussian and available analytically.

从这个后验出发，E 步提供期望

$$\mathbb{E}[\mathbf{z}] = \mathbf{M}^{-1} \mathbf{W}^T (\mathbf{x} - \boldsymbol{\mu}),$$

以及

$$\mathbb{E}[\mathbf{z}\mathbf{z}^T] = \alpha^2 \mathbf{M}^{-1} + \mathbb{E}[\mathbf{z}] \mathbb{E}[\mathbf{z}]^T.$$

随后 M 步把这些期望代入期望完整数据对数似然，并关于参数 $(\mathbf{W}, \boldsymbol{\mu}, \alpha)$ 最大化。这导出 PPCA 参数的闭式更新方程。

这里的要点不仅在于 PPCA 可以用 EM 拟合，更在于精确的 PPCA 解可以重新解释为一个 EM 过程的不动点。换言之，EM 给出的不是不同的模型，而是学习同一模型的不同视角。

更宽泛地说，EM 教会我们：潜变量模型中的学习可以理解为如下两者的交替：

- **推断** (inference)，即在给定数据下估计隐藏变量；
- **学习** (learning)，即利用推断出的潜变量更新模型参数。

2.5.3 从 PPCA 到正则化的潜在表示

尽管 PPCA 引入了潜变量上的先验, $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$, 并定义了一个合法的生成模型, 它尚未提供那种灵活且正则化的推断框架——这种框架将在 VAE 等现代潜变量模型中成为核心。

对于任意单个观测 $\mathbf{x}$, 后验 $p(\mathbf{z} | \mathbf{x})$ 描述了在该模型下, 哪些潜在坐标是对该数据点的合理解释。若在经验数据分布下对这些后验取平均, 我们得到聚合后验: $\mathbb{E}_{q(\mathbf{x})}[p(\mathbf{z} | \mathbf{x})]$. 这一分布描述了整个数据集在潜空间中是如何被表示的。

在 PPCA 中, 这一后验可以精确计算, 因为模型是线性且高斯的。这是 PPCA 的一个优点, 但它也揭示其局限的根源: 干净的数学依赖强假设。潜到观测的映射是线性的, 观测噪声是高斯的, 后验推断可以解析地完成。

当我们走出线性—高斯世界, 这一区分变得重要。现代生成模型希望在保留同样潜变量思想的同时, 让潜变量到观测的映射灵活得多。一旦引入这种灵活性, 使 PPCA 如此透明的简单闭式计算通常便不再可得。因此, 我们需要一个新框架, 它能够学习有表达力的生成映射、从数据推断潜在表示, 并以一种支持生成的方式保持潜空间的组织性。

这正是变分自编码器所扮演的角色。VAE 可以看作 PPCA 故事的非线性与变分扩展: 它保留了潜变量生成观测的思想, 但用一个可学习的推断—生成框架替代精确的高斯计算。这一框架的细节, 包括变分后验的精确角色与潜空间正则化项, 将在下一章展开。

因此, 从 PPCA 到 VAE 的过渡, 并不是从非生成模型到生成模型的转变。PPCA 已经是生成的。这一过渡实际上是从一个解析可处理的线性—高斯潜变量模型, 走向一个更灵活的非线性潜变量模型——在其中, 推断与生成必须被共同学习。

下一章中, 变分自编码器将在单一的变分目标内结合重构、概率推断与潜空间正则化, 把这一思想完整展开。

总结与参考文献

本章引入了概率 PCA (PPCA), 作为书中第一个概率潜变量模型。它通过引入潜在先验、概率解码器、用于学习的边际似然以及用于推断的后验分布, 扩展了 PCA 的确定性图景。

由于 PPCA 是线性且高斯的, 其所有核心量都保持解析可处理。这使我们能够显式推导边际似然, 把其协方差解释为结构化低秩分量与各向同性噪声之和, 并把 PPCA 视为一个罕见的、先验、似然、边际与后验均能写成闭式的模型。

随后我们考虑了学习模型的三种视角: 直接的解析极大似然、基于梯度的优化与 EM。其中 EM 尤为重要, 因为它揭示了潜变量学习的更深结构: 隐藏变量上的推断与模型参数的优化之间的交替。这又引出了 Jensen 不等式与 ELBO, 它们把 PPCA 的故事推广到精确边际化不再可能的模型。

最后, 我们指出了 PPCA 的一个重要局限: 尽管它引入了潜变量上的先验, 它并未显式地对聚合推断出的潜空间进行正则化以与该先验对齐。这直接指向下一章: 变分自编码器 (VAE) 将在统一的变分目标内结合重构、概率推断与潜空间正则化。

本章内容基于概率 PCA、潜变量模型与极大似然推断的经典工作。PPCA 的原始表述由 Tipping 与 Bishop [42] 提出, 而 EM 算法由 Dempster、Laird 与 Rubin [7] 经典地引入。对希望获得这些思想的现代且更具教学性处理的读者——特别是高斯潜变量模型、EM 及其概率解释——有用的参考文献包括 Bishop [4] 与 Murphy [27]。

第 3 章 3

变分自编码器：从概率潜变量到变分推断

概述

变分自编码器 (Variational Autoencoder, VAE) 是现代深度生成学习的奠基模型之一。它在本书中占据重要地位，因为它汇聚了前面各章发展的两条主线：基于重构进行表示学习的自编码器 (autoencoder)，以及作为潜变量生成模型的概率 PCA (probabilistic PCA, PPCA)。

在确定性自编码器中，每个输入被映射为单个潜编码，随后被重构。而在 PPCA 中，潜变量以概率方式处理，但模型仍是线性且高斯的。VAE 在一个更灵活的非线性设定中结合了这些思想：编码器产生潜变量上的一个分布，解码器定义观测上的一个条件分布，学习过程则通过优化一个变分下界而非精确的边缘似然来进行。

这使 VAE 成为从经典潜变量模型通往现代深度生成建模的天然桥梁。它保留了 PPCA 的概率结构——先验、似然、后验与边缘似然——但用学习得到的近似后验取代了精确的高斯推断。上一章引入的证据下界 (Evidence Lower Bound, ELBO)，如今成为一个实用的训练目标，在重构精度与潜空间正则化之间加以权衡。

尽管 VAE 已不再是最新的主导生成范式，它在概念上依然处于核心地位。它展示了概率推断、神经网络、潜表示与基于梯度的优化如何结合在单个端到端生成模型之中。因此，本章构成了从解析可解的潜变量模型迈向本书后续更广阔的深度生成框架的第一个重要台阶。


概念图

本章追溯从确定性自编码器到变分潜变量生成模型的演进过程。

- 我们首先把确定性自编码器转变为概率模型。编码器不再将每个观测映射为单个潜编码，而是产生一个分布 $q_\phi(\mathbf{z} | \mathbf{x})$ ，同时解码器定义条件分布 $p_\theta(\mathbf{x} | \mathbf{z})$ 。这既赋予模型不确定性，也赋予其真正的生成能力。
- 接着，我们从潜变量模型本身出发推导学习目标。从不可解析求解的边缘似然 $p_\theta(\mathbf{x})$ 出发，我们运用上一章建立的 ELBO 框架并将其特化到 VAE 场景。由此揭示出人们熟悉的分解形式——一个重构项与一个正则化项——展示了精确的数据拟合如何与潜空间结构相互平衡。

→ 最后，我们说明 VAE 如何训练，以及由此达成了什么。变分后验 $q_\phi(\mathbf{z} | \mathbf{x})$ 扮演着真实后验的学习近似这一角色，而重参数化技巧 (reparameterisation trick) 使这一随机推断过程变得可微，从而能够用基于梯度的优化加以训练。

VAE 的主要概率关系在下面以图示方式总结。



3.1 从自编码器到变分自编码器

在前面几章中，两条思想并行发展。一方面，自编码器展示了如何把数据压缩为低维的潜表示，即一种紧凑的内部描述或特征编码，输入可以由它重构出来。另一方面，概率 PCA (PPCA) 展示了潜变量模型如何把这种表示转变为一个真正概率化的生成过程。变分自编码器 (VAE) [21, 35] 将这两条线索汇聚在一起。

标准自编码器具有人们熟悉的确定性形式

$$\mathbf{x} \xrightarrow{\text{encoder}} \mathbf{z} \xrightarrow{\text{decoder}} \hat{\mathbf{x}}.$$

给定输入 $\mathbf{x}$ ，编码器产生单个潜编码 $\mathbf{z}$ ，解码器再将该编码映射回单个重构 $\hat{\mathbf{x}}$ 。这种结构对压缩和表示学习很有用，但它有一个重要局限：潜编码是一个固定点，而非概率对象。其结果是，模型无法自然地表达不确定性，也未能提供一个有原则的潜变量生成框架。

VAE 通过用潜变量上的一个分布取代确定性潜编码来解决这一问题。这与早前从 PCA 到 PPCA 的转变如出一辙：在那里，同样是把确定性的低维描述通过引入不确定性转变为概率潜变量模型。VAE 不再把 $\mathbf{x}$ 编码为潜空间中的一个精确点，而是将其编码为一个概率分布，以表达“哪个潜表示最能解释该观测”上的不确定性。这正是关键的概念转变：

潜表示不再是一个单一的编码，而是一个可以从中采样出编码的分布。

3.1.1 将编码器概率化

在确定性自编码器中，编码器是一个函数

$$f_{\text{enc}} : \mathbf{x} \mapsto \mathbf{z}.$$

对每个观测 $\mathbf{x}$ ，它恰好返回一个潜向量 $\mathbf{z}$ 。

在 VAE 中，编码器转而定义一个易于处理的潜变量条件分布，

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}),$$

它充当真实后验的学习近似。这一分布通常称为变分后验 (variational posterior) 或近似后验 (approximate posterior)。它的作用是刻画：在给定观测数据点 $\mathbf{x}$ 的条件下，哪些潜变量是合理的。

使用后验一词是有意为之。在之前的 PPCA 一章中，我们看到潜变量模型中的真实后验是

$$p_{\theta}(\mathbf{z} \mid \mathbf{x}),$$

即观测到 $\mathbf{x}$ 之后潜变量上的分布。在 VAE 中，这一真实后验通常是不可解析求解的。主要原因在于，编码器与解码器通常由带有多个非线性层的神经网络建模，后验因此不再保有使 PPCA 可解析求解的简单线性—高斯形式。于是我们转而引入易于处理的近似 $q_{\phi}(\mathbf{z} \mid \mathbf{x})$ 。就目前而言，关键的结构变化仅仅在于：编码器不再输出单个向量，而是输出一个分布的参数。

在实践中，编码器通常由一个神经网络实现，把 $\mathbf{x}$ 映射为某个高斯分布的参数。最常见的是，我们假设

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z} \mid \boldsymbol{\mu}_{\phi}(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_{\phi}^2(\mathbf{x}))),$$

或采用简化的各向同性形式，

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z} \mid \boldsymbol{\mu}_{\phi}(\mathbf{x}), \boldsymbol{\sigma}_{\phi}^2(\mathbf{x})\mathbf{I}).$$

因此，编码器网络并不直接产生 $\mathbf{z}$ ，而是产生指定潜空间中一个高斯分布的均值与方差参数。

在概念上，编码器现在具有如下形式

$$\mathbf{x} \longrightarrow (\boldsymbol{\mu}_{\phi}(\mathbf{x}), \boldsymbol{\sigma}_{\phi}(\mathbf{x})) \longrightarrow q_{\phi}(\mathbf{z} \mid \mathbf{x}).$$

随后，通过采样

$$\mathbf{z} \sim q_{\phi}(\mathbf{z} \mid \mathbf{x}).$$

得到一个潜编码。

于是，对固定的输入 $\mathbf{x}$ ，与确定性自编码器的对比十分直接：自编码器返回一个潜空间中的点，而 VAE 编码器定义一个由合理的潜值构成的分布，可以从中采样出不同的编码。图 3.1 从几何上展示了这一“点对分布”的转变。




图 3.1: **From a deterministic latent code to a variational posterior.** For a fixed input $\mathbf{x}$, a standard autoencoder produces one latent point, whereas a VAE encoder specifies a distribution $q_\phi(\mathbf{z} | \mathbf{x})$ of plausible latent values. Here the common diagonal-Gaussian choice is shown through samples, its mean, and elliptical contours. The shared centre is chosen only to make the point-versus-distribution contrast visually direct.

为何选择易于处理的高斯近似后验?

VAE 中的真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ 通常过于复杂而无法精确计算，因此我们用一个更简单、可以在实践中表示并学习的分布族 $q_\phi(\mathbf{z} | \mathbf{x})$ 来取代它。选择高斯尤为方便，主要原因有二。

- 它易于表示。神经网络只需输出一个均值和一个方差，便给出了一种紧凑且可微的描述潜分布的方式。
- 它在计算上易于处理。我们可以方便地从中采样，而且学习目标中后续会出现的许多数学量，在使用高斯分布时会变得容易求值得多。

这里所说的“易于处理”(tractable)，是指近似后验被选得足够简单，以便在学习过程中加以驾驭。这并不意味着整个 VAE 重新变得可解析求解。与 PPCA 不同，解码器仍然是非线性的，精确的数据似然依旧不可解析求解，我们仍然需要代理目标与基于梯度的优化来训练模型。

3.1.2 将解码器概率化

解码一侧也发生了类似的转变。在确定性自编码器中，解码器是一个函数

$$f_{\text{dec}} : \mathbf{z} \mapsto \hat{\mathbf{x}},$$

它对每个潜输入产生单个重构 $\hat{\mathbf{x}}$ 。

在 VAE 中，解码器转而定义一个条件分布

$$p_\theta(\mathbf{x} | \mathbf{z}),$$

它刻画观测如何由潜变量生成。这是模型的生成部分。

同样，解码器通常由神经网络参数化。给定 $\mathbf{z}$ ，解码器输出数据空间中某个分布的参数。对连续数据，常见的选择是形如

$$p_{\theta}(\mathbf{x} | \mathbf{z}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_{\theta}(\mathbf{z}), \sigma^2 \mathbf{I}),$$

的高斯分布；而对二值数据，则常用伯努利似然。具体选择取决于所建模的数据类型，但其基本原则始终相同：

解码器并不输出单个确定性重构，而是输出给定潜变量下可能观测上的一个分布。

在实践中，人们常取该分布的均值或众数作为模型的代表性重构，但在概念上，解码器定义的是一条完整的条件概率规律，而非单点预测。因此，编码器把数据映射为潜空间中的分布，而解码器把潜变量映射为数据空间中的分布。

3.1.3 先验与学习的困难

潜变量先验。为补全这个概率潜变量模型，我们还需引入潜变量上的一个先验分布：

$$p(\mathbf{z}).$$

与 PPCA 中一样，标准 VAE 通常从一个简单的标准高斯先验出发，

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

该先验扮演两个角色。

第一，它提供了生成的起点：训练完成后，我们可以采样

$$\mathbf{z} \sim p(\mathbf{z}),$$

再从解码器分布中采样以生成一个观测

$$\mathbf{x} \sim p_{\theta}(\mathbf{x} | \mathbf{z}).$$

第二，它提供了日后对推断出的潜分布进行正则化时所参照的分布。这是超越 PPCA 的重要一步：在 PPCA 中，先验虽然存在，但模型并未显式鼓励推断出的潜表示与先验对齐。而在 VAE 中，这种对齐将成为学习目标本身的一部分。

如此一来，先验赋予潜空间一个全局结构，而解码器把该空间中的点转变为数据。

这为何带来新的困难。把这些部件组合起来，VAE 由三个概率成分构成：

$$p(\mathbf{z}), \quad q_{\phi}(\mathbf{z} | \mathbf{x}), \quad p_{\theta}(\mathbf{x} | \mathbf{z}),$$

即潜变量上的先验、用于推断的近似后验，以及用于生成的解码器似然。

这赋予 VAE 一个既像自编码器又像 PPCA、却比两者都更丰富的结构。像自编码器一样，它具有编码器—解码器架构；像 PPCA 一样，它是一个概率潜变量模型。但与 PPCA 不同，编码器与解码器如今通常是非线性神经网络，这极大地增强了建模能力，同时也摧毁了我们此前赖以使用的解析可解性。

在 PPCA 中，线性—高斯结构使边缘似然 $p(\mathbf{x})$ 与后验 $p(\mathbf{z} | \mathbf{x})$ 等量能够被显式推导出来。在 VAE 中，这些量通常不再有闭式表达。因此，尽管 VAE 具有清晰的概率结构，其学习问题不再像 PPCA 那样可解析求解。这就把我们直接引向本章的核心问题：

如果真实的边缘似然与后验都不可解析求解，我们应当转而优化什么目标？

答案正是上一章引入的同一一般原则：证据下界（ELBO）。在下一节中，我们将把这一原则特化到 VAE，并推导出使模型可训练的目标。

3.2 从不可解析求解的似然到 ELBO

确立了 VAE 的概率结构之后，我们现在可以问：模型应当如何学习。与 PPCA 中一样，自然的原则是极大似然（maximum likelihood）：我们希望选择参数，使模型为观测数据赋予高概率。

对单个观测 $\mathbf{x}$ 而言，相关的量是边缘似然

$$p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \int p_{\theta}(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z},$$

而在数据集 $\{\mathbf{x}^{(i)}\}$ 上，学习目标变为

$$\max_{\theta} \sum_i \log p_{\theta}(\mathbf{x}^{(i)}).$$

这与上一章 PPCA 的目标在形式上相同，但如今存在一个关键差异。在 PPCA 中，线性—高斯结构使得对 $\mathbf{z}$ 的积分可以被精确计算。在 VAE 中，解码器 $p_{\theta}(\mathbf{x} | \mathbf{z})$ 通常由非线性神经网络参数化，这破坏了先前允许精确边缘化的简单线性—高斯形式。其结果是，对数边缘似然

$$\log p_{\theta}(\mathbf{x}) = \log \int p_{\theta}(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}$$

通常是不可解析求解的。

同样的困难立刻出现在后验中：

$$p_{\theta}(\mathbf{z} | \mathbf{x}) = \frac{p_{\theta}(\mathbf{x} | \mathbf{z}) p(\mathbf{z})}{p_{\theta}(\mathbf{x})}.$$

分子可以写出来，但要对其归一化，需要同一个不可解析求解的边缘似然 $p_{\theta}(\mathbf{x})$ 。因此在 VAE 中，边缘似然与真实后验通常都没有闭式表达。

这正是上一章的变分机制变得不可或缺的关键节点。我们不直接优化不可解析求解的对数似然，而是优化一个易于处理的下界：证据下界（ELBO）。

3.2.1 引入变分后验

在第 2 章中，ELBO 是通过在潜变量上引入一个辅助分布 $Q(\mathbf{z})$ 推导出来的。在 VAE 中，该辅助分布现在成为真实后验的一个学习得到、参数化的近似：

$$Q(\mathbf{z}) \longrightarrow q_{\phi}(\mathbf{z} | \mathbf{x}),$$

其中 $q_{\phi}(\mathbf{z} | \mathbf{x})$ 正是上一节引入的编码器网络。

这一替换是把一般 ELBO 框架转变为 VAE 目标的关键步骤。我们不再试图计算不可解析求解的真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ ，而是使用易于处理的近似 $q_\phi(\mathbf{z} | \mathbf{x})$ ，并优化 $\log p_\theta(\mathbf{x})$ 的一个下界。

应用 ELBO 的构造，得到

$$\log p_\theta(\mathbf{x}) \geq \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} \right].$$

于是，单个数据点的 VAE 目标为

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} \right].$$

这就是特化到 VAE 场景的 ELBO。它同时依赖于两组参数：

- θ ，解码器网络 $p_\theta(\mathbf{x} | \mathbf{z})$ 的参数；
- ϕ ，编码器网络 $q_\phi(\mathbf{z} | \mathbf{x})$ 的参数。

训练 VAE，意味着同时关于模型的这两个部分最大化该下界。

我们现在将同一目标改写为三种等价形式。每种形式突出学习问题的一个不同侧面：潜变量结构、与精确似然之间的差距，以及重构与正则化之间的实际权衡。

3.2.2 ELBO 的三种等价形式

ELBO 的第一种形式：联合密度形式。 ELBO 最紧凑的形式是

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} \right].$$

展开对数，可以使其结构更加清晰：

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}, \mathbf{z})] - \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log q_\phi(\mathbf{z} | \mathbf{x})].$$

这一形式在概念上很有用，因为它展示的潜变量结构与上一章一般 ELBO 推导中的完全一致。第一项要求采样得到的潜变量与联合模型 $p_\theta(\mathbf{x}, \mathbf{z})$ 相容，而第二项则来自变分分布本身。

它也清楚地表明 VAE 正在做什么。模型希望借助潜变量 $\mathbf{z}$ 来解释观测 $\mathbf{x}$ ，但由于精确后验不可得，它转而优化一个依赖近似后验 $q_\phi(\mathbf{z} | \mathbf{x})$ 的下界。

ELBO 的第二种形式：精确似然减去后验失配。 利用贝叶斯公式，

$$p_\theta(\mathbf{x}, \mathbf{z}) = p_\theta(\mathbf{z} | \mathbf{x}) p_\theta(\mathbf{x}),$$

我们可以把 ELBO 改写为

$$\begin{aligned} \mathcal{L}(\mathbf{x}; \theta, \phi) &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_\theta(\mathbf{z} | \mathbf{x}) p_\theta(\mathbf{x})}{q_\phi(\mathbf{z} | \mathbf{x})} \right] \\ &= \log p_\theta(\mathbf{x}) - \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{q_\phi(\mathbf{z} | \mathbf{x})}{p_\theta(\mathbf{z} | \mathbf{x})} \right]. \end{aligned}$$

KL 散度

对两个概率分布 q 与 p , 从 q 到 p 的 *Kullback-Leibler* (KL) 散度定义为

$$\text{KL}(q \parallel p) = \mathbb{E}_q \left[\log \frac{q}{p} \right].$$

它度量在以 q 为基准取期望时, q 与 p 之间的差异程度。这里有两个基本事实尤为重要:

- $\text{KL}(q \parallel p) \geq 0$;
- $\text{KL}(q \parallel p) = 0$ 当且仅当 $q = p$ 几乎处处成立。

因此, KL 散度的作用如同两个分布之间失配程度的一个非负度量。它并不是几何意义上的真正距离, 因为它不对称, 但它在概率建模中极为有用。

识别出第二项是一个 KL 散度, 便得到

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \log p_{\theta}(\mathbf{x}) - \text{KL}(q_{\phi}(\mathbf{z} \mid \mathbf{x}) \parallel p_{\theta}(\mathbf{z} \mid \mathbf{x})).$$

这一形式表明, ELBO 与真实对数似然之间的差异, 仅仅是近似后验与真实后验之间的散度。由于 KL 散度总是非负的,

$$\text{KL}(q_{\phi}(\mathbf{z} \mid \mathbf{x}) \parallel p_{\theta}(\mathbf{z} \mid \mathbf{x})) \geq 0,$$

立即可得

$$\mathcal{L}(\mathbf{x}; \theta, \phi) \leq \log p_{\theta}(\mathbf{x}),$$

这正是 ELBO 之所以确实是下界的原因。

这一形式也清楚地表明 ELBO 最大化所要达成的目标: 在提升模型证据下界的同时, 缩小近似后验与真实后验之间的失配。

ELBO 的第三种形式: 重构加正则化。 为得到实践中最常用的形式, 我们把联合分布分解为

$$p_{\theta}(\mathbf{x}, \mathbf{z}) = p_{\theta}(\mathbf{x} \mid \mathbf{z}) p(\mathbf{z}).$$

将其代入 ELBO, 得到

$$\begin{aligned} \mathcal{L}(\mathbf{x}; \theta, \phi) &= \mathbb{E}_{q_{\phi}(\mathbf{z} \mid \mathbf{x})} \left[\log \frac{p_{\theta}(\mathbf{x} \mid \mathbf{z}) p(\mathbf{z})}{q_{\phi}(\mathbf{z} \mid \mathbf{x})} \right] \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z} \mid \mathbf{x})} [\log p_{\theta}(\mathbf{x} \mid \mathbf{z})] + \mathbb{E}_{q_{\phi}(\mathbf{z} \mid \mathbf{x})} [\log p(\mathbf{z}) - \log q_{\phi}(\mathbf{z} \mid \mathbf{x})]. \end{aligned}$$

第二个期望同样是一个负的 KL 散度, 于是我们得到

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_{\phi}(\mathbf{z} \mid \mathbf{x})} [\log p_{\theta}(\mathbf{x} \mid \mathbf{z})] - \text{KL}(q_{\phi}(\mathbf{z} \mid \mathbf{x}) \parallel p(\mathbf{z})).$$

这是人们最熟悉的 VAE 目标。它包含作用截然不同的两项:

- 重构项

$$\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})],$$

它鼓励解码器在给定采样潜编码时为观测数据赋予高概率，因此充当一个重构目标；

- 正则化项

$$\text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \parallel p(\mathbf{z})),$$

它鼓励近似后验保持接近先验。

第一项通过解码器促进精确的重构。第二项则阻止编码器把每个数据点任意地放置在潜空间中。相反，它鼓励推断出的潜分布与所假设的先验保持相容，从而赋予潜空间一个更连贯的全局结构。

正是这种正则化使得生成式采样具有意义。训练完成后，我们可以抽取

$$\mathbf{z} \sim p(\mathbf{z}), \quad \mathbf{x} \sim p_\theta(\mathbf{x} | \mathbf{z}),$$

并期待所得到的样本与数据分布相似。

这也回应了 PPCA 一章结尾所强调的局限。在 PPCA 中，模型引入了先验，却没有显式地正则化推断出的潜空间使之与先验对齐。在 VAE 中，这种对齐被直接构建进学习目标之中。

上面推导的三种形式在代数上等价，但强调同一目标的不同侧面。图 3.2 把它们汇总在一起，随后我们将总结 ELBO 最大化达成了什么。




图 3.2: **Three equivalent views of the VAE ELBO.** The joint-density form is the generic variational objective. Bayes' rule gives the inference view as the exact log-likelihood minus posterior mismatch, while factoring the joint gives the training view as expected reconstruction log-likelihood minus regularisation toward the latent prior. All three are algebraically equivalent.

ELBO 达成了什么。 我们现在可以从两个互补的视角来审视 VAE 目标。

从推断的视角，ELBO 说的是：

学习一个既接近真实后验、又能很好解释数据的近似后验。

从表示学习的视角，它说的是：

学习能够精确重构数据的潜编码，但要让潜空间保持有序，并与一个简单先验相容。

这就是为什么 VAE 不只是“加了噪声的自编码器”。它的目标不只是重构，而是在一个潜变量生成模型的内部执行近似的概率推断。

与此同时，这一目标带来了新的计算挑战。重构项是对从 $q_\phi(\mathbf{z} | \mathbf{x})$ 采样得到的随机潜变量取期望。要关于编码器参数 ϕ 优化 ELBO，从而把近似后验与解码器联合训练，我们需要一种让梯度穿过这一采样过程的方法。

这正是重参数化技巧的目的所在，它将是下一节的出发点。

3.3 学习变分自编码器：重参数化与优化

上一节表明，VAE 通过最大化 ELBO 进行训练，

$$\mathcal{L}(\mathbf{x}; \theta, \phi) = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})] - \text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \parallel p(\mathbf{z})).$$

剩下的问题是：鉴于该目标包含对从编码器分布抽取的随机潜样本取期望，它在实践中应当如何优化。

ELBO 中的重构项包含对潜样本的期望：

$$\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})].$$

这意味着，在训练期间，我们必须从编码器分布中采样 $\mathbf{z}$ ，然后将该样本送入解码器。

乍看之下，这似乎很直接：采样

$$\mathbf{z} \sim q_\phi(\mathbf{z} | \mathbf{x}),$$

计算重构项，然后优化。困难在于，采样分布本身依赖于编码器参数 ϕ 。如果我们把 $\mathbf{z} \sim q_\phi(\mathbf{z} | \mathbf{x})$ 当作黑箱随机操作，那么样本 $\mathbf{z}$ 对 ϕ 的依赖就被隐藏在采样步骤内部，从而阻碍普通的反向传播穿过编码器。

换言之，一旦给定 $\mathbf{z}$ ，对解码器参数 θ 求导很容易；但编码器参数 ϕ 却更成问题，因为它们决定了 $\mathbf{z}$ 如何被采样。要通过基于梯度的优化高效地训练 VAE，我们需要一种方法，把这一随机采样步骤改写为可微的计算。

重参数化技巧。 关键思想是把随机性的来源与对编码器参数的依赖分离开来。对于常见的带对角协方差的高斯近似后验，

$$q_\phi(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}_\phi(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_\phi^2(\mathbf{x}))),$$

我们可以先生成潜样本：先从标准正态分布中抽取噪声


$$\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

再定义

$$\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\epsilon}.$$

这就是重参数化技巧 [21, 35]。图 3.3 对比了直接的随机视角与重参数化后的计算。

(a) Direct parameter-dependent sampling



(b) Reparameterised sampling




图 3.3: **The reparameterisation trick separates randomness from the encoder parameters.** Directly sampling $\mathbf{z} \sim q_\phi(\mathbf{z} | \mathbf{x})$ obscures the ordinary pathwise gradient through the sampling step. Instead, sampling parameter-free $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ and setting $\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\epsilon}$ preserves the same Gaussian distribution while making $\mathbf{z}$ differentiable in the encoder outputs for a fixed noise draw.

这一技巧并没有消除随机性，而是把它转移到了与编码器参数独立的辅助噪声 $\boldsymbol{\epsilon}$ 上。对固定的噪声抽取而言，潜变量是一个确定性的可微函数

$$\mathbf{z} = \mathbf{z}(\mathbf{x}, \phi, \boldsymbol{\epsilon}),$$

因此普通的路径梯度可以借助标准的反向传播穿过编码器进行传播。

编码器与解码器的联合优化。 有了重参数化技巧，VAE 便可以通过关于两组参数联合最大化 ELBO 来进行端到端训练：

$$(\theta, \phi) \mapsto \max \mathcal{L}(\mathbf{x}; \theta, \phi).$$

在实践中，对每个输入，编码器产生 $\boldsymbol{\mu}_\phi(\mathbf{x})$ 与 $\boldsymbol{\sigma}_\phi(\mathbf{x})$ ，通过重参数化构造一个潜样本，计算 ELBO，然后梯度同时穿过编码器与解码器反向传播。这一优化通常使用小批量随机梯度方法或其现代变体之一来执行。

这是 VAE 最重要的概念成就之一。它把近似后验推断与生成学习变成了单个可微的计算图。从这一点起，编码器与解码器不再作为彼此分离的对象来训练：它们通过 ELBO 耦合在一起，共同学习。

从这个意义上说，训练 VAE 是变分推断 (variational inference) 的一个实例。我们不再精确计算真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ ，而是学习一个易于处理的近似 $q_\phi(\mathbf{z} | \mathbf{x})$ ，并同时关于解码器参数 θ 与编码器参数 ϕ 优化 ELBO。

一个变体： β -VAE。重构与正则化之间的平衡可以以不同方式加以调节，其中一个重要扩展是 β -VAE [14]，它在 KL 项上引入了一个权重因子：

$$\mathcal{L}_\beta = \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})] - \beta \text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})).$$

当 $\beta > 1$ 时，潜空间受到更强的正则化，往往带来更有结构或更解耦的表示，但通常以重构质量为代价。

这一扩展尤其清楚地揭示了变分潜变量模型中的一个核心张力：

潜空间必须足够规整以支持生成，同时又必须足够富含信息以支持有用的表示与重构。

从这个角度看，VAE 标志着现代生成建模发展中的一个重要步骤。PPCA 引入了一个易于处理的概率潜变量模型。VAE 则通过用学习得到的近似取代精确推断、并把 ELBO 变成实用的训练目标，把同样的潜变量逻辑带入了非线性神经网络的场景。

这些思想在后续章节中仍将发挥作用。特别地，尽管扩散模型常从其他视角引入，基于 ELBO 的推理与潜变量视角同样为接近它们提供了有用的框架。在下一章中，我们将看到这些相同的概率思想如何在最重要的现代生成式 AI 框架之一中得到进一步延展。

总结与参考文献

本章介绍了变分自编码器 (VAE)：它既是自编码器的概率扩展，也是经由 PPCA 发展起来的潜变量框架的非线性延续。

由于模型是非线性的，边缘似然 $p_\theta(\mathbf{x})$ 与真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ 通常都没有闭式表达。随后我们看到，ELBO 具有若干等价形式，其中最熟悉的一种分解为重构项与正则化项。这清楚地表明，VAE 并不仅仅是在重构输入，而是在学习一个与简单先验保持相容、因而能够支持有意义生成的潜表示。

最后，本章展示了重参数化技巧如何把随机潜采样改写为对不含参数的噪声的可微变换，从而使编码器与解码器能够通过基于梯度的优化联合训练。

VAE 的原始表述由 Kingma 与 Welling [21] 提出，密切相关的随机梯度变分方法则由 Rezende、Mohamed 与 Wierstra [35] 发展而来。关于更广泛的概率建模背景，参见 Bishop [4] 与 Murphy [27]。关于 VAE 的全面介绍及其近期发展的综述，参见 Kingma 与 Welling [22]。

第 4 章 4

去噪扩散概率模型

概述

扩散模型 (diffusion model) 是现代最重要的生成模型家族之一，在众多应用中取得了出色表现，尤其是在图像合成领域。其核心是一个简单而强大的思想：不再一步生成样本，而是学习通过一系列去噪操作，将噪声逐步变换为结构化数据。

本章聚焦于离散时间的去噪扩散概率模型 (Denoising Diffusion Probabilistic Model, DDPM) 框架 [16]，它为这一思想提供了最清晰的概率表述之一。从历史上看，基于扩散的生成建模由 Sohl-Dickstein 等人 [37] 提出，其灵感来自物理学中的思想，尤其是随机性随时间逐渐累积的过程。例如，在物理世界中，一滴墨水滴入水中后会慢慢扩散，直到其结构与周围环境无法区分。扩散模型借用这一直觉并将其反转：我们不再旁观秩序消融为噪声，而是学习如何从噪声出发，逐步重构出结构。

然而在本书中，我们首先从经由 PPCA 与 VAE 建立起来的概率与潜变量视角来切入扩散模型。这能在引入连续时间动力学视角之前，提供一个自然的切入点。之后，在第 5 章中，我们将回到相关的微积分、动力学与密度演化视角，并在第 6 章中逐步建立更为连续化的诠释。

从方法论角度看，扩散模型仍与早期的潜变量模型有着重要的结构性联系。关键区别在于：扩散模型不再使用单个潜变量或单步随机编码，而是引入了一整条随时间相连的潜状态序列。在实践中，这赋予扩散模型两个相互关联的阶段：一个固定的前向过程，将数据逐步腐蚀为噪声；以及一个学习得到的反向去噪过程，从噪声中逐步重构出结构。这种时序化设计为模型带来了更大的灵活性，但也改变了推断与学习的表述方式。

概念图


本章将前几章的建模逻辑加以拓展，通过潜变量、后验推断与变分学习来解释序列化的加噪与去噪过程。

- 我们从前向扩散过程开始。一个干净样本 $\mathbf{x}_0$ 在 T 步中被高斯噪声逐渐腐蚀，产生一条潜轨迹 $\mathbf{x}_1, \dots, \mathbf{x}_T$ 。这定义了一条固定的马尔可夫链，同时给出任意带噪状态 $\mathbf{x}_t$ 与原始样本 $\mathbf{x}_0$ 之间的闭式关系。
- 随后，我们将反向过程作为学习得到的生成模型引入。模型从时刻 T 处一个简单的高斯先验出发，学习一条反向去噪链，目标是重构数据分布。这条反向链是扩散中未

知的部分，也是学习的主要对象。

- 接着，我们把扩散模型改写为 **ELBO** 形式。观测变量是干净样本 $\mathbf{x}_0$ ，而潜变量是整条轨迹 $\mathbf{x}_{1:T}$ 。已知的前向过程在 ELBO 中扮演辅助分布的角色，把一个难以处理的似然转化为可处理的下界。
- 我们将 **ELBO** 分解为局部的去噪项。这表明，在每个时间步上，关键的可训练量是学习得到的反向转移 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 与真实反向后验 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 之间的不匹配程度。
- 然后，我们推导真实反向后验，并将其重写到噪声域中。由于前向过程是高斯的，真实反向后验也是高斯的。通过噪声变量对其均值进行重参数化，可以消去对 $\mathbf{x}_0$ 的显式依赖，从而得到标准的 DDPM 参数化形式。
- 最后，我们得到实用的 **DDPM** 目标函数与生成流程。学习问题简化为噪声预测，因此训练变成一个关于高斯噪声的回归任务；而采样则变成一个迭代去噪过程，将纯噪声逐步变换为数据样本。

DDPM 的主要概率结构如下图直观总结所示。



4.1 前向扩散过程：从数据到噪声

扩散模型与我们迄今研究过的生成框架在一个重要方面有所不同。在 PPCA 与 VAE 中，每个观测都由一个相对直接的潜表示来描述。相比之下，在扩散模型中，一个数据点关联着一系列潜状态，它记录了随时间逐渐发生的变换。因此，生成不再是一次性的解码步骤，而是一条轨迹。

从高层来看，DDPM 由两个互补的过程构成。前向过程将一个干净的数据样本 $\mathbf{x}_0$ 逐渐腐蚀，直到它几乎变成纯高斯噪声。反向过程，亦称去噪过程，则旨在逐步撤销这种腐蚀，从噪声出发逐渐恢复出一个结构化的样本。

我们从模型中较简单的一半开始：前向过程。在扩散文献中，这个过程习惯上记作 q 。它是固定且已知的，而非从数据中学习得到。它的作用是定义干净样本 $\mathbf{x}_0$ 如何在 T 个离散时间步上被逐渐腐蚀，从而产生一个噪声越来越大的潜状态序列

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T.$$

4.1.1 高斯加噪与前向过程的闭式表达

逐步的高斯加噪过程。令 $\mathbf{x}_0$ 表示一个观测到的数据样本。前向扩散过程通过在每一步加入少量高斯噪声来产生上述序列。形式上，从 $\mathbf{x}_{t-1}$ 到 $\mathbf{x}_t$ 的转移定义为

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t | \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}),$$

其中 $\beta_t \in (0, 1)$ 控制在第 t 步注入多少噪声。

等价地，我们也可以把同一步写成

$$\mathbf{x}_t = \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \mathbf{z}_t, \quad \mathbf{z}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

这个更新式有一个简单的解释： $\sqrt{1 - \beta_t}$ 保留了上一时刻信号的一部分，而 $\sqrt{\beta_t}$ 则缩放当前步新加入的高斯扰动。因此，每个新状态 $\mathbf{x}_t$ 都比它之前的状态噪声略大一些。

这里 β_t 控制在第 t 步加入多少新的高斯噪声，因而也控制了随着过程演化，数据的原始结构被摧毁的速度。

$\mathbf{x}_t$ 与 $\mathbf{x}_0$ 之间的闭式联系。上面的一步规则告诉我们 $\mathbf{x}_t$ 如何依赖于 $\mathbf{x}_{t-1}$ ，但把 $\mathbf{x}_t$ 直接与原始的干净样本 $\mathbf{x}_0$ 联系起来往往更有用。事实证明，这是前向扩散过程最有用的性质之一，因为它让我们能够直接跳到任意时间步 t ，而不必模拟整条链。

从

$$\mathbf{x}_t = \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \mathbf{z}_t, \quad \mathbf{z}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

出发，我们可以递归地把更早的步骤代入更晚的步骤之中。

例如，

$$\mathbf{x}_1 = \sqrt{1 - \beta_1} \mathbf{x}_0 + \sqrt{\beta_1} \mathbf{z}_1,$$

$$\mathbf{x}_2 = \sqrt{1 - \beta_2} \mathbf{x}_1 + \sqrt{\beta_2} \mathbf{z}_2.$$

把第一式代入第二式，得到

$$\mathbf{x}_2 = \sqrt{(1 - \beta_2)(1 - \beta_1)} \mathbf{x}_0 + \sqrt{1 - \beta_2} \sqrt{\beta_1} \mathbf{z}_1 + \sqrt{\beta_2} \mathbf{z}_2.$$

此时，方便的做法是定义

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s.$$

这里 α_t 是第 t 步的信号保留因子，而 $\bar{\alpha}_t$ 是直到时刻 t 的累积信号保留因子。

规律现在已经清楚了。在每一个新步骤中，剩余信号都要再乘以一个因子 $\sqrt{1 - \beta_t} = \sqrt{\alpha_t}$ ，同时加入一份新的高斯扰动。因此，经过 t 步之后，从 $\mathbf{x}_0$ 继承下来的信号被缩放为

$$\prod_{s=1}^t \sqrt{1 - \beta_s} = \prod_{s=1}^t \sqrt{\alpha_s} = \sqrt{\bar{\alpha}_t}.$$

与此同时，众多相互独立的高斯噪声项可以合并为单个总体高斯变量。由于独立高斯变量的加权和仍然是高斯的，累积噪声可以写成一个标准高斯乘以总方差因子 $1 - \bar{\alpha}_t$ 。这就给出闭式关系

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

写成概率形式，即

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}).$$

这一记号上的区分很重要：

- $\mathbf{z}_t$ 表示在第 t 步新加入的局部高斯噪声；
- ϵ 表示整体累积的噪声，概括了直到时刻 t 为止所有加噪步骤的效果。

上面的闭式表达式极为有用。它告诉我们：经过 t 步之后，样本 $\mathbf{x}_t$ 仍包含原始信号的 $\sqrt{\bar{\alpha}_t}$ 部分，而其余部分已被高斯噪声所取代。当 $t = 0$ 时，有 $\bar{\alpha}_0 = 1$ ，于是 $\mathbf{x}_t = \mathbf{x}_0$ 。当 $t = T$ 大到使 $\bar{\alpha}_T \approx 0$ 时，反复的高斯腐蚀已经洗去了原始结构，样本被驱动到接近各向同性的高斯噪声。 $\mathbf{x}_t$ 与 $\mathbf{x}_0$ 之间的这种直接关系，将在后文使训练变得更加高效，因为它让我们能够在任意时间步上采样带噪状态，而无须模拟整条轨迹。

图 4.1 直观地总结了这两种效应：信号系数随噪声系数的增大而减小，而边缘分布则逐渐失去其原有结构。




图 4.1: **Forward diffusion and its closed-form noising relation.** The upper row shows marginal samples at selected diffusion times under the illustrative linear noise schedule. As t increases, the data structure is progressively overwhelmed by Gaussian noise, while the lower panel shows the signal coefficient decreasing as the noise coefficient increases. The snapshots are sampled directly from $q(\mathbf{x}_t | \mathbf{x}_0)$, so they represent distributions at different times rather than one realised Markov trajectory.

4.1.2 前向链与马尔可夫假设

由于扩散过程引入了整条潜状态序列，完整的前向轨迹由联合分布

$$q(\mathbf{x}_{0:T}) = q(\mathbf{x}_0) q(\mathbf{x}_{1:T} | \mathbf{x}_0).$$

描述。由概率的链式法则，

$$q(\mathbf{x}_{0:T}) = q(\mathbf{x}_0) \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots, \mathbf{x}_0).$$

关键的简化假设是：前向过程是马尔可夫的。这意味着每个新状态只依赖于紧挨着的上一个状态：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots, \mathbf{x}_0) = q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

因此，完整的前向分布分解为

$$q(\mathbf{x}_{0:T}) = q(\mathbf{x}_0) \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

这使得前向过程在数学上可处理且易于分析。但它并不是学习的主要对象。一旦数据样本 $\mathbf{x}_0$ 与噪声时间表 $\{\beta_t\}_{t=1}^T$ 被固定，前向过程 q 就完全已知。

前向过程小结

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t | \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \quad \alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s.$$

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

因此等价地有

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}).$$

$$q(\mathbf{x}_{0:T}) = q(\mathbf{x}_0) \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

然而，对生成而言真正重要的是反向过程（亦称去噪过程）：从一个随机高斯点出发，逐步重构出类似数据的样本。该反向过程没有解析形式，必须学习得到，通常由神经网络来完成。为了理解它，我们现在重新启用前面建立的 ELBO 与变分推断工具，并将其适配到这条随时间变化的潜序列上，使得反向过程能够被表达、分析，并最终被训练。

4.2 反向过程与 ELBO 表述

前向过程给了我们一种固定且可处理的方式，把一个干净数据样本 $\mathbf{x}_0$ 变换成噪声越来越大的潜状态序列 $\mathbf{x}_1, \dots, \mathbf{x}_T$ ，最终趋近于高斯噪声。然而，这个过程并不是我们想要学习的

部分。对生成而言，重要的是相反的方向：从噪声出发，逐渐恢复出结构。这正是反向过程的作用，习惯上记作 p 。

从高层来看，反向过程试图撤销前向链所引入的腐蚀。从一个简单的高斯样本 $\mathbf{x}_T$ 出发，它逐步生成 $\mathbf{x}_{T-1}, \mathbf{x}_{T-2}, \dots, \mathbf{x}_0$ ，目标是让最终状态 $\mathbf{x}_0$ 看起来像一个真实的数据样本。换言之，如果前向过程是沿

$$\mathbf{x}_0 \longrightarrow \mathbf{x}_1 \longrightarrow \dots \longrightarrow \mathbf{x}_T,$$

方向移动，那么反向过程的目标是对相反方向

$$\mathbf{x}_T \longrightarrow \mathbf{x}_{T-1} \longrightarrow \dots \longrightarrow \mathbf{x}_0.$$

进行建模。

4.2.1 学习得到的反向链

为了以概率方式描述生成，我们引入一个参数化的反向过程。由概率的一般链式法则，整条反向轨迹上的联合分布原则上可以写成

$$\begin{aligned} p_\theta(\mathbf{x}_{0:T}) &= p_\theta(\mathbf{x}_0, \mathbf{x}_{1:T}) \\ &= p_\theta(\mathbf{x}_0 \mid \mathbf{x}_{1:T}) p_\theta(\mathbf{x}_{1:T}) \\ &= p_\theta(\mathbf{x}_0 \mid \mathbf{x}_{1:T}) p_\theta(\mathbf{x}_1 \mid \mathbf{x}_{2:T}) p_\theta(\mathbf{x}_{2:T}) \\ &= p_\theta(\mathbf{x}_0 \mid \mathbf{x}_{1:T}) p_\theta(\mathbf{x}_1 \mid \mathbf{x}_{2:T}) p_\theta(\mathbf{x}_2 \mid \mathbf{x}_{3:T}) \cdots p_\theta(\mathbf{x}_{T-1} \mid \mathbf{x}_T) p(\mathbf{x}_T). \end{aligned}$$

这是最一般的展开式：每个更早的状态都可能依赖于所有更晚的状态。

然而在扩散模型中，我们做出与前向过程相同的简化选择，假设反向链也是马尔可夫的。即

$$p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_{t:T}) = p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t).$$

在这一阶马尔可夫假设下，反向联合分布简化为

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t).$$

这个表达式应当从右向左读。我们从最后一个时间步的一个简单先验出发，通常是

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

然后依次施加一系列学习得到的反向转移 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ ，直至最终在时刻 0 得到一个样本。

这是模型中关键的未知对象。与前向过程 q 不同——前向过程一旦选定噪声时间表 $\{\beta_t\}$ 就完全确定——反向转移没有闭式表达，因此必须从数据中学习。在实践中，参数 θ 属于一个神经网络，它将被训练来对这些反向去噪步骤建模。

4.2.2 为什么反向过程是困难的

乍一看，人们可能会想象直接把前向规则反过来用。但这并不简单。虽然前向转移

$$q(\mathbf{x}_t | \mathbf{x}_{t-1})$$

是高斯的且有解析定义，但相应的反向转移

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

并不能以可直接使用的形式获得。

为了看清原因，回忆贝叶斯公式：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}) q(\mathbf{x}_{t-1})}{q(\mathbf{x}_t)}.$$

前向条件分布 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 由构造可知。困难在于边缘分布 $q(\mathbf{x}_{t-1})$ 与 $q(\mathbf{x}_t)$ 。它们并不是人为选定的简单固定高斯分布；相反，它们是由未知的数据分布 $q(\mathbf{x}_0)$ 经过前向加噪链推演而诱导出来的。因此，尽管前向步骤本身很简单，真实的反向条件分布却隐式地依赖于底层的数据分布，从而无法表示为一个可以直接求值或从中采样的简单规则。

当我们考虑基于似然的学习时，还会出现第二个困难。模型在整条反向轨迹 $\mathbf{x}_{0:T}$ 上定义了一个联合分布，但我们最终关心的是观测到的干净数据的边缘似然：

$$p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}.$$

这正对应于我们在前面各章潜变量模型中遇到的边缘似然在扩散模型中的版本。观测变量是干净样本 $\mathbf{x}_0$ ，而整条轨迹 $\mathbf{x}_{1:T}$ 扮演潜变量的角色，必须被积分掉。

$p_\theta(\mathbf{x}_0)$ 这个量是我们希望学习与优化的关键对象，因为它衡量模型赋予真实数据样本多大的概率。如果一个生成模型赋予观测数据很高的概率，就说明它学到了数据域上一个良好的分布。但在扩散模型中，这个边缘似然只是通过反向链

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t).$$

间接定义的。因此，把反向转移 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 学好，恰恰就是我们希望构建一个对 $\mathbf{x}_0$ 赋予高似然的模型的方式。

然而困难在于：计算 $p_\theta(\mathbf{x}_0)$ 需要对整条潜轨迹 $\mathbf{x}_{1:T}$ 积分。由于这条轨迹是高维且按时间索引的，该积分通常难以处理。

因此，正如在 VAE 中一样，核心的学习问题是：

当精确的边缘似然没有闭式表达时，我们该如何优化模型？

答案依然是使用证据下界（Evidence Lower Bound, ELBO）。

4.2.3 扩散模型的 ELBO

将 ELBO 改写到扩散情形。此时，把扩散模型与前几章建立的一般 ELBO 框架联系起来会很有帮助。

在 PPCA 与 VAE 中，我们把边缘似然写成一般的潜变量形式

$$p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z},$$

其中 $\mathbf{x}$ 是观测变量， $\mathbf{z}$ 是潜变量。在扩散模型中，同样的结构依然存在，只是记号现在特化为：

$$\mathbf{x} \longrightarrow \mathbf{x}_0, \quad \mathbf{z} \longrightarrow \mathbf{x}_{1:T}.$$

也就是说，观测变量是干净数据样本 $\mathbf{x}_0$ ，而潜变量不再是单个编码，而是整条带噪轨迹 $\mathbf{x}_{1:T}$ 。

相应地，边缘似然现在具有如下形式

$$p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}.$$

在一般的 ELBO 推导中，我们还引入了潜变量上的一个辅助分布 $Q(\mathbf{z})$ 。在扩散情形中，这个角色自然由

$$q(\mathbf{x}_{1:T} \mid \mathbf{x}_0),$$

来扮演，即以观测数据为条件的、已知的前向过程。

这一点值得强调。在 VAE 中，辅助分布必须作为一个学习得到的近似 $q_\phi(\mathbf{z} \mid \mathbf{x})$ 引入，因为真实后验难以处理，也没有闭式的编码器可用。然而在扩散模型中，情况有所不同：一旦 $\mathbf{x}_0$ 已知，前向加噪过程已经为我们提供了潜轨迹上完整的条件分布。也就是说，对于一个给定的干净数据点 $\mathbf{x}_0$ ，模型已经确切地告诉我们如何采样它的带噪版本 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T$ 。因此，ELBO 所需的辅助分布并不是额外附加在模型之上的可学习构造；它已经作为前向扩散过程本身内建于模型之中。

这是扩散模型的优雅特性之一。“变分分布”已经现成可用：

$$Q(\mathbf{Z}) \longrightarrow q(\mathbf{x}_{1:T} \mid \mathbf{x}_0).$$

换言之，扩散模型无须像 VAE 那样为潜变量单独学习一个编码器网络。已知的前向过程已经提供了 ELBO 所需的潜状态条件分布。

ELBO 形式下的扩散模型各量

observed variable: $\mathbf{x} \rightarrow \mathbf{x}_0$, latent variable: $\mathbf{z} \rightarrow \mathbf{x}_{1:T}$.

learned generative joint: $p(\mathbf{x}, \mathbf{z}) \rightarrow p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$.

auxiliary / variational distribution: $Q(\mathbf{z}) \rightarrow q(\mathbf{x}_{1:T} | \mathbf{x}_0)$,

它已经由前向扩散过程完全已知。

marginal likelihood: $p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}$,

它通常难以处理，因为需要将整条潜轨迹边缘化掉。

扩散模型的 ELBO。 有了这些对应关系，标准的 ELBO 构造给出

$$\log p_\theta(\mathbf{x}_0) \geq \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

这就是特化到扩散情形的 ELBO。

随后，为了在整个数据集上训练模型，我们对经验数据分布 $q(\mathbf{x}_0)$ 取一层外期望，也就是对于干净训练样本本身取期望。这给出总体目标

$$\mathbb{E}_{q(\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0)] \geq \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

因此，从本书前面建立的潜变量视角来看，扩散模型自然地融入同一个一般概率框架：它们仍然是生成式的潜变量模型，只是现在的潜变量是一条按时间索引的潜序列，而非单个潜编码。我们不再直接优化难以处理的边缘似然，而是优化一个由两个成分构成的可处理下界：学习得到的反向生成模型 $p_\theta(\mathbf{x}_{0:T})$ ，与已知的前向过程 $q(\mathbf{x}_{1:T} | \mathbf{x}_0)$ 。

因此，关键的下一步就是展开并化简这个 ELBO，从而看清学习问题如何分解到各个扩散时间步上。这将是下一节的目标：在那里，我们将更明确地拆解反向过程，并推导出最终通向实用 DDPM 训练损失的逐时间步目标。

4.3 从扩散 ELBO 到逐时间步的目标

我们现在把上一节推导出的扩散 ELBO 改写成一种形式，使模型实际被训练去学习的内容显露出来。关键思想是：尽管似然涉及整条潜轨迹 $\mathbf{x}_{1:T}$ ，最终得到的目标却可以分解为局部的去噪步骤。

4.3.1 展开扩散 ELBO

代入前向链与反向链。 回顾已经建立的两个分解式：

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t),$$

以及

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

如前所述，由于前向过程是以干净数据样本 $\mathbf{x}_0$ 为条件来定义的，我们同样可以把这一条件显式保留，写成

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0).$$

由马尔可夫性质，在单步前向转移中以 $\mathbf{x}_0$ 为条件是多余的，但让它保持可见很快就会有用了——稍后我们将用贝叶斯公式重写 ELBO。

把前向链与反向链代入 ELBO，得到

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)}{\prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)} \right].$$

利用对数把乘积化为求和，上式变为

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\log p(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)} \right].$$

乍一看，这已经像一个逐时间步的目标了。然而，它还没有写成最有用的形式。这里的分母仍然是前向加噪分布，而模型试图学习的是一个反向去噪过程。

学习得到的去噪过程应当逼近什么？ 学习得到的反向转移

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

是模型的去噪规则：给定一个带噪状态 $\mathbf{x}_t$ ，它应当产生一个关于稍干净一些的状态 $\mathbf{x}_{t-1}$ 的分布。因此，自然的学习目标不是前向腐蚀规则 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ ，而是由前向过程诱导出的相应真实反向后验。

这里需要区分两个密切相关的对象：

- 学习得到的反向过程（亦称学习得到的去噪过程）

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t),$$

即我们参数化并训练的模型；

- 由前向过程诱导出的真实反向后验

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0),$$

即在给定干净样本 $\mathbf{x}_0$ 之后，由已知加噪机制所隐含的精确单步去噪分布。

为什么我们希望学习得到的去噪过程与这个后验相匹配？因为前向过程确切地告诉了我们真实数据是如何被腐蚀的。所以在训练期间，它也告诉我们该腐蚀过程正确的单步逆转应当是什么。如果学习得到的反向转移在每个时间步都模仿真实反向后验，那么整条学习得到的反向链就将能够撤销前向加噪过程，并恢复数据分布。

一个微妙但重要的点是：我们并不直接处理

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t).$$

这个对象是由完整数据分布诱导出的无条件反向分布，无法直接处理。然而在训练期间，干净数据样本 $\mathbf{x}_0$ 是被观测到的。这意味着我们可以转而处理

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0),$$

即对于那个特定的观测样本，由已知前向过程诱导出的条件后验。这正是我们让 $\mathbf{x}_0$ 保持显式的原因：以观测数据为条件，可以使相关的反向分布在解析上可处理。

因此，学习反向过程的任务可以更精确地表述为：

训练模型化的去噪转移 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ ，使其在每个扩散时间步上都与真实反向后验 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$ 相匹配。

4.3.2 用贝叶斯公式重写 ELBO

一个揭示真实反向后验的实用技巧

这个技巧是让每一项都保持以观测到的干净样本 $\mathbf{x}_0$ 为条件，然后应用贝叶斯公式。从前向转移 $q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0)$ 出发，在以 $\mathbf{x}_0$ 为条件时，贝叶斯公式给出：

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1}, \mathbf{x}_t \mid \mathbf{x}_0)}{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)} = \frac{q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) q(\mathbf{x}_t \mid \mathbf{x}_0)}{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}.$$

整理后即得真实反向后验：

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)}.$$

为了把这个真实反向后验引入 ELBO，我们对前向转移应用贝叶斯公式：

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) q(\mathbf{x}_t \mid \mathbf{x}_0)}{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}.$$

把它代入 ELBO 的分母，得到

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)} \left[\log p(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t) q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) q(\mathbf{x}_t \mid \mathbf{x}_0)} \right].$$

现在把乘积的对数拆成求和：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} \mid \mathbf{x}_0)} \left[\log p(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)}{q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)} + \sum_{t=1}^T \log \frac{q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)} \right].$$

第二个求和是望远镜式（前后相消）的。为了看清这一点，

$$\begin{aligned}
 \sum_{t=1}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)} &= \log \frac{q(\mathbf{x}_0 | \mathbf{x}_0)}{q(\mathbf{x}_1 | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{q(\mathbf{x}_2 | \mathbf{x}_0)} + \dots + \log \frac{q(\mathbf{x}_{T-1} | \mathbf{x}_0)}{q(\mathbf{x}_T | \mathbf{x}_0)} \\
 &= \log \left[\frac{q(\mathbf{x}_0 | \mathbf{x}_0)}{q(\mathbf{x}_1 | \mathbf{x}_0)} \cdot \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{q(\mathbf{x}_2 | \mathbf{x}_0)} \dots \frac{q(\mathbf{x}_{T-1} | \mathbf{x}_0)}{q(\mathbf{x}_T | \mathbf{x}_0)} \right] \\
 &= \log \left[\frac{q(\mathbf{x}_0 | \mathbf{x}_0)}{q(\mathbf{x}_T | \mathbf{x}_0)} \right] = \log q(\mathbf{x}_0 | \mathbf{x}_0) - \log q(\mathbf{x}_T | \mathbf{x}_0).
 \end{aligned}$$

因为所有中间项都两两相消。项 $q(\mathbf{x}_0 | \mathbf{x}_0)$ 形式上是一个集中在观测值 $\mathbf{x}_0$ 处的退化分布，对应一个 Dirac delta 函数而非普通密度。由于它不含可学习参数，只对目标函数贡献一个加性常数，因此在优化时可以忽略。于是 ELBO 变为

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q(\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\log p(\mathbf{x}_T) - \log q(\mathbf{x}_T | \mathbf{x}_0) + \sum_{t=1}^T \log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] + \text{const.}$$

4.3.3 从整体 ELBO 到局部学习项

现在我们把 ELBO 重新整理成标准的逐时间步分解形式。需要处理两个主要部分：

- 涉及端点 $\mathbf{x}_T$ 的边界项；
- 涉及学习得到的去噪转移 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 的时间步项。

从上文得到的表达式出发，我们首先分离出只涉及端点 $\mathbf{x}_T$ 的部分：

$$\mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} [\log p(\mathbf{x}_T) - \log q(\mathbf{x}_T | \mathbf{x}_0)].$$

由于该被积函数只依赖于 $\mathbf{x}_T$ ，其余所有潜变量 $\mathbf{x}_1, \dots, \mathbf{x}_{T-1}$ 都可以在前向链下被边缘化掉，只留下边缘分布 $q(\mathbf{x}_T | \mathbf{x}_0)$ ：

$$\begin{aligned}
 &\mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} [\log p(\mathbf{x}_T) - \log q(\mathbf{x}_T | \mathbf{x}_0)] \\
 &= \mathbb{E}_{q(\mathbf{x}_T | \mathbf{x}_0)} [\log p(\mathbf{x}_T) - \log q(\mathbf{x}_T | \mathbf{x}_0)] \\
 &= -\mathbb{E}_{q(\mathbf{x}_T | \mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p(\mathbf{x}_T)} \right] \\
 &= -\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)).
 \end{aligned}$$

这就是先验匹配项：它比较的是前向过程在最后一个时间步所达到的分布，与学习得到的反向过程出发时所用的简单高斯先验之间的差异。

现在我们来处理关于 t 的求和。这里必须仔细处理内层期望 $\mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)}$ 。整个求和位于期望内部，但每个求和项

$$\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}$$

只依赖于局部变量 $\mathbf{x}_{t-1}$ 和 $\mathbf{x}_t$ ，以及观测样本 $\mathbf{x}_0$ 。因此对每个固定的 t ，其余潜变量同样可以被边缘化掉。

对于特殊情形 $t = 1$ ，这给出

$$\mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}{q(\mathbf{x}_0 | \mathbf{x}_1, \mathbf{x}_0)} \right] = \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}{q(\mathbf{x}_0 | \mathbf{x}_1, \mathbf{x}_0)} \right].$$

由于一旦以 $\mathbf{x}_0$ 为条件， $q(\mathbf{x}_0 | \mathbf{x}_1, \mathbf{x}_0)$ 就是退化的，它对应观测值处的一个点质量，且不含可学习参数。因此它只贡献一个加性常数，余下的就是重构项

$$\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)].$$

对其余各项 $t = 2, \dots, T$ ，我们对内层期望做同样的局部化处理：

$$\begin{aligned} & \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] \\ &= \mathbb{E}_{q(\mathbf{x}_{t-1}, \mathbf{x}_t|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] \\ &= \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \mathbb{E}_{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right]. \end{aligned}$$

现在把内层期望识别为一个 KL 散度的负数：

$$\begin{aligned} & \mathbb{E}_{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)}{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)} \right] \\ &= -\mathbb{E}_{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \left[\log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\ &= -\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)). \end{aligned}$$

因此，每个中间时间步的贡献变为


$$-\mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))].$$

把边界项与时间步项合在一起，负 ELBO 可以写成

$$\begin{aligned} -\mathcal{L}_{\text{ELBO}} &= \mathbb{E}_{q(\mathbf{x}_0)} \left[\underbrace{\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{\text{prior-matching term}} \right. \\ &\quad + \underbrace{\sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))]}_{\text{step-wise denoising terms}} \\ &\quad \left. - \underbrace{\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)]}_{\text{reconstruction term}} \right]. \end{aligned}$$

这个分解区分了三种角色：带噪端点处的先验匹配、中间各步的局部反向转移匹配，以及数据端的重构。图 4.2 展示了这些项如何分布在前向链与反向链上。

The diffusion ELBO decomposes along the chain



The global latent-trajectory objective becomes a boundary term, a reconstruction term, and a sum of local reverse-transition matching terms.

图 4.2: From the diffusion ELBO to local denoising terms. The fixed forward chain q creates the latent trajectory, while p_θ models transitions in the reverse direction. Reorganising the negative ELBO gives endpoint prior matching, data reconstruction, and intermediate KL terms comparing each learned reverse transition with the exact posterior $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$.

关键结论是：学习归结为在每个时间步上，让学习得到的去噪转移 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 与真实反向后验 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 相匹配。因此下一步就是求出这个后验的解析形式。

4.4 从真实反向后验到 DDPM 学习

前几节表明，扩散 ELBO 中核心的可训练项比较的是学习得到的去噪转移

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

与真实反向后验

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0).$$

本节的目的就是把这两种视角联系起来：首先确定由前向过程隐含的精确高斯反向后验，然后展示该后验如何通向实用的 DDPM 学习目标与采样流程。

4.4.1 由已知前向量得到真实反向后验

由上一节，我们有恒等式

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}.$$

这很有用，因为右端的每一项都由前向过程决定，而前向过程是已知的。特别地，

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t} \mathbf{x}_{t-1}, (1 - \alpha_t)\mathbf{I}),$$

其中 $\alpha_t = 1 - \beta_t$ 。由前面的前向过程闭式关系，我们还知道

$$q(\mathbf{x}_{t-1} | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} | \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0, (1 - \bar{\alpha}_{t-1})\mathbf{I}),$$

以及

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t} \mathbf{x}_0, (1 - \alpha_t)\mathbf{I}).$$

于是，真实反向后验完全由前向扩散过程中的高斯量表示。由于上面各项都是高斯的，关于 $\mathbf{x}_{t-1}$ 的后验也必然是高斯的。因此可以写成

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} | \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I}),$$

其中 $\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)$ 为某个均值， $\tilde{\beta}_t$ 为方差系数。

利用前面介绍过的配方 (completing-the-square) 思想 (推导见附录 B)，真实反向后验具有如下高斯形式：其中

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t,$$

且

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

这个结果值得解读。后验均值 $\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)$ 是两部分信息的加权组合：干净样本 $\mathbf{x}_0$ 告诉我们轨迹的起点，当前带噪状态 $\mathbf{x}_t$ 告诉我们在时刻 t 所处的位置。因此，真实反向后验通过结合对干净起点与当前带噪观测两者的知识，找出最合理的、稍微更干净一点的状态。

后验方差 $\tilde{\beta}_t \mathbf{I}$ 同样由前向扩散时间表完全确定。也就是说，一旦前向加噪过程被选定，相应反向步的不确定性也就随之确定。因此，从 ELBO 的角度看，反向模型并不是被要求去匹配一个任意的去噪分布，而是去匹配一个由已知前向过程诱导出的特定高斯目标。

图 4.3 将这一目标描绘为两个已知前向过程因子的高斯融合。




图 4.3: **The exact reverse posterior as a Gaussian fusion.** For fixed $\mathbf{x}_0$ and $\mathbf{x}_t$, the forward marginal $q(\mathbf{x}_{t-1} | \mathbf{x}_0)$ and the transition likelihood $q(\mathbf{x}_t | \mathbf{x}_{t-1})$, viewed as a function of $\mathbf{x}_{t-1}$, provide two Gaussian factors. Their product gives $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$. The one-dimensional plot visualises the same componentwise calculation used in the isotropic multivariate case.

尽管这个后验是精确的，它仍然显式依赖于干净数据样本 $\mathbf{x}_0$ 。在训练时这是可以接受的，因为 $\mathbf{x}_0$ 已知；但在生成时它无法直接使用，因为 $\mathbf{x}_0$ 恰恰是我们想要创造的未知对象。

4.4.2 通过噪声变量对后验进行重参数化

关键的观察是：前向过程已经给出了干净样本 $\mathbf{x}_0$ 、带噪样本 $\mathbf{x}_t$ 与一个标准高斯噪声变量之间的直接关系：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

从中解出 $\mathbf{x}_0$ ，得到

$$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon} \right).$$

现在把它代入后验均值 $\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)$ ，以消去其中对 $\mathbf{x}_0$ 的显式依赖。

从

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\bar{\alpha}_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t,$$

出发，代入 $\mathbf{x}_0$ 的表达式，得到

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \boldsymbol{\epsilon}) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \cdot \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon} \right) + \frac{\sqrt{\bar{\alpha}_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t.$$

化简系数后，上式变为

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \boldsymbol{\epsilon}) = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right).$$

系数化简背后的代数推导

利用

$$\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}, \quad \frac{\sqrt{\bar{\alpha}_{t-1}}}{\sqrt{\bar{\alpha}_t}} = \frac{1}{\sqrt{\alpha_t}},$$

$\mathbf{x}_t$ 的系数变为

$$\frac{\beta_t}{\sqrt{\alpha_t}(1 - \bar{\alpha}_t)} + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} = \frac{\beta_t + \alpha_t(1 - \bar{\alpha}_{t-1})}{\sqrt{\alpha_t}(1 - \bar{\alpha}_t)}.$$

由于

$$\beta_t = 1 - \alpha_t, \quad \bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1},$$

于是有

$$\beta_t + \alpha_t(1 - \bar{\alpha}_{t-1}) = (1 - \alpha_t) + \alpha_t - \alpha_t \bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t,$$

因此化简为

$$\frac{1 - \bar{\alpha}_t}{\sqrt{\alpha_t}(1 - \bar{\alpha}_t)} = \frac{1}{\sqrt{\alpha_t}}.$$

类似地, ϵ 的系数变为

$$\frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{\sqrt{\bar{\alpha}_t} \sqrt{1 - \bar{\alpha}_t}} = \frac{\beta_t}{\sqrt{\alpha_t} \sqrt{1 - \bar{\alpha}_t}}.$$

于是, 真实反向后验可以重写为

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \epsilon) = \mathcal{N}\left(\mathbf{x}_{t-1} \mid \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon\right), \tilde{\beta}_t \mathbf{I}\right).$$

这种形式极为重要。它表明反向步可以通过当前带噪样本 $\mathbf{x}_t$ 与产生它的聚合噪声 ϵ 来刻画。因此, 模型不必试图直接恢复 $\mathbf{x}_0$, 而可以把目标设为预测其背后的噪声。

4.4.3 参数化学习得到的反向过程并推导实用的 DDPM 目标

这就引出了标准的 DDPM 参数化。模型并不知道真实噪声 ϵ , 因此我们引入一个神经网络

$$\epsilon_\theta(\mathbf{x}_t, t)$$

来从带噪样本 $\mathbf{x}_t$ 和时间步 t 预测它。

学习得到的反向转移随即定义为

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1} | \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \tilde{\beta}_t \mathbf{I}),$$

其均值为

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right).$$

这有一个清晰的解释: 如果网络能准确预测真实噪声, 那么学习得到的反向均值就与精确的反向后验均值一致, 从而学习得到的去噪过程就与正确的局部反向步一致。

回顾 ELBO 中核心的可训练项为

$$\mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) \right].$$

现在两个分布都是高斯的，且具有相同的方差 $\tilde{\beta}_t \mathbf{I}$ 。因此它们的 KL 散度退化为均值之间的平方差：

$$\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) \propto \|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \boldsymbol{\epsilon}) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t)\|^2.$$

代入两个均值表达式，得到

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \boldsymbol{\epsilon}) - \boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}} (\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)).$$

因此，除了一个随时间变化的缩放因子之外，KL 项变成了噪声预测的均方误差：

$$\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) \propto \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2.$$

这是 DDPM 中最核心的简化：局部变分项（除一个随时间变化的系数外）退化为对所加高斯噪声的回归问题。因此，精确的 ELBO 诱导出一个加权的噪声预测均方误差。在实践中，Ho 等人 [16] 常用的简化目标去掉了这个随时间变化的权重，使用

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\epsilon}} \left[\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2 \right]$$

其中 $\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1-\alpha_t} \boldsymbol{\epsilon}$ 。图 4.4 总结了从局部后验匹配到这个实用的噪声预测损失之间的代数桥梁。




图 4.4: **From exact posterior matching to noise prediction.** Writing the exact and learned reverse means in the same form, with the same fixed variance, turns the local Gaussian KL into squared mean matching. Their shared coefficients reduce this to a time-weighted squared error between the true noise ϵ and its prediction $\epsilon_\theta(\mathbf{x}_t, t)$. The commonly used $\mathcal{L}_{\text{simple}}$ objective drops this time-dependent weighting.

4.4.4 训练与采样如何进行

训练循环现在在概念上变得很简单。对于每个干净数据样本 $\mathbf{x}_0$ ，我们：

1. 采样一个时间步 t ;
2. 采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;
3. 构造带噪状态

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon;$$

4. 训练网络从 $(\mathbf{x}_t, t)$ 预测 ϵ 。

由于 $\mathbf{x}_t$ 可以直接从 $\mathbf{x}_0$ 采样，训练无需逐步模拟整条前向链。

训练完成后，模型通过迭代运行学习得到的反向过程来生成数据。我们从

$$\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

出发，然后对 $t = T, T-1, \dots, 1$ 依次采样

$$\mathbf{x}_{t-1} \sim p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t).$$

在每一步，模型利用其预测的噪声 $\epsilon_\theta(\mathbf{x}_t, t)$ 计算反向均值，并去除少量腐蚀。在所有时间步上重复这一过程后，最终状态 $\mathbf{x}_0$ 即为生成的样本。

至此，离散时间下 DDPM 的主要概率脉络已经完整。前向过程是固定的，反向过程是学习得到的，ELBO 归结为局部的去噪目标，而最终实用的目标函数则变成噪声预测。

小结与参考文献

本章从概率潜变量的视角介绍了去噪扩散概率模型 (DDPM)。与 PPCA 和 VAE 中由单个潜变量扮演核心角色不同，扩散模型处理的是一条完整的、按时间索引的潜轨迹 $\mathbf{x}_{1:T}$ ，它由一个固定的高斯马尔可夫过程对数据逐步腐蚀而生成。

我们首先展示了前向过程如何把一个干净样本 $\mathbf{x}_0$ 变换成噪声越来越大的状态，并推导了 $\mathbf{x}_t$ 与 $\mathbf{x}_0$ 之间的闭式关系。随后我们转向反向过程——这是必须学习的部分——并利用 ELBO 框架把扩散模型表述为一个边缘似然难以处理的潜变量生成模型。

接着，ELBO 被分解为局部的去噪项，揭示出在每个时间步上关键的可训练量是学习得到的反向转移 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 与真实反向后验 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 之间的不匹配程度。由于前向过程是高斯的，这个后验也是高斯的，并可以闭式地推导出来。然而，由于它显式依赖于干净样本 $\mathbf{x}_0$ ，在生成时无法直接使用。

最后，通过噪声变量对后验进行重参数化，我们展示了扩散学习如何归结为噪声预测。这就给出了实用的 DDPM 目标：训练一个神经网络，预测在给定时间步产生带噪样本的高斯噪声；然后利用这个学习得到的预测器，把纯高斯噪声迭代地去噪成一个数据样本。通过这种方式，DDPM 把前面各章发展起来的概率潜变量路线，拓展为一个建立在渐进腐蚀与重构之上的序列化生成框架。

基于扩散的生成建模框架由 Sohl-Dickstein 等人 [37] 提出，他们将生成表述为对一个渐进加噪过程的学习式逆转，其灵感来自非平衡热力学。这项工作确立了若干至今仍是 DDPM 核心的要素：一个固定的前向腐蚀过程、一个学习得到的反向过程，以及一条连接数据与噪声的中间潜状态序列。

现代的 DDPM 表述由 Ho、Jain 与 Abbeel [16] 发展而来，他们展示了这个序列化潜变量模型如何通过一个可简化为噪声预测的变分目标进行有效训练。后续的改进工作，如 Nichol 与 Dhariwal [28]，改善了 DDPM 的实际训练与采样表现。本书后文展开的基于分数 (score-based) 与连续时间的视角，为同一去噪原理提供了互补的诠释，但本章的重点是 DDPM 的离散潜变量构造。

第 5 章 5

连续时间生成建模的微积分基础

概览

在上一章中，我们研究了离散时间下的去噪扩散概率模型（denoising diffusion probabilistic models, DDPMs），其中生成过程被描述为一系列有限的加噪与去噪步骤。这一视角十分有力，但它也自然引出下一个问题：当步长变得越来越小、以至于这种演化更适合被视为时间上连续的过程时，会发生什么？

这个问题并非扩散模型（diffusion model）所独有。更一般地，机器学习与生成建模（generative modelling）中的许多方法都可以视为形如

$$x_{t+\Delta t} \approx x_t + \text{small update.}$$

的重复局部更新。一个更具体的例子是

$$x_{t+\Delta t} = x_t + \alpha f(x_t) \Delta t + \beta \text{ noise,}$$

其中下一个状态由当前状态加上一个结构化的变化得到，在某些设定下还加上一个随机扰动。在离散时间中，这类规则一步一步地写出；而在连续时间中，同样的思想改由无穷小运动来表达：状态在一个任意小的时间区间内如何变化，以及随机性如何进入这一运动。这正是微积分语言不可或缺的原因。

为此，本章从运动与轨迹讲起。在研究完整的概率分布之前，先理解单个状态在局部更新规则下如何运动、这样的运动在连续时间中如何成为微分方程，以及确定性运动与随机运动如何以统一的方式描述，会很有帮助。

但对生成建模而言，仅有运动还不够。归根结底，重要的不只是单个粒子移动到哪里，而是一整团粒子如何演化，才能使其概率密度呈现出我们想要的形式。因此，接下来我们转向密度演化：粒子运动如何重塑概率质量——先在确定性传输下，后在漂移加噪声的动力学下——最终得到福克-普朗克（Fokker-Planck）方程。

因此，本章逐步展开如下进程

$$\text{discrete updates} \longrightarrow \text{continuous motion} \longrightarrow \text{density evolution.}$$


这为下一章奠定了微积分基础：在下一章中，这些思想将与基于分数的生成建模（score-based generative modelling）相联系，进而引出完全连续的扩散模型。

概念地图

本章建立从离散更新规则走向连续时间生成动力学、再从粒子运动走向整体概率密度演化所需的微积分基础。

- 我们首先通过收缩 (contraction) 研究确定性连续时间运动。在一维情形中，收缩清楚地展示了微分方程如何显式地确定一条轨迹。在多维情形中，同一思想通过矩阵与矩阵指数 (matrix exponential) 加以推广，揭示出不同方向可以以不同的速率收缩。
- 接着我们通过布朗运动 (Brownian motion) 引入随机运动。布朗运动给出了连续时间随机波动的标准模型，其高斯增量的方差随时间线性增长。它提供了日后构成扩散基础的基本随机要素。
- 然后，我们在 Ornstein–Uhlenbeck 过程中将漂移与噪声结合起来。OU 过程展示了确定性收缩与随机扰动如何在单一系统中并存，产生出均值回复的漂移加噪声动力学，预示了后续的时间生成模型。
- 随后我们从粒子运动转向确定性密度演化。从流映射下的概率守恒出发，我们推导出有限时间的变量替换公式，再过渡到无穷小时间，得到一维刘维尔 (Liouville) 方程以及沿轨迹的对数密度变化。
- 我们继而将确定性密度演化推广到多维。这引入了雅可比矩阵 (Jacobian matrix) 作为流的局部线性化、行列式作为局部体积变化的度量，以及散度 (divergence) 作为刻画净局部流出量的物理量。由此得到多维刘维尔方程及其沿轨迹形式。
- 最后，我们加入布朗扩散，得到福克–普朗克方程。可以看到，纯布朗运动通过高斯平均使密度变得平滑，由此产生扩散方程。再加入确定性漂移，便得到完整的福克–普朗克方程，展示传输与扩散如何结合起来支配连续时间中的随机密度演化。

本章所建立的主要关系在下方以图示方式总结。



5.1 从离散更新到连续运动

本节介绍本章其余部分将用到的连续时间运动的基本语言。我们首先建立状态、速度、微分方程与局部近似等核心概念，它们使离散更新规则可以被重新解释为连续运动定律。随

后我们研究三个基本例子：确定性收缩，它以结构化的方式把状态拉向原点；布朗运动，它引入连续时间的随机波动；以及 Ornstein-Uhlenbeck 过程，它在单一的随机系统中结合了漂移与噪声。这些例子共同提供了日后支撑密度演化与连续时间生成动力学的基本运动模式。

5.1.1 连续时间运动的基本语言

我们首先介绍描述连续时间运动的基本语言，目的是精确说明状态如何平滑演化、其局部变化如何度量，以及离散更新规则如何以无穷小形式重新表述。

设 $x(t)$ 表示某个量在时刻 t 的位置。在一维中， $x(t)$ 只是时间的标量值函数；在多维中，它成为一个各坐标都随时间演化的向量。一阶导数 $\frac{dx}{dt}$ 度量 x 对时间的瞬时变化率，通常被解释为速度，也常以点记号写作 $\dot{x}(t)$ 。类似地，二阶导数 $\frac{d^2x}{dt^2} = \ddot{x}(t)$ 度量速度的变化率，通常被解释为加速度。

符号 dx 与 dt 常被非正式地读作位置的无穷小变化与时间的无穷小变化。基本直觉是：若 $\frac{dx}{dt}$ 是变化率，那么在一个极小的时间区间上，位置的相应变化由

$$dx = \frac{dx}{dt} dt.$$

表示。因此，在无穷小形式下，局部变化再次被理解为

$$\text{change} = \text{rate} \times \text{duration}.$$

一旦写出描述位置随时间变化的方程，我们就得到了微分方程。在最简单的情形中，这样的方程把状态在每个可能位置处的速度表示为其当前位置（有时还包括时间）的函数。在高维中，这一局部运动规则在几何上可视为给空间中每个点指定一个运动方向。因此，可以把微分方程看作一条运动规则，把向量场看作由所有局部箭头构成的图像，这些箭头指明粒子若被放置在不同位置将如何运动。

这些思想在这里尤其有用，因为它们使我们能够把迭代更新规则重新解释为连续运动定律。在小区间 Δt 上，一阶近似给出

$$x(t + \Delta t) \approx x(t) + \frac{dx}{dt} \Delta t.$$

这表明稍晚时刻的值近似等于当前值加上速度乘以小的时间增量，因此它是离散更新规则在连续时间中的对应物。

一阶泰勒展开

泰勒展开利用光滑函数在某选定点处的各阶导数来近似该点附近的函数。在局部形式下，对于小位移 Δx ，可以写出

$$f(x + \Delta x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x)}{k!} (\Delta x)^k.$$

写出前几项，得

$$f(x + \Delta x) = f(x) + f'(x)\Delta x + \frac{f''(x)}{2!}(\Delta x)^2 + \frac{f^{(3)}(x)}{3!}(\Delta x)^3 + \dots$$

一阶泰勒近似只保留常数项与线性项：

$$f(x + \Delta x) \approx f(x) + f'(x)\Delta x.$$

被舍弃的项涉及 $(\Delta x)^2$ 、 $(\Delta x)^3$ 等幂次。当 Δx 非常小时，这些高阶项变得远小于线性项。

在当前设定中，函数是轨迹 $x(t)$ ，展开变量是时间，小位移是 Δt 。于是

$$x(t + \Delta t) = x(t) + \left. \frac{dx}{dt} \right|_t \Delta t + O(\Delta t^2).$$

只保留一阶项，得 $x(t + \Delta t) \approx x(t) + \left. \frac{dx}{dt} \right|_t \Delta t$ 。

5.1.2 确定性收缩

我们首先考虑确定性运动：当前状态一旦已知，未来的演化便完全确定。最简单的例子是收缩：一种状态被持续拉回原点的运动。它从一维开始，并自然地推广到多维，在多维中不同坐标可以以不同的速率收缩。

一维收缩。一维中朝向原点的收缩由

$$\frac{dx}{dt} = -\alpha x, \quad \alpha > 0.$$

描述。它表明速度总与当前位置成正比，但符号相反。若 $x > 0$ ，则 $\dot{x} < 0$ ，状态向左朝原点运动；若 $x < 0$ ，则 $\dot{x} > 0$ ，状态向右朝原点运动。两种情形中运动都指向内侧，且状态离原点越远，拉回的力越强。

该方程可以直接求解：

$$\begin{aligned} \frac{dx}{dt} = -\alpha x &\implies \frac{1}{x} \frac{dx}{dt} = -\alpha \implies \frac{d}{dt} \log |x| = -\alpha \\ &\implies \log |x(t)| = -\alpha t + C \implies x(t) = C e^{-\alpha t}. \end{aligned}$$

利用初始条件 $x(0) = x_0$ ，得 $C = x_0$ ，故

$$x(t) = x_0 e^{-\alpha t}.$$

这让系统的行为一目了然。在时刻 $t = 0$, 状态为 x_0 。随着时间增大, 指数因子 $e^{-\alpha t}$ 向零收缩, $x(t)$ 的幅值随之向原点衰减。参数 α 控制收缩的速度: α 越大, 衰减越快; α 越小, 衰减越慢。

因此, 即便是这个简单的例子也已说明了连续时间运动的一个基本原理: 微分方程规定运动的局部方向与速度, 而其解揭示随时间形成的轨迹。

推广到多维。 同一思想自然地推广到高维。设 $x(t) \in \mathbb{R}^2$ 为二维状态向量

$$x(t) = \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix}.$$

一个简单的多维收缩模型是

$$\frac{d}{dt}x(t) = Ax(t),$$

其中 A 是常数矩阵。为表示沿每个坐标轴的独立收缩, 可取

$$A = \begin{bmatrix} -\alpha_1 & 0 \\ 0 & -\alpha_2 \end{bmatrix}, \quad \alpha_1, \alpha_2 > 0.$$

于是系统变为

$$\frac{d}{dt} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} = \begin{bmatrix} -\alpha_1 & 0 \\ 0 & -\alpha_2 \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix},$$

它等价于一对标量方程

$$\dot{x}_1(t) = -\alpha_1 x_1(t), \quad \dot{x}_2(t) = -\alpha_2 x_2(t).$$

因此每个坐标按各自的速率独立收缩:

$$x_1(t) = x_1(0)e^{-\alpha_1 t}, \quad x_2(t) = x_2(0)e^{-\alpha_2 t}.$$

以紧凑形式, 可写作

$$x(t) = e^{At}x(0),$$

其中 e^{At} 是矩阵指数。在本例中, A 是对角矩阵, 因此矩阵指数只是把通常的标量指数函数作用于每个对角元:

$$e^{At} = \begin{bmatrix} e^{-\alpha_1 t} & 0 \\ 0 & e^{-\alpha_2 t} \end{bmatrix}.$$

通过麦克劳林级数理解矩阵指数

光滑函数在零点处的泰勒展开称为麦克劳林级数 (Maclaurin series)。对标量函数 f ，其形式为

$$f(u) = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} u^k = f(0) + f'(0)u + \frac{f''(0)}{2!}u^2 + \frac{f^{(3)}(0)}{3!}u^3 + \dots$$

对指数函数而言，各阶导数仍是 e^u ，故在 $u = 0$ 处它们都等于 1。因此

$$e^u = 1 + u + \frac{u^2}{2!} + \frac{u^3}{3!} + \dots = \sum_{k=0}^{\infty} \frac{u^k}{k!}.$$

矩阵指数用同一级数定义，只是把标量 u 换成矩阵 At ：

$$e^{At} = I + At + \frac{(At)^2}{2!} + \frac{(At)^3}{3!} + \dots$$

标量 1 被单位矩阵 I 替代，因为 I 扮演着矩阵乘法单位元的角色。对这里用到的对角矩阵 $A = \begin{bmatrix} -\alpha_1 & 0 \\ 0 & -\alpha_2 \end{bmatrix}$ ，

我们有

$$At = \begin{bmatrix} -\alpha_1 t & 0 \\ 0 & -\alpha_2 t \end{bmatrix}.$$

对角矩阵的幂仍是对角矩阵：

$$(At)^k = \begin{bmatrix} (-\alpha_1 t)^k & 0 \\ 0 & (-\alpha_2 t)^k \end{bmatrix}.$$

把这些幂代入级数，得

$$e^{At} = \begin{bmatrix} \sum_{k=0}^{\infty} \frac{(-\alpha_1 t)^k}{k!} & 0 \\ 0 & \sum_{k=0}^{\infty} \frac{(-\alpha_2 t)^k}{k!} \end{bmatrix} = \begin{bmatrix} e^{-\alpha_1 t} & 0 \\ 0 & e^{-\alpha_2 t} \end{bmatrix}.$$

这个多维例子引入了一个重要的新特征：运动现在可能在不同方向以不同速度缩小。若 $\alpha_1 > \alpha_2$ ，则第一个坐标比第二个坐标衰减更快，因此状态在 x_1 方向的收缩快于 x_2 方向。于是运动仍朝向原点，但收缩未必在所有方向上均匀。

对角形式还表明坐标之间仍无相互作用：每个分量各自演化。虽然为清晰起见例子写在二维中，同一思想可直接推广到 $\mathbb{R}^d$ 。对角矩阵

$$A = \text{diag}(-\alpha_1, -\alpha_2, \dots, -\alpha_d)$$

在每个坐标方向产生独立的指数收缩。

这使得对角收缩成为一个有用的首个多维例子。它以尽可能简单的方式引入了基于矩阵的连续运动，也为从标量微分方程过渡到向量值连续动力学提供了自然的桥梁。

5.1.3 布朗运动

到目前为止的讨论完全是确定性的：初始状态一旦给定，未来轨迹便完全由控制微分方程决定。然而，许多连续时间生成模型还包含随机性。在每个小的时间区间上，状态可能受到随机扰动，所产生的运动不再能仅凭初始条件完全预测。

这种随机连续时间波动的基本模型是布朗运动 (Brownian motion)，也称为维纳运动 (Wiener motion) [29]。它通常记为 $\{W_t\}_{t \geq 0}$ ，可由三条基本性质刻画：

1. $W_0 = 0$;
2. 不相交时间区间上的增量相互独立；
3. 对任意 $\Delta t > 0$,

$$W_{t+\Delta t} - W_t \sim \mathcal{N}(0, \Delta t).$$

第三条性质尤为重要。它表明在长度为 Δt 的短时间区间上，随机增量的均值为零、方差为 Δt 。因此布朗运动引入的波动在平均意义上无偏，但其不确定性随时间流逝而增长。

高斯假设也是自然的。如果设想短区间上的运动是许多微小、近似独立的随机扰动的累积效应，那么它们的总和可用高斯随机变量很好地刻画。这与中心极限定理背后的直觉密切相关：当许多微小的独立效应相加时，其总和趋于高斯形式。

理解这一点的一个有用方式，是把区间 $[0, t]$ 划分成许多小块，并把 W_t 写成独立高斯增量之和。若把 $[0, t]$ 分成 n 个长度为 $\Delta t = \frac{t}{n}$ 的相等小块，则

$$W_t - W_0 = \sum_{k=0}^{n-1} (W_{(k+1)\Delta t} - W_{k\Delta t}) = \sum_{k=0}^{n-1} \Delta W_k, \quad \Delta W_k := W_{(k+1)\Delta t} - W_{k\Delta t}.$$

由于 $W_0 = 0$ ，上式变为

$$W_t = \sum_{k=0}^{n-1} \Delta W_k.$$

布朗运动在时刻 t 的均值与方差

每个增量满足

$$\Delta W_k \sim \mathcal{N}(0, \Delta t), \quad \mathbb{E}[\Delta W_k] = 0, \quad \text{Var}(\Delta W_k) = \Delta t = \frac{t}{n}.$$

因此

$$\mathbb{E}[W_t] = \sum_{k=0}^{n-1} \mathbb{E}[\Delta W_k] = 0,$$

并利用独立性，

$$\text{Var}(W_t) = \sum_{k=0}^{n-1} \text{Var}(\Delta W_k) = \sum_{k=0}^{n-1} \frac{t}{n} = t.$$

于是

$$\mathbb{E}[W_t] = 0, \quad \text{Var}(W_t) = t.$$

因此在每个固定时刻 t ，布朗运动以零为中心，但其扩散程度随时间线性增长。这意味着布朗运动不会把状态拉向任何特定位置；相反，它描述的是不确定性随时间增加的随机游走。

理解布朗运动的一个有用的启发式方式是通过近似

$$W_{t+\Delta t} - W_t \approx \sqrt{\Delta t} \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1).$$

它让尺度关系尤为清晰。由于增量的方差为 Δt ，其典型大小是 $\sqrt{\Delta t}$ 的量级，而非 Δt 。这一平方根尺度是随机连续时间运动最显著的特征之一，之后会在扩散模型中再次出现。

布朗运动常以微分形式非正式地写作 dW_t ，表示一个无穷小的随机增量。尽管 dW_t 不是确定性意义上的普通微分，这种记号却极其有用，因为它使随机运动可以写成与常微分方程平行的形式。

5.1.4 Ornstein–Uhlenbeck 过程

随机连续时间运动的一个特别重要的例子是 Ornstein–Uhlenbeck (OU) 过程。它把确定性收缩与布朗噪声结合在一起：

$$dX_t = -\alpha X_t dt + \sigma dW_t, \quad \alpha > 0, \sigma > 0.$$

该方程包含两部分。漂移项 $-\alpha X_t dt$ 像前文引入的一维收缩模型那样把状态拉回原点；噪声项 σdW_t 注入由布朗运动驱动的随机扰动。因此 OU 过程平衡两种相互竞争的倾向：朝向原点的确定性拉力与离开原点的随机波动。

在一个小的时间区间 Δt 上，可以启发式地把相应的更新写成

$$X_{t+\Delta t} \approx X_t - \alpha X_t \Delta t + \sigma \sqrt{\Delta t} \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1).$$

这一离散时间视角非常有用。它表明下一个状态由当前状态加上两部分得到：

- 一个大小为 Δt 的确定性修正；
- 一个大小为 $\sqrt{\Delta t}$ 的随机扰动。

因此 OU 过程已经具备日后将出现在朗之万动力学与扩散模型中的基本漂移加噪声结构。

OU 过程还有显式解：

$$X_t = X_0 e^{-\alpha t} + \sigma \int_0^t e^{-\alpha(t-s)} dW_s.$$

这一公式清楚地揭示了其结构。第一项 $X_0 e^{-\alpha t}$ ，正是初始状态的确定性指数收缩；第二项累积所有过去的随机扰动，但每个扰动都以衰减因子 $e^{-\alpha(t-s)}$ 加权。于是较早的噪声贡献逐渐失去影响，而较近的噪声影响更大。

这就是 OU 过程常被描述为均值回复 (mean-reverting) 随机过程的原因：它在保持随机性的同时保有稳定的回复倾向。图 5.1 把这一行为与确定性收缩、布朗运动并排列出，清楚地展示了 OU 过程如何结合这两种基本效应。

不过到目前为止，我们仍只在单个粒子的层面描述运动。下一步是理解这样的运动如何随时间重塑整个概率密度。




图 5.1: **Three fundamental continuous-time motion laws.** Deterministic contraction produces smooth trajectories that decay toward the origin. Brownian motion has zero-mean independent Gaussian increments, so paths wander with typical spread proportional to $\sqrt{t}$; the dashed curves show $\pm 2\sqrt{t}$ for unit Brownian motion. The Ornstein-Uhlenbeck process combines random fluctuations with a restoring drift toward the origin; its dashed lines show twice the stationary standard deviation.

5.2 确定性密度演化

上一节关注单个粒子的运动。这一视角已经很有用，因为许多连续时间模型确实由作用于状态或轨迹的微分方程描述。然而对生成建模而言，单个粒子的运动只是故事的一部分。我们最终关心的是一大群这样的粒子如何随时间改变其概率密度。

因此，本节实现一个重要转变：从轨迹动力学到密度动力学。我们从最简单的确定性设定开始，其中粒子由一个映射传输，概率质量得以保持。这首先导出有限时间的变量替换公式，然后得到无穷小的密度演化定律，最后通过散度得到其多维形式。贯穿始终的基本思想是：

particle motion $\rightarrow$ transport of probability mass $\rightarrow$ deterministic density evolution.

5.2.1 有限时间的密度变换

我们从最简单的密度原理开始：概率在确定性传输下守恒。这里的意思是，粒子被动力学以完全确定的方式从一个位置移动到另一个位置，而与之相伴的概率质量随之被携带。

设在时刻 0，粒子位于 x_0 ，其分布服从密度 $p_0(x_0)$ 。再设确定性动力学把这个初始点传输到较晚的位置

$$x_t = \phi_t(x_0),$$

其中 ϕ_t 表示把粒子从时刻 0 移动到时刻 t 的轨迹或流映射 (flow map)。

为理解密度如何变化，考虑 x_0 附近一个长度为 dx_0 的极小区间。该小区间所含概率质量约为

$$p_0(x_0) dx_0.$$

演化到时刻 t 后，同一小块概率质量被传输到围绕 $x_t = \phi_t(x_0)$ 的新区间。设被传输区间的长度为 dx_t 。由于确定性运动只是传输粒子，不会创造或消灭概率质量，总概率必须保持不变：

$$p_0(x_0) dx_0 = p_t(x_t) dx_t.$$

于是关键问题是小区间 dx_0 在流映射下如何变换。在一维中，这种局部拉伸或压缩由映射的导数度量。推导如下。

推导一维变量替换公式

不仅跟踪点 x_0 ，还跟踪邻近点 $x_0 + dx_0$ 。在同一流映射下，

$$x_t = \phi_t(x_0), \quad x_t + dx_t = \phi_t(x_0 + dx_0),$$

故 $dx_t = \phi_t(x_0 + dx_0) - \phi_t(x_0)$ 。由于 dx_0 非常小，对 ϕ_t 在 x_0 处做一阶泰勒展开，得

$$\phi_t(x_0 + dx_0) \approx \phi_t(x_0) + \frac{d\phi_t(x_0)}{dx_0} dx_0.$$

于是 $dx_t \approx \frac{d\phi_t(x_0)}{dx_0} dx_0 = \frac{dx_t}{dx_0} dx_0$ 。代入概率守恒

$$p_0(x_0) dx_0 = p_t(x_t) \left| \frac{dx_t}{dx_0} \right| dx_0,$$

并消去 dx_0 ，得

$$p_t(x_t) = p_0(x_0) \left| \frac{dx_t}{dx_0} \right|^{-1}.$$

这就是确定性流所诱导的一维变量替换公式。其解释非常直观：若变换拉伸一个区间，同样的概率摊在更大区域上，密度下降；若变换压缩一个区间，同样的概率质量挤进更小区域，密度上升。因此导数 $\frac{dx_t}{dx_0}$ 度量局部长度的变化量，其倒数告诉我们密度如何重新缩放。

同一思想自然地推广到多维。一维时我们跟踪小长度在映射下的变化；二维时须跟踪小面积的变化；三维时是小体积；一般地是小的 d 维体积元。度量这种局部缩放的量不再是

普通导数，而是变换的雅可比矩阵的行列式。于是多维变量替换公式变为

$$p_t(x_t) = p_0(x_0) \left| \det \left(\frac{\partial x_t}{\partial x_0} \right) \right|^{-1}.$$

因此行列式在高维中扮演着 $\frac{dx_t}{dx_0}$ 在一维中扮演的角色，度量流对微小局部区域的拉伸或压缩程度。

需要注意的是，该公式描述的是有限时间的确定性变换。它告诉我们密度在时刻 0 与时刻 t 之间如何变化，但尚未描述密度变化的无穷小速率。为此，下一步我们推导局部时间的连续性方程。

5.2.2 一维无穷小密度演化：刘维尔方程

有限时间变量替换公式告诉我们密度在时刻 0 与时刻 t 之间如何变换。然而在连续时间建模中，理解密度在无穷小时间区间内如何变化往往更加重要，因为连续动力学正由这类局部更新构成。这引出刘维尔方程 (Liouville equation)，在确定性语境下也称为连续性方程。

设粒子按一维常微分方程

$$\frac{dx}{dt} = f(x, t),$$

运动，其中 $f(x, t)$ 是局部速度场。为理解密度如何变化，我们采用固定空间的视角：不再跟随单个粒子，而是站在空间中一个小区间处，观察概率质量从中流过。

考虑短区间 $[x, x + \Delta x]$ 。时刻 t 该区间内的总概率质量约为

$$p(x, t) \Delta x.$$

在无穷小时间区间内，这一局部质量只会因概率从左边界流入或从右边界流出而改变。

相关的流量是概率通量 (probability flux)，即密度乘以速度：

$$p(x, t) f(x, t).$$

它告诉我们单位时间内有多少概率质量穿过某个位置。于是左边界的流入量为

$$p(x, t) f(x, t),$$

而右边界的流出量为

$$p(x + \Delta x, t) f(x + \Delta x, t).$$

因此概率守恒表明，区间内概率质量的变化率必须等于流入减去流出：

$$\frac{\partial}{\partial t} p(x, t) \Delta x = p(x, t) f(x, t) - p(x + \Delta x, t) f(x + \Delta x, t).$$

两边除以 Δx ，得

$$\frac{\partial}{\partial t} p(x, t) = \frac{p(x, t) f(x, t) - p(x + \Delta x, t) f(x + \Delta x, t)}{\Delta x}.$$

整理，得

$$\frac{\partial}{\partial t} p(x, t) = - \frac{p(x + \Delta x, t) f(x + \Delta x, t) - p(x, t) f(x, t)}{\Delta x}.$$

现在令 $\Delta x \rightarrow 0$ 。右边成为空间导数，于是得到

$$\partial_t p(x, t) = -\partial_x (p(x, t)f(x, t)).$$

这就是一维刘维尔方程。

该方程表明，密度按概率通量的净流出而变化。若流出某区域的概率多于流入，则该处密度下降；若流入多于流出，则密度上升。用乘积法则展开右边常常有用：

$$\partial_t p = -(f \partial_x p + p \partial_x f).$$

这揭示出两种不同的贡献。

项 $-f \partial_x p$ 依赖于密度本身的空间斜率，因此描述的是传输 (transport)：已有的密度轮廓被速度场在空间中携带。如果流动只是把粒子从一个地方移动到另一个地方而不改变其相对间隔，那么主要效应就是整个密度轮廓的平移。

相反，项 $-p \partial_x f$ 依赖于速度场的空间斜率，因此描述的是形变 (deformation)：邻近粒子不再以完全相同的速度运动，因而彼此散开或挤压。若 $\partial_x f > 0$ ，速度随位置增大，邻近粒子分离，密度下降；若 $\partial_x f < 0$ ，速度随位置减小，邻近粒子压缩，密度上升。

5.2.3 沿轨迹的密度变化

刘维尔方程描述密度在空间固定位置处如何变化。但还有一个同样非常有益的视角：沿运动粒子的轨迹，密度如何变化？这一视角把注意力从固定位置处发生的事情，转移到随流运动的粒子所经历的变化。

设粒子服从确定性动力学

$$\frac{dx(t)}{dt} = f(x(t), t).$$

考虑沿该粒子路径求值的密度：

$$p(x(t), t).$$

由于位置与时间都在变化，我们用链式法则对该量求导。等价地说，这是全导数 (total derivative)：它把对时间的显式变化与粒子自身在空间中移动带来的隐式变化结合起来。于是

$$\frac{d}{dt} p(x(t), t) = \partial_t p(x(t), t) + \frac{dx(t)}{dt} \partial_x p(x(t), t).$$

由于 $\dot{x}(t) = f(x(t), t)$ ，上式变为

$$\frac{d}{dt} p(x(t), t) = \partial_t p + f \partial_x p.$$

现在代入刘维尔方程

$$\partial_t p = -\partial_x (pf) = -(f \partial_x p + p \partial_x f).$$

得

$$\frac{d}{dt} p(x(t), t) = -(f \partial_x p + p \partial_x f) + f \partial_x p.$$

传输项相消，留下

$$\frac{d}{dt}p(x(t), t) = -p(x(t), t) \partial_x f(x(t), t).$$

两边除以 $p(x(t), t)$ ，得

$$\frac{d}{dt} \log p(x(t), t) = -\partial_x f(x(t), t).$$

因此

$$\boxed{\frac{d}{dt} \log p(x(t), t) = -\partial_x f(x(t), t).}$$

这是一个重要的结果。在上一小节中，密度演化被分解为传输部分与形变部分。这里我们看到，一旦与粒子本身一起运动，传输部分就消失了：从粒子自身的视角看，它不再是在观察被携带穿过空间的轮廓，因为它正随该流一起运动。剩下的只有局部的膨胀或压缩效应。

因此，若 $\partial_x f > 0$ ，邻近粒子趋于分离，沿轨迹的密度下降；若 $\partial_x f < 0$ ，邻近粒子趋于压缩，密度上升。可见固定空间视角与运动粒子视角强调的是同一动力学的不同侧面。刘维尔方程描述整个密度场在空间中如何变化，而上式告诉我们密度沿单条轨迹如何变化。

5.2.4 散度与多维刘维尔方程

现在我们把密度演化从一维推广到完整的多维状态空间。主要的新特征是运动与概率通量都成为向量值。一维中标量导数 ∂_x 就足以描述概率流入或流出小区间；多维中相应的量是散度 (divergence)，它度量向量场从空间微小区域中的净流出。本节展示散度如何从局部体积变化中自然产生，以及它如何导出多维刘维尔方程。

设 $x(t) \in \mathbb{R}^d$ ，粒子按

$$\frac{dx}{dt} = v(x, t),$$

演化，其中速度场为

$$v(x, t) = \begin{bmatrix} v_1(x, t) \\ v_2(x, t) \\ \vdots \\ v_d(x, t) \end{bmatrix}.$$

与一维情形一样，基本思想仍是概率的局部守恒。但在写出密度方程之前，我们首先需要理解空间中微小区域在流下如何变化。一维中这由映射的导数度量，它告诉我们小区间被拉伸或压缩的程度；多维中相应的对象是雅可比矩阵及其行列式。

在一个极小的时间步 $t \rightarrow t + dt$ 上，运动近似为

$$x(t + dt) = x(t) + v(x(t), t) dt.$$

于是无穷小变换为

$$x \mapsto x + v(x, t) dt.$$

为理解微小体积如何变化，我们问更新后的点如何依赖其起始位置。这一依赖关系由对该映射关于 x 求导来刻画，得到该变换的雅可比矩阵：

$$\frac{\partial x(t + dt)}{\partial x} = I + \frac{\partial v}{\partial x} dt.$$

若把速度场的雅可比矩阵记为

$$J_v(x, t) = \frac{\partial v}{\partial x},$$

则

$$\frac{\partial x(t + dt)}{\partial x} = I + J_v(x, t) dt.$$

雅可比矩阵告诉我们小位移在流下如何变化。要从位移过渡到体积，我们取其行列式。

局部体积缩放与散度

局部体积缩放为

$$\det(I + J_v(x, t) dt).$$

对小的 dt ，一阶展开给出

$$\det(I + A dt) = 1 + \text{tr}(A) dt + O(dt^2).$$

以 $A = J_v(x, t)$ 代入，得

$$\det(I + J_v(x, t) dt) = 1 + \text{tr}(J_v(x, t)) dt + O(dt^2).$$

雅可比矩阵的迹有一个专门的名字：

$$\text{tr}(J_v(x, t)) = \nabla \cdot v(x, t) = \sum_{i=1}^d \frac{\partial v_i}{\partial x_i}(x, t).$$

因此

$$\det(I + J_v(x, t) dt) = 1 + (\nabla \cdot v(x, t)) dt + O(dt^2),$$

故小体积元按

$$dV(t + dt) = (1 + (\nabla \cdot v(x, t)) dt) dV(t),$$

演化（精确到一阶）。

这给出了散度的关键几何解释：它是微小体积在流下膨胀或收缩的瞬时速率。若 $\nabla \cdot v > 0$ ，流局部膨胀体积；若 $\nabla \cdot v < 0$ ，流局部压缩体积。

有了这一几何图像，我们就可以推导密度演化方程。一个小的运动体积内的概率质量必须保持不变：

$$p(x, t) dV(t) = p(x + v(x, t)dt, t + dt) dV(t + dt).$$

代入体积缩放关系

$$dV(t + dt) = (1 + (\nabla \cdot v) dt) dV(t),$$

得

$$p(x, t) = p(x + vdt, t + dt)(1 + (\nabla \cdot v) dt).$$

接着，对密度应用多变量一阶泰勒展开。

推导多维刘维尔方程

对同时依赖位置与时间的函数 $p(x, t)$ ，一阶多变量泰勒展开为

$$p(x + \Delta x, t + \Delta t) \approx p(x, t) + \nabla p(x, t) \cdot \Delta x + \partial_t p(x, t) \Delta t.$$

在这里考虑的流中， $\Delta x = v(x, t)dt$ 且 $\Delta t = dt$ ，故

$$\begin{aligned} p(x + vdt, t + dt) &= p(x, t) + \nabla p(x, t) \cdot (vdt) + \partial_t p(x, t)dt + O(dt^2) \\ &= p(x, t) + (v \cdot \nabla p)dt + (\partial_t p)dt + O(dt^2). \end{aligned}$$

把它代入概率守恒

$$p(x, t) = p(x + vdt, t + dt)(1 + (\nabla \cdot v)dt),$$

得

$$\begin{aligned} p &= [p + (\partial_t p)dt + (v \cdot \nabla p)dt] [1 + (\nabla \cdot v)dt] + O(dt^2) \\ &= p + (\partial_t p)dt + (v \cdot \nabla p)dt + p(\nabla \cdot v)dt + O(dt^2). \end{aligned}$$

减去 p ，除以 dt ，并令 $dt \rightarrow 0$ ，

$$0 = \partial_t p + v \cdot \nabla p + p(\nabla \cdot v).$$

利用 $\nabla \cdot (pv) = v \cdot \nabla p + p(\nabla \cdot v)$ ，上式变为

$$0 = \partial_t p + \nabla \cdot (pv),$$

或等价地，

$$\partial_t p(x, t) = -\nabla \cdot (p(x, t)v(x, t)).$$

这就是多维刘维尔方程。它是一维连续性方程的自然推广：标量导数 $\partial_x(pf)$ 的位置现在换成了向量值概率通量 pv 的散度。因此，密度按照概率从空间小区域中的净流出而变化。

沿轨迹的视角同样自然地推广。沿满足

$$\dot{x}(t) = v(x(t), t),$$

的路径，对数密度按

$$\frac{d}{dt} \log p(x(t), t) = -\nabla \cdot v(x(t), t).$$

演化。因此在多维中，与一维一样，一旦与粒子本身一起运动，传输部分就消失了，剩下的密度变化由流的局部膨胀或压缩决定。图 5.2 总结了有限时间体积变化、密度重新缩放与无穷小散度关系之间的几何联系。

Deterministic flow: local volume change controls density




图 5.2: **Probability conservation links local volume change to density change.** A deterministic flow map F_t moves particles and their surrounding volume elements. The Jacobian determinant measures local volume scaling, so conservation of probability rescales density by the inverse volume factor. Infinitesimally, this gives the trajectory-wise Liouville relation: local expansion lowers density, while compression raises it.

5.3 随机密度演化与福克-普朗克方程

到目前为止，密度演化完全是确定性的：概率质量被流传输，其局部变化由散度支配。然而，许多连续时间生成模型还包含随机扰动。一旦加入这类扩散，密度就不再只通过传输与局部膨胀或压缩而变化，还会在空间中扩散开来。这把我们从小维刘维尔方程引向福克-普朗克方程 [36]。

5.3.1 作为高斯平滑的纯布朗扩散

为建立直觉，先考虑一维纯布朗扩散：

$$dX_t = \sigma dW_t.$$

在小区间 Δt 上，增量是高斯的：

$$X_{t+\Delta t} - X_t \sim \mathcal{N}(0, \sigma^2 \Delta t).$$

于是先前位于 y 的粒子在这一短时间步后有一定概率到达 x 附近，而该概率由以 y 为中心的高斯核描述。因此更新后的密度由来自所有邻近先前位置的贡献汇集而成：

$$p(x, t + \Delta t) = \int p(y, t) \frac{1}{\sqrt{2\pi\sigma^2\Delta t}} \exp\left(-\frac{(x-y)^2}{2\sigma^2\Delta t}\right) dy.$$

换言之，短时间后 x 处的密度是 x 附近先前密度的加权平均，权重由短时高斯转移核 (transition kernel) 给出。这是与窄高斯核的卷积。直观上，概率质量从邻近位置扩散进入 x ，同时先前在 x 附近的一部分概率又扩散出去。净效果是密度的平滑与扩散。

为便于分析，设高斯增量记为 η ，其中

$$\eta \sim \mathcal{N}(0, \sigma^2 \Delta t).$$

引入变量替换

$$\eta = x - y, \quad \text{so that} \quad y = x - \eta.$$

于是密度更新可写成

$$p(x, t + \Delta t) = \int p(x - \eta, t) G_{\Delta t}(\eta) d\eta,$$

其中

$$G_{\Delta t}(\eta) = \frac{1}{\sqrt{2\pi\sigma^2\Delta t}} \exp\left(-\frac{\eta^2}{2\sigma^2\Delta t}\right)$$

是增量的高斯密度。由于

$$\int G_{\Delta t}(\eta) d\eta = 1,$$

它也可以看作一个期望：

$$p(x, t + \Delta t) = \mathbb{E}_\eta[p(x - \eta, t)].$$

5.3.2 从布朗扩散到福克-普朗克方程

现在我们用泰勒级数在 x 附近展开 $p(x - \eta, t)$ 。一般地，对充分光滑的一元函数，有 $f(x + h) = \sum_{k=0}^{\infty} \frac{f^{(k)}(x)}{k!} h^k$ 。于是取 $f(\cdot) = p(\cdot, t)$ 、 $h = -\eta$ ，得

$$\begin{aligned} p(x - \eta, t) &= \sum_{k=0}^{\infty} \frac{\partial_x^k p(x, t)}{k!} (-\eta)^k \\ &= p(x, t) - \eta \partial_x p(x, t) + \frac{(-\eta)^2}{2!} \partial_{xx} p(x, t) + \frac{(-\eta)^3}{3!} \partial_{xxx} p(x, t) + \cdots \\ &= p(x, t) - \eta \partial_x p(x, t) + \frac{\eta^2}{2} \partial_{xx} p(x, t) + O(\eta^3). \end{aligned}$$

对 η 取期望，得

$$p(x, t + \Delta t) = \mathbb{E}_\eta[p(x - \eta, t)] = p(x, t) - \mathbb{E}[\eta] \partial_x p(x, t) + \frac{1}{2} \mathbb{E}[\eta^2] \partial_{xx} p(x, t) + \cdots.$$

由于高斯增量均值为零，

$$\mathbb{E}[\eta] = 0,$$

一阶项消失。其方差为

$$\mathbb{E}[\eta^2] = \sigma^2 \Delta t,$$

故二阶项保留：

$$p(x, t + \Delta t) = p(x, t) + \frac{\sigma^2 \Delta t}{2} \partial_{xx} p(x, t) + o(\Delta t).$$

两边减去 $p(x, t)$ ，除以 Δt ，并令 $\Delta t \rightarrow 0$ ，得

$$\partial_t p(x, t) = \frac{\sigma^2}{2} \partial_{xx} p(x, t).$$

于是纯布朗运动给出纯扩散方程。

这是随机扩散在密度层面的标志。与通过确定性传输移动密度的刘维尔方程不同，扩散方程通过空间对密度进行平滑与扩散。

现在假设我们还加入确定性漂移：

$$dX_t = f(X_t, t) dt + \sigma dW_t.$$

在短区间上，粒子经历两种效应：

- 由漂移 f 引起的量级为 Δt 的确定性位移；
- 由布朗项引起的量级为 $\sqrt{\Delta t}$ 的随机高斯位移。

所得的密度演化把确定性刘维尔传输项与上面推导的扩散项结合起来：

$$\partial_t p(x, t) = -\partial_x (f(x, t) p(x, t)) + \frac{\sigma^2}{2} \partial_{xx} p(x, t).$$

这就是扩散系数 σ 为常数时的一维福克-普朗克方程。图 5.3 比较了仅有漂移、仅有扩散以及二者组合之下的密度演化。




图 5.3: **Drift transports probability; diffusion spreads it.** Starting from the same Gaussian density, deterministic contraction moves the mean toward the origin while shrinking the variance, whereas pure Brownian diffusion keeps the mean fixed while increasing the variance. The Ornstein-Uhlenbeck process combines both effects: its mean reverts toward zero while its variance approaches the stationary value $\sigma^2/(2\alpha)$. The curves are exact Gaussian density solutions.

5.3.3 多维形式与解释

在多维中，确定性部分变为

$$-\nabla \cdot (p(x, t)v(x, t)),$$

而扩散项变为

$$\frac{\sigma^2}{2} \Delta p(x, t),$$

其中拉普拉斯算子为

$$\Delta p = \nabla \cdot (\nabla p) = \sum_{i=1}^d \frac{\partial^2 p}{\partial x_i^2}.$$

于是，对各向同性的常数扩散系数 σ ，多维福克-普朗克方程的形式为

$$\partial_t p(x, t) = -\nabla \cdot (p(x, t)v(x, t)) + \frac{\sigma^2}{2} \Delta p(x, t).$$

该方程是连续时间概率建模中最重要的密度演化定律之一。刘维尔方程告诉我们密度在确定性流下如何运动；福克-普朗克方程通过加入随机扩散扩展了这一图景。二者共同提供了从基本连续时间运动通往支撑完全连续扩散模型的密度动力学的主要桥梁。

在下一章中，我们将直接在这一基础上展开。关键的下一步是理解密度演化如何与对数密度的梯度相联系，以及这一视角如何自然地引出基于分数的学习与完全连续的扩散。

总结与参考文献

本章建立了从离散更新走向连续时间生成动力学所需的微积分基础。我们首先通过导数、微分方程、无穷小变化与一阶泰勒近似介绍了连续运动的基本语言。

随后我们研究了三种核心运动模式。确定性收缩展示了微分方程如何确定轨迹：先在一维中，随后通过矩阵与矩阵指数推广到多维。布朗运动通过高斯增量引入了连续时间的随机波动，而 Ornstein-Uhlenbeck 过程则在单一的均值回复系统中结合了漂移与噪声。

本章继而从粒子运动转向密度演化。对确定性流，我们推导了有限时间变量替换公式，然后是刘维尔方程及其沿轨迹的对数密度形式。推广到多维引入了雅可比矩阵、行列式与散度，作为描述局部体积变化与密度流动的关键工具。

最后，我们加入布朗扩散，得到福克-普朗克方程，它把确定性传输与随机扩散结合起来。这为下一章提供了主要桥梁：在下一章中，密度演化将与对数密度梯度、基于分数的学习以及完全连续的扩散模型相联系。

本章内容取材自微积分、微分方程、随机过程与连续时间概率中的标准思想。关于广泛的机器学习背景与概率建模视角，有用的一般性参考包括 Bishop [4] 与 Murphy [27]。关于随机微分方程与布朗运动，标准入门参考是 Øksendal [29]。关于连续性方程、传输及相关偏微分方程视角，一个有用的参考是 Evans [10]。关于福克-普朗克方程与随机扩散，经典参考是 Risken [36]。

第 6 章 6

基于分数的生成建模与连续时间扩散

概览

前面的 DDPM 章节将扩散模型作为一种离散潜变量构造加以介绍：数据被逐步破坏成噪声，而学习得到的反向过程则逐步重建结构。这一观点之所以有力，是因为它把扩散模型与本书此前展开的概率建模思想联系起来，包括潜变量、高斯转移、后验推断以及变分学习。

但扩散模型也容许另一种解释，而这一解释如今已成为现代生成建模的核心。我们可以不只追问如何写出一个反向马尔可夫链，而是提出一个更局部、更几何的问题：若某个样本当前位于 x ，它应当朝哪个方向移动，才能在我们想要从中生成的分布之下变得更加可能？答案由分数函数（score function）给出，即 $\nabla_x \log p(x)$ ，它指向对数密度局部上升最陡的方向。

这一视角的转变意义深远。概率密度描述的是概率质量集中在哪里，而分数描述的则是如何在该密度所定义的空间中移动。它把一个分布变成了一个向量场。一旦这个场已知，它就能引导带噪样本回到高概率区域。从这个意义上说，基于分数的建模把生成建模从显式求值密度的问题，转化为学习该密度局部几何的问题。

这是基于分数的生成建模成为理解扩散模型的重要方式的原因之一。与通过单次直接变换来生成数据的模型不同，现代扩散系统学习如何在许多破坏层级上逐步地或连续地修正噪声。在每个层级上，模型都需要关于“带噪样本应如何被微调才能变得更像数据”的局部信息。分数恰好提供了这种信息。

上一章为这一视角提供了所需的微积分工具。我们研究了粒子在确定性动力学与随机动力学下如何运动，以及整块概率密度如何通过刘维尔（Liouville）方程和福克-普朗克（Fokker-Planck）方程演化。本章将运用这些工具，说明分数场、随机采样与密度演化如何在基于分数的扩散中融为一体。


本章的目标并非取代 DDPM 的观点，而是对其加以补充。DDPM 展示了扩散如何被组织成一个离散潜变量模型；基于分数的观点则说明了为什么去噪还可以从几何与动力学的角度来理解：生成由一条带噪分布路径上学到的局部方向所引导，把样本从随机性逐步带回结构。

概念图谱

本章展开扩散模型的基于分数的解释：从局部密度几何，到分数学习，到多尺度去噪，最终到连续时间的反向扩散。

- 我们从分数函数开始。分数 $\nabla_x \log p(x)$ 被解释为一个局部的概率方向场。它指向对数密度上升最陡的区域。
- 我们通过朗之万动力学把分数与采样联系起来。确定性的分数流把样本移向高密度区域，而布朗噪声则防止坍缩并支持探索。福克-普朗克方程说明了为什么目标密度在这种“分数加噪声”的动力学下是平稳的。
- 我们接着追问：分数如何才能学到？Fisher 散度让学习到的分数 $s_\theta(x)$ 去匹配真实的数据分数，为此提供了一个自然的目标函数。分数匹配利用分部积分改写这一目标，免去了对未知数据密度的求值。
- 我们通过去噪来稳定分数学习。我们不直接学习原始数据分数，而是添加高斯噪声，学习平滑分布 p_σ 的分数。这把分数估计变成了针对去噪方向的回归问题。
- 我们从单一噪声层级走向多个层级。大的噪声层级揭示粗糙的全局结构，小的噪声层级揭示精细的局部细节。因此，多尺度分数学习要学习的是一族跨越不同平滑尺度的分数场。
- 我们把多尺度分数与扩散联系起来。当带噪分布被组织成单一前向加噪过程的边缘分布时，一族带噪分数场就构成了扩散模型。在连续时间下，这给出一条密度路径 $p_t(x)$, $0 \leq t \leq T$ 。
- 我们用分数实现扩散的反向。前向过程把数据带向噪声。反向时间动力学把时间相关的分数 $\nabla_x \log p_t(x)$ 用作局部修正，引导样本从噪声回到数据。
- 我们最后回溯到 DDPM。DDPM 此前被介绍为离散潜变量模型。这里我们把它们的噪声预测目标重新解读为携带关于中间带噪分布的类分数信息，说明 DDPM 观点与基于分数的观点是互补的。

本章基于分数的建模主干路径总结如下图所示。



6.1 从分数函数到朗之万采样

上一章解释了概率密度在确定性输运与随机扩散下如何演化。我们看到，常微分方程诱导刘维尔型的密度演化，而带布朗噪声的随机微分方程则导出福克-普朗克方程。这些结果之所以重要，是因为它们把讨论从单个粒子的运动推进到整个分布的演化。

接下来一个自然的问题是：在所有可能的密度演化中，哪些才真正对生成建模有用？在生成建模中，我们寻求的不是任意的运动，而是一种其行为与感兴趣的概率密度——通常是数据分布或其适当平滑后的版本——相联系的动力学。分数函数正是在这里登场。

分数提供了一个局部的概率方向场；与噪声结合后，它引出朗之万动力学，这是密度建模与采样之间最重要的桥梁之一。本节将细致地介绍这座桥梁。我们首先把分数解释为一个概率漂移场，然后说明噪声如何通过朗之万动力学被加入，最后借助平稳性的概念解释为什么所得动力学与一个目标密度联系在一起。

因此，本节的目的尚不是以完整形态介绍现代扩散模型，而是确立一个更简单也更根本的原理：如果目标密度的分数可得，那么它就可以作为一个随机动力学的漂移场，而该动力学的平稳分布正是目标本身。这一思想提供了从描述目标密度到构造能从中生成样本的动力学之间的主要概念桥梁之一。

6.1.1 作为概率漂移场的分数函数

设 $p(x)$ 为 $\mathbb{R}^d$ 上的概率密度。其分数函数定义为

$$s(x) = \nabla_x \log p(x).$$

若该密度还依赖于时间，则时间相关的分数写作

$$s(x, t) = \nabla_x \log p(x, t).$$

乍看之下，对数密度的梯度竟如此重要，可能令人略感意外。原因在于，分数以一种特别有用的形式捕捉了局部方向信息。密度 $p(x)$ 告诉我们在 x 附近集中了多少概率质量，而分数告诉我们对数密度朝哪个方向增长最快。因此，它提供了一个指向更高概率区域的局部向量场。

在一维情形，分数变为

$$s(x) = \frac{d}{dx} \log p(x) = \frac{p'(x)}{p(x)}.$$

这个表达式已经很说明问题。分子 $p'(x)$ 度量密度的局部变化，而除以 $p(x)$ 则把这一变化相对密度本身的局部尺度加以归一化。因此，分数度量的是相对斜率而非单纯的绝对斜率。这使它作为一个概率运动场更有意义。

一个简单的高斯例子可以把这一解释具体化。考虑一维高斯密度

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

取对数得

$$\log p(x) = -\frac{(x-\mu)^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2).$$

对 x 求导，我们得到

$$\frac{d}{dx} \log p(x) = -\frac{x - \mu}{\sigma^2}.$$

于是分数为

$$s(x) = -\frac{x - \mu}{\sigma^2}.$$

这个高斯例子立刻展示了分数的几何含义。若 $x > \mu$ ，则分数为负，指向均值；若 $x < \mu$ ，则分数为正，同样指向均值。 x 离均值越远，分数的模越大。因此，对高斯密度而言，分数表现得像一个回复场，把粒子引向高密度区域。

在多元高斯情形，

$$p(x) = \mathcal{N}(\mu, \Sigma),$$

分数变为

$$\nabla_x \log p(x) = -\Sigma^{-1}(x - \mu).$$

同样，分数是一个指向高密度中心的向量场，但此时其形状由协方差结构决定。方差较小的方向产生较强的回复力，方差较大的方向产生较弱的回复力。图 6.1 展示了同一思想如何推广到单一高斯之外：对多峰密度，分数变成一个空间上变化的场，其局部方向取决于周围的密度几何。




图 6.1: **The score turns a multimodal density into a local direction field.** The left panel shows density contours for an exact two-component Gaussian mixture, while the right shows the corresponding score directions $\nabla_x \log p(x)$. The arrows point toward increasing log-density and bend toward the locally more influential mode. Arrow lengths are normalised for legibility, so the figure emphasises direction rather than magnitude.

这提示了一个自然的想法。如果我们用

$$\frac{dx}{dt} = \nabla_x \log p(x),$$

定义一个确定性流，那么粒子将朝对数密度上升最陡的方向移动。由于对数函数单调，这也会把粒子移向密度更高的区域。在这个意义上，分数可以被解释为一个概率漂移场：如果我们希望把粒子引向目标分布下更可能的区域，它就告诉我们应当如何移动。

这一视角极为有用，但也揭示了一个重要局限。纯确定性的分数流倾向于把粒子推向众数。因此，它可能使轨迹坍缩进局部集中的高密度区域，而不是探索整个目标分布。这对优化有用，但对采样来说还不够。要获得真正的采样动力学，必须加入噪声。这就直接引出了朗之万动力学。

6.1.2 朗之万动力学：分数加噪声

朗之万动力学组合两个要素：

1. 由分数给出的漂移项，把粒子拉向更高密度的区域；
2. 布朗噪声项，注入随机性并维持探索。

在连续时间下，朗之万随机微分方程形如

$$dX_t = \nabla_x \log p^*(X_t) dt + \sqrt{2} dW_t,$$

其中 $p^*(x)$ 表示感兴趣的目标密度。这里采用记号 p^* ，是为了强调这正是我们希望从中采样的那个密度。

在离散时间下，这启发式地对应于更新

$$x_{k+1} = x_k + \epsilon \nabla_x \log p^*(x_k) + \sqrt{2\epsilon} \xi_k, \quad \xi_k \sim \mathcal{N}(0, I),$$

其中 $\epsilon > 0$ 是一个小步长。

这一更新有直观的解读。当前状态 x_k 首先被分数项

$$\epsilon \nabla_x \log p^*(x_k),$$

移动，该分数项把粒子推向目标密度下概率更大的区域。然后加入高斯扰动

$$\sqrt{2\epsilon} \xi_k$$

这个随机项防止粒子简单坍缩到某个众数，并允许粒子继续探索状态空间。在连续时间极限下，确定性的分数漂移与布朗扰动合并成上面的朗之万 SDE。

这个结构应与上一章的内容似曾相识。朗之万动力学是一个“漂移加噪声”系统，因此其密度按照福克-普朗克方程演化。对朗之万动力学

$$dX_t = \nabla_x \log p^*(X_t) dt + \sqrt{2} dW_t,$$

漂移场为

$$v(x) = \nabla_x \log p^*(x),$$

而扩散系数为 $\sigma = \sqrt{2}$ 。由于常数各向同性扩散下的福克-普朗克方程是

$$\partial_t p(x, t) = -\nabla \cdot (p(x, t) v(x, t)) + \frac{\sigma^2}{2} \Delta p(x, t),$$

代入 $v(x) = \nabla_x \log p^*(x)$ 与 $\sigma^2 = 2$, 得

$$\partial_t p(x, t) = -\nabla \cdot (p(x, t) \nabla_x \log p^*(x)) + \Delta p(x, t).$$

这个方程结合了两种效应。第一项 $-\nabla \cdot (p \nabla_x \log p^*)$, 描述由分数场诱导的确定性输运。第二项 Δp , 描述布朗噪声引起的扩散。漂移项倾向于把概率集中到目标的高密度区域, 而扩散项倾向于把概率向外铺展。重要的事实是: 恰在这一组合下, 目标密度成为平稳的。这正是朗之万动力学能用作采样机制的关键原因。

把它与前面介绍的 Ornstein–Uhlenbeck 过程相对照也颇有启发。OU 过程具有指向原点的线性漂移和一个高斯平稳分布。朗之万动力学推广了同一原理: 它不使用固定的线性回复力, 而是使用所选目标密度的分数作为回复场。在这个意义上, OU 过程可以被视为更一般的基于分数的采样机制的一个高斯特例。

为了显式地看到这一点, 设目标密度为标准高斯 $p^*(x) = \mathcal{N}(0, I)$ 。那么

$$\nabla_x \log p^*(x) = -x,$$

朗之万动力学变为

$$dX_t = -X_t dt + \sqrt{2} dW_t,$$

这正是一个具有特定噪声尺度的 Ornstein–Uhlenbeck 过程。因此, 当目标密度为高斯时, 朗之万方程恢复出 OU 过程; 而通过分数 $\nabla_x \log p^*(x)$, 它又被推广到非高斯目标。

6.1.3 目标分布与平稳分布

我们现在解释为什么朗之万动力学不只是一个形式化的方程, 而是一种有意义的采样机制。

设密度 $p(x, t)$ 按照某个密度演化方程

$$\partial_t p(x, t) = \mathcal{L}[p(x, t)].$$

演化。若系统一旦拥有密度 p^* 便保持在那里, 则称密度 $p^*(x)$ 为一个平稳分布 (stationary distribution)。用偏微分方程的语言来说, 这意味着

$$\mathcal{L}[p^*(x)] = 0.$$

等价地,

$$\partial_t p(x, t) = 0 \quad \text{when} \quad p(x, t) = p^*(x).$$

这一概念在生成建模中很重要。如果目标密度对某个动力学是平稳的, 那么该动力学就与该目标分布对齐。此外, 如果从别处出发的轨迹或密度随时间趋近这一平稳律, 那么该过程就成为从目标分布采样的机制。完整的收敛理论需要附加假设, 超出了本教程的范围, 但平稳性计算已经揭示了核心思想。

现在为朗之万动力学验证平稳性。回忆其福克–普朗克方程为

$$\partial_t p(x, t) = -\nabla \cdot (p(x, t) \nabla_x \log p^*(x)) + \Delta p(x, t).$$

我们代入

$$p(x, t) = p^*(x).$$

于是右端变为

$$-\nabla \cdot (p^*(x) \nabla_x \log p^*(x)) + \Delta p^*(x).$$

现在利用恒等式

$$p^*(x) \nabla_x \log p^*(x) = \nabla_x p^*(x),$$

因为

$$\nabla_x \log p^*(x) = \frac{\nabla_x p^*(x)}{p^*(x)}.$$

因此前面的表达式化简为

$$-\nabla \cdot (\nabla_x p^*(x)) + \Delta p^*(x).$$

但按定义，

$$\nabla \cdot (\nabla_x p^*) = \Delta p^*.$$

故

$$-\Delta p^*(x) + \Delta p^*(x) = 0.$$

所以确实有

$$\partial_t p(x, t) = 0 \quad \text{when} \quad p(x, t) = p^*(x).$$

因此 p^* 是朗之万动力学

$$dX_t = \nabla_x \log p^*(X_t) dt + \sqrt{2} dW_t.$$

的平稳分布。

这是基于分数的生成建模背后的核心概念结果之一。它表明，若把目标密度的分数用作漂移场，并与适当的布朗噪声相结合，那么所得的密度演化会保持该目标密度。因此，分数不仅仅是密度的一个有趣的导数；它恰恰是使期望密度在一种自然的随机动力学下保持平稳的漂移场。

同时，准确说明所证明的内容也很重要。上面的论证确立的是平稳性，而不是每个初始密度都收敛到 p^* 的完整证明。后者是涉及随机过程长时间行为的更深的问题。尽管如此，平稳性结果弥合了一个重要的概念缺口：它解释了为什么基于分数的漂移加上布朗噪声，为从感兴趣的分布中采样提供了一条有原则的途径。

如果在合适的条件下让朗之万过程演化足够长时间，其分布可能趋近平稳律 p^* 。在密度层面，这意味着概率质量逐渐呈现期望目标分布的形状；在粒子层面，这意味着通过朗之万动力学反复更新样本，可以产生统计行为类似于目标律抽样结果的粒子。

因此，密度层面与粒子层面的观点彼此一致。福克-普朗克方程解释分布如何演化，朗之万更新解释单个样本如何移动。分数把二者联系起来：它在局部充当概率漂移场，在整体上则是使目标密度平稳的那个要素。

6.2 学习分数：Fisher 散度与分数匹配

上一节说明了为什么分数函数对采样如此重要。如果目标密度 $p^*(x)$ 的分数可得，那么它可以作为朗之万动力学

$$dX_t = \nabla_x \log p^*(X_t) dt + \sqrt{2} dW_t,$$

的漂移场，其平稳分布为 p^* 。这在概率密度与随机采样动力学之间建立了一条有原则的联系。

然而在生成建模中，目标密度通常没有闭式表达。我们拥有的是来自某个未知数据生成分布的样本，而不是密度本身。把这个未知分布记为 $p_{\text{data}}(x)$ 。于是核心的学习问题便是逼近它的分数

$$s_{\text{data}}(x) = \nabla_x \log p_{\text{data}}(x).$$

如果能从数据中学到这个向量场，我们就可以把它用于朗之万型的采样动力学。

我们用一个参数化函数 $s_{\theta}(x)$ 来建模分数，通常是以 θ 为参数的神经网络。一个自然的目标是最小化在数据分布下学习分数与真实数据分数之间的偏差。这就引出 *Fisher* 散度：

$$\mathcal{J}(\theta) = \mathbb{E}_{x \sim p_{\text{data}}} [\|s_{\theta}(x) - s_{\text{data}}(x)\|_2^2].$$

等价地，学习问题即 $\min_{\theta} \mathcal{J}(\theta)$ 。这里散度定义在向量场之间，而优化则针对参数 θ 进行。若 $\mathcal{J}(\theta) = 0$ ，则

$$s_{\theta}(x) = s_{\text{data}}(x)$$

在 p_{data} 下几乎处处成立。此时，学到的向量场与数据分布的局部几何相匹配。

然而这里有一个直接的困难。该目标似乎需要真实分数 $s_{\text{data}}(x)$ ，而它依赖于未知密度 $p_{\text{data}}(x)$ 。分数匹配 [19] 通过改写目标、使未知分数不再显式出现，解决了这一困难。

6.2.1 展开 Fisher 散度

我们首先展开平方范数：

$$\begin{aligned} \mathcal{J}(\theta) &= \mathbb{E}_{p_{\text{data}}} \left[(s_{\theta}(x) - s_{\text{data}}(x))^{\top} (s_{\theta}(x) - s_{\text{data}}(x)) \right] \\ &= \mathbb{E}_{p_{\text{data}}} [\|s_{\theta}(x)\|_2^2 - 2s_{\theta}(x)^{\top} s_{\text{data}}(x) + \|s_{\text{data}}(x)\|_2^2]. \end{aligned}$$

最后一项

$$\mathbb{E}_{p_{\text{data}}} [\|s_{\text{data}}(x)\|_2^2],$$

不依赖于 θ ，因而不影响优化。于是最小化 $\mathcal{J}(\theta)$ 等价于最小化

$$\tilde{\mathcal{J}}(\theta) = \mathbb{E}_{p_{\text{data}}} [\|s_{\theta}(x)\|_2^2] - 2\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^{\top} s_{\text{data}}(x)].$$

第一项可以直接由样本计算，因为它只需在数据点上求值模型 $s_{\theta}(x)$ 。困难在于交叉项

$$\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^{\top} s_{\text{data}}(x)],$$

因为它仍然涉及未知的真实分数。

分数匹配的关键思想是利用分部积分改写这个交叉项。我们先在一维情形仔细地做这件事，因为此时计算最为透明，然后再把结果推广到多维。

6.2.2 一维情形

为了突出主要思想，考虑一维场景，其真实数据分数为

$$s_{\text{data}}(x) = \frac{d}{dx} \log p_{\text{data}}(x) = \frac{1}{p_{\text{data}}(x)} \frac{d}{dx} p_{\text{data}}(x).$$

把它代入交叉项得

$$\begin{aligned} \mathbb{E}_{p_{\text{data}}} [s_{\theta}(x) s_{\text{data}}(x)] &= \int s_{\theta}(x) \frac{d}{dx} \log p_{\text{data}}(x) p_{\text{data}}(x) dx \\ &= \int s_{\theta}(x) \frac{1}{p_{\text{data}}(x)} \frac{d}{dx} p_{\text{data}}(x) p_{\text{data}}(x) dx \\ &= \int s_{\theta}(x) \frac{d}{dx} p_{\text{data}}(x) dx. \end{aligned}$$

到这一步，导数作用在未知密度 $p_{\text{data}}(x)$ 上。我们的目标是利用分部积分，把这个导数转移到模型 $s_{\theta}(x)$ 上。

一维分部积分

乘积法则表明

$$\frac{d}{dx} (u(x)v(x)) = u'(x)v(x) + u(x)v'(x).$$

两边积分得

$$\int u(x)v'(x) dx = [u(x)v(x)]_{-\infty}^{\infty} - \int u'(x)v(x) dx.$$

这个恒等式把导数从 v 转移到 u ，代价是一个边界项。

我们通过选择

$$u(x) = s_{\theta}(x), \quad v'(x) = \frac{d}{dx} p_{\text{data}}(x), \quad v(x) = p_{\text{data}}(x).$$

来应用这一恒等式。于是

$$\int s_{\theta}(x) \frac{d}{dx} p_{\text{data}}(x) dx = [s_{\theta}(x)p_{\text{data}}(x)]_{-\infty}^{\infty} - \int \frac{d}{dx} s_{\theta}(x) p_{\text{data}}(x) dx.$$

在 $p_{\text{data}}(x)$ 随 $|x| \rightarrow \infty$ 足够快衰减、且 $s_{\theta}(x)$ 增长不太快的标准假设下，乘积 $s_{\theta}(x)p_{\text{data}}(x)$ 在边界处消失，因此边界贡献为零。于是我们得到

$$\int s_{\theta}(x) \frac{d}{dx} p_{\text{data}}(x) dx = - \int \frac{d}{dx} s_{\theta}(x) p_{\text{data}}(x) dx.$$

把右端识别为 p_{data} 下的期望，我们得出

$$\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x) s_{\text{data}}(x)] = - \mathbb{E}_{p_{\text{data}}} \left[\frac{d}{dx} s_{\theta}(x) \right].$$

导数就这样从未知密度 $p_{\text{data}}(x)$ 转移到了模型 $s_{\theta}(x)$ 上，不再需要对真实数据分数的显式了解。把这个结果代入化简后的 Fisher 散度，得

$$\begin{aligned}\tilde{\mathcal{J}}(\theta) &= \mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^2] - 2\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)s_{\text{data}}(x)] \\ &= \mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^2] + 2\mathbb{E}_{p_{\text{data}}} \left[\frac{d}{dx} s_{\theta}(x) \right].\end{aligned}$$

由于目标函数乘以一个正常数不改变其最小化子，通常把一维分数匹配目标写成

$$\mathcal{L}_{\text{SM}}(\theta) = \mathbb{E}_{p_{\text{data}}} \left[\frac{1}{2} s_{\theta}(x)^2 + \frac{d}{dx} s_{\theta}(x) \right].$$

6.2.3 推广到多维

我们现在把同一论证推广到一般情形 $x \in \mathbb{R}^d$ 。真实数据分数为

$$s_{\text{data}}(x) = \nabla_x \log p_{\text{data}}(x),$$

Fisher 散度中的交叉项变为

$$\begin{aligned}\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^{\top} s_{\text{data}}(x)] &= \int s_{\theta}(x)^{\top} \nabla_x \log p_{\text{data}}(x) p_{\text{data}}(x) dx \\ &= \int s_{\theta}(x)^{\top} \nabla_x p_{\text{data}}(x) dx.\end{aligned}$$

一维中由普通导数扮演的角色，现在由散度来扮演。对向量场

$$v(x) = \begin{bmatrix} v_1(x) \\ \vdots \\ v_d(x) \end{bmatrix},$$

散度为

$$\nabla_x \cdot v(x) = \sum_{i=1}^d \frac{\partial v_i(x)}{\partial x_i}.$$

正如上一章所介绍的，散度度量向量场的局部净外流。它在这里出现，是因为模型分数 $s_{\theta}(x)$ 本身就是一个向量场。

分部积分的多维类似物来自散度定理。相关的乘积法则是

$$\nabla_x \cdot (p_{\text{data}}(x) s_{\theta}(x)) = s_{\theta}(x)^{\top} \nabla_x p_{\text{data}}(x) + p_{\text{data}}(x) \nabla_x \cdot s_{\theta}(x).$$

移项得

$$s_{\theta}(x)^{\top} \nabla_x p_{\text{data}}(x) = \nabla_x \cdot (p_{\text{data}}(x) s_{\theta}(x)) - p_{\text{data}}(x) \nabla_x \cdot s_{\theta}(x).$$

在 $\mathbb{R}^d$ 上积分，并假设适当的边界条件使散度项不产生边界通量，我们得到

$$\int s_{\theta}(x)^{\top} \nabla_x p_{\text{data}}(x) dx = - \int p_{\text{data}}(x) \nabla_x \cdot s_{\theta}(x) dx.$$

因此，

$$\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x)^{\top} s_{\text{data}}(x)] = -\mathbb{E}_{p_{\text{data}}} [\nabla_x \cdot s_{\theta}(x)].$$

这是一维结果

$$\mathbb{E}_{p_{\text{data}}} [s_{\theta}(x) s_{\text{data}}(x)] = -\mathbb{E}_{p_{\text{data}}} \left[\frac{d}{dx} s_{\theta}(x) \right].$$

在多维下的直接对应。唯一结构性变化是：标量分数的导数被向量值分数场的散度所取代。把交叉项恒等式代入化简后的 Fisher 散度，得

$$\tilde{\mathcal{J}}(\theta) = \mathbb{E}_{p_{\text{data}}} [\|s_{\theta}(x)\|_2^2 + 2\nabla_x \cdot s_{\theta}(x)].$$

等价地，乘以 1/2 后，一般的分数匹配目标为

$$\mathcal{L}_{\text{SM}}(\theta) = \mathbb{E}_{p_{\text{data}}} \left[\frac{1}{2} \|s_{\theta}(x)\|_2^2 + \nabla_x \cdot s_{\theta}(x) \right].$$

这就是经典的分数匹配目标函数。它由学习分数与真实数据分数之间的 Fisher 散度导出，但最终表达式不再显式包含 $s_{\text{data}}(x)$ 。一旦 $s_{\theta}(x)$ 逼近 $s_{\text{data}}(x)$ ，就可以把它插入前面介绍的朗之万动力学。在适当条件下，这个学到的动力学便可以用来生成分布近似数据分布的样本。

6.3 稳定学习：通过加噪实现的去噪分数匹配

上一节导出了分数匹配目标函数，它使分数函数 $s_{\theta}(x)$ 可以在不显式了解数据密度的情况下从数据中学得。虽然理论上优雅，直接分数匹配在高维生成建模中可能难以应用。

核心困难源于真实数据分布的几何。经验数据往往集中在高维空间中嵌入的低维流形上或其附近。因此，数据密度可能在数据支撑集之外急剧集中、不规则或性质恶劣。直接学习这种分布的分数可能不稳定，因为由此诱导的向量场在数据覆盖很少或没有覆盖的区域可能表现紊乱。

一个自然的补救办法是引入噪声。高斯加噪把经验分布或急剧集中的数据分布变成一个分数场性质好得多的平滑分布。我们不直接学习原始数据分布的分数，而是学习其带噪版本的分数。这一思想是去噪分数匹配 [43] 的基础。

6.3.1 高斯加噪与平滑分数

我们首先用加性高斯噪声扰动数据。给定干净样本

$$x \sim p_{\text{data}}(x),$$

我们构造带噪观测

$$\tilde{x} = x + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I).$$

等价地，给定干净样本时带噪样本的条件分布为

$$p(\tilde{x} | x) = \mathcal{N}(\tilde{x}; x, \sigma^2 I).$$

$\tilde{x}$ 的边缘分布由对干净变量 x 积分得到：

$$p_{\sigma}(\tilde{x}) = \int p_{\text{data}}(x)p(\tilde{x} | x) dx.$$

这是原始数据分布与高斯核的卷积。其效果是平滑化：概率质量被铺展到邻近区域，尖锐结构被软化，而先前密度可忽略的区域在受扰分布下可能获得非零概率。

我们现在不再学习原始数据分布的分数，而是以学习这个平滑密度的分数为目标：

$$s_{\sigma}(\tilde{x}) = \nabla_{\tilde{x}} \log p_{\sigma}(\tilde{x}).$$

接下来考察这个带噪分数的结构。由对数梯度恒等式，

$$\nabla_{\tilde{x}} \log p_{\sigma}(\tilde{x}) = \frac{1}{p_{\sigma}(\tilde{x})} \nabla_{\tilde{x}} p_{\sigma}(\tilde{x}).$$

平滑密度的梯度为

$$\begin{aligned} \nabla_{\tilde{x}} p_{\sigma}(\tilde{x}) &= \nabla_{\tilde{x}} \int p_{\text{data}}(x)p(\tilde{x} | x) dx \\ &= \int p_{\text{data}}(x) \nabla_{\tilde{x}} p(\tilde{x} | x) dx, \end{aligned}$$

其中在标准正则条件下我们在积分号下求导。因此，

$$s_{\sigma}(\tilde{x}) = \frac{\int p_{\text{data}}(x) \nabla_{\tilde{x}} p(\tilde{x} | x) dx}{\int p_{\text{data}}(x) p(\tilde{x} | x) dx}.$$

这个表达式有一个有用的概率解释。由贝叶斯法则，给定带噪观测时干净变量的后验分布为

$$p(x | \tilde{x}) = \frac{p_{\text{data}}(x)p(\tilde{x} | x)}{p_{\sigma}(\tilde{x})}.$$

利用这个后验，带噪分数可以写成

$$s_{\sigma}(\tilde{x}) = \int p(x | \tilde{x}) \nabla_{\tilde{x}} \log p(\tilde{x} | x) dx,$$

或等价地，

$$s_{\sigma}(\tilde{x}) = \mathbb{E}_{x \sim p(x|\tilde{x})} [\nabla_{\tilde{x}} \log p(\tilde{x} | x)].$$

对高斯加噪，

$$p(\tilde{x} | x) = \mathcal{N}(\tilde{x}; x, \sigma^2 I).$$

其对数（略去与 $\tilde{x}$ 无关的常数）为

$$\log p(\tilde{x} | x) = -\frac{1}{2\sigma^2} \|\tilde{x} - x\|_2^2 + \text{constant}.$$

于是

$$\nabla_{\tilde{x}} \log p(\tilde{x} | x) = -\frac{1}{\sigma^2}(\tilde{x} - x) = \frac{1}{\sigma^2}(x - \tilde{x}).$$

把它代入条件期望，得

$$s_{\sigma}(\tilde{x}) = \frac{1}{\sigma^2} \mathbb{E}_{x \sim p(x|\tilde{x})} [x - \tilde{x}].$$

这个恒等式给出了平滑分数的一个直观解释。在带噪点 $\tilde{x}$ 处，分数指向可能产生该点的条件平均干净点。换句话说，带噪分数给出一个局部的去噪方向：它告诉我们平均而言应如何移动 $\tilde{x}$ ，才能回到数据分布。

6.3.2 带噪分数的不可处理性

上面的恒等式在概念上非常有用，但它尚未给出一个可直接计算的训练目标。前向加噪过程很简单：我们可以采样

$$x \sim p_{\text{data}}(x), \quad \tilde{x} = x + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I).$$

因此生成样本对 $(x, \tilde{x})$ 毫无困难。

问题在于，带噪分数涉及后验分布 $p(x | \tilde{x})$ 下的期望：

$$s_{\sigma}(\tilde{x}) = \frac{1}{\sigma^2} \mathbb{E}_{x \sim p(x|\tilde{x})} [x - \tilde{x}].$$

由贝叶斯法则，

$$p(x | \tilde{x}) = \frac{p(\tilde{x} | x) p_{\text{data}}(x)}{p_{\sigma}(\tilde{x})},$$

其中

$$p_{\sigma}(\tilde{x}) = \int p_{\text{data}}(x) p(\tilde{x} | x) dx.$$

尽管似然 $p(\tilde{x} | x)$ 已知，数据分布 $p_{\text{data}}(x)$ 却没有闭式表达。我们只有来自它的样本。因此边缘密度 $p_{\sigma}(\tilde{x})$ 与后验 $p(x | \tilde{x})$ 都无法直接得到。

这使我们无法直接最小化带噪 Fisher 散度

$$\mathbb{E}_{\tilde{x} \sim p_{\sigma}} [\|s_{\theta}(\tilde{x}) - s_{\sigma}(\tilde{x})\|_2^2],$$

因为求值这一目标需要显式访问真实带噪分数 $s_{\sigma}(\tilde{x})$ 。于是，尽管前向加噪过程是可处理的，对应的分数在闭式意义下仍然不可得。

我们因此面对一个熟悉的局面：我们有一个定义明确的分数估计问题，但其目标无法直接计算。关键在于，已知的加噪过程能否被用来避免求值后验。

6.3.3 作为回归问题的去噪分数匹配

关键的观察是：加噪过程定义了 $(x, \tilde{x})$ 上一个可处理的联合分布：

$$p_{\text{data}}(x) p(\tilde{x} | x).$$

我们也许不显式知道边缘密度 $p_{\sigma}(\tilde{x})$ 或后验 $p(x | \tilde{x})$ ，但我们可以精确地从该联合分布采样：抽取一个干净数据点 x ，加入高斯噪声，便得到 $\tilde{x}$ 。

去噪分数匹配通过最小二乘回归的一个基本性质来利用这一联合采样过程。

最小二乘回归恒等式

对随机变量 (U, Y) ，最小化

$$\mathbb{E} [\|f(U) - Y\|_2^2]$$

的函数为

$$f^*(U) = \mathbb{E}[Y | U].$$

因此，在平方误差损失下，最好的预测是给定输入时目标变量的条件均值。

我们现在把这个恒等式应用于去噪场景。令输入变量为带噪观测

$$U = \tilde{x},$$

回归目标为缩放残差

$$Y = \frac{1}{\sigma^2}(x - \tilde{x}).$$

现在考虑目标函数

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{x \sim p_{\text{data}}, \tilde{x} \sim p(\tilde{x}|x)} \left[\left\| s_{\theta}(\tilde{x}) - \frac{1}{\sigma^2}(x - \tilde{x}) \right\|_2^2 \right].$$

由最小二乘回归恒等式，最优函数满足

$$s_{\theta}^*(\tilde{x}) = \mathbb{E} \left[\frac{1}{\sigma^2}(x - \tilde{x}) \mid \tilde{x} \right].$$

而这个条件期望恰是前面导出的带噪分数：

$$s_{\sigma}(\tilde{x}) = \frac{1}{\sigma^2} \mathbb{E} [x - \tilde{x} \mid \tilde{x}].$$

因此，

$$s_{\theta}^*(\tilde{x}) = s_{\sigma}(\tilde{x}).$$

这就是去噪分数匹配的核心洞见。单个训练样本对提供可处理的条件目标，而平方误差回归在给定 $\tilde{x}$ 的条件下对这些目标取平均，恢复出平滑密度的分数。图 6.2 把这种平均的几何显式地呈现出来。




图 6.2: **Denoising score matching as least-squares regression.** In this finite illustration, the thin arrows show the tractable conditional targets $(x - \tilde{x})/\sigma^2$ for possible clean points, with visual strength reflecting their posterior responsibility. Their posterior-weighted average, shown by the thick arrow, terminates at $\mathbb{E}[x | \tilde{x}]$ and equals the marginal score $\nabla_{\tilde{x}} \log p_\sigma(\tilde{x})$. Thus squared-error regression recovers the noisy-distribution score from individual denoising targets.

等价地，由于

$$\tilde{x} = x + \varepsilon,$$

我们有

$$x - \tilde{x} = -\varepsilon.$$

于是去噪分数匹配目标也可以写成

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{x \sim p_{\text{data}}, \varepsilon \sim \mathcal{N}(0, \sigma^2 I)} \left[\left\| s_\theta(x + \varepsilon) + \frac{\varepsilon}{\sigma^2} \right\|_2^2 \right].$$

这个形式使学习目标尤其具体：模型被训练去预测负的噪声方向，并按 $1/\sigma^2$ 缩放。

因此，去噪分数匹配把一个不可处理的分数估计问题，替换为一个完全通过已知加噪过程定义的监督回归问题。该目标只依赖干净数据样本与高斯噪声，不要求值 $p_{\text{data}}(x)$ 、 $p_\sigma(\tilde{x})$ 或后验 $p(x | \tilde{x})$ 。

值得注意的是，对固定的 σ ，模型学到的是受扰密度 p_σ 的分数，而不是 p_{data} 的分数本身。因此，噪声层级控制了所学几何所属的分布。然而，在单一噪声层级上学习分数引出下一个问题：噪声尺度 σ 应当如何选择？

6.4 从多尺度分数学习到连续时间扩散

到目前为止，本章自底向上地展开基于分数的生成建模。我们首先把分数介绍为一个概率漂移场，然后说明朗之万动力学如何利用分数进行采样，接着导出分数匹配与去噪分数匹配这两种从数据中学习分数场的方法。

现在我们完成最后一步概念跃迁：从在单一噪声层级上学习分数，转向在一整条带噪声布路径上学习分数——这一多尺度视角在现代基于分数的生成建模 [38, 39] 中占据了核心地位。正是在这里，基于分数的学习开始与扩散模型直接对接。

这一衔接需要被仔细理解。在之前的 DDPM 章节中，我们从离散潜变量的视角介绍了扩散模型：一条前向加噪马尔可夫链、一条学习得到的反向链，以及一个变分训练目标。这里我们从另一个方向逼近同一宽泛的思想。从分数学习出发，我们追问：一族带噪分数场如何被用来把样本从噪声移回数据？这首先引出多尺度去噪分数匹配，接着引出退火朗之万动力学，最终引出连续时间扩散过程。

因此，本节并不重复 DDPM 的推导，而是说明基于分数的视角如何给出一条通往扩散的连续时间路径：

single noisy score $\rightarrow$ many noisy scores
 $\rightarrow$ annealed reverse sampling $\rightarrow$ continuous-time score-guided diffusion.

6.4.1 多尺度去噪分数匹配

上一节表明，对固定的噪声层级 σ ，去噪分数匹配学到的是平滑数据分布 p_σ 的分数。我们用

$$\tilde{x} = x + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I),$$

破坏数据，并训练

$$s_\theta(\tilde{x}, \sigma) \approx \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}).$$

对应的去噪目标是

$$\frac{1}{\sigma^2}(x - \tilde{x}) = -\frac{\varepsilon}{\sigma^2}.$$

然而，单一噪声层级只给出数据分布的一个平滑视图。若 σ 很大，密度平滑，分数场提供朝向数据大区域的稳定全局引导，但精细细节被抹去。若 σ 很小，密度更接近原始数据分布，分数场捕捉更锐利的局部细节，但在数据支撑集之外可能难以可靠估计。因此，单一噪声层级无法同时提供稳健的全局引导与精确的局部修正。

图 6.3 针对同一多峰密度在三个高斯平滑尺度下展示了这一效应：大噪声揭示粗糙的全局几何，小噪声恢复更锐利的局部结构。




图 6.3: **Different noise levels define different score fields.** The same two-component distribution is smoothed with Gaussian noise at three scales. Large noise reveals coarse global geometry, while decreasing the noise level exposes separate modes and sharper local structure. Multi-scale score models therefore condition on the noise level rather than sharing one score field across all scales. Arrow lengths are normalised for legibility.

这提示我们，噪声尺度不应一劳永逸地选定。相反，我们应当在一系列噪声层级上学得一族分数场。

设

$$\sigma_1 > \sigma_2 > \cdots > \sigma_K > 0$$

为一个递减的噪声尺度序列。对每个 σ_k ，定义受扰密度

$$p_{\sigma_k}(\tilde{x}) = \int p_{\text{data}}(x) \mathcal{N}(\tilde{x}; x, \sigma_k^2 I) dx.$$

我们不再学习单个分数场，而是训练一个噪声条件模型

$$s_{\theta}(\tilde{x}, \sigma_k) \approx \nabla_{\tilde{x}} \log p_{\sigma_k}(\tilde{x}).$$

去噪分数匹配目标从单一尺度情形直接推广：

$$\mathcal{L}_{\text{MS-DSM}}(\theta) = \mathbb{E}_k \mathbb{E}_{x \sim p_{\text{data}}, \tilde{x} \sim \mathcal{N}(x, \sigma_k^2 I)} \left[\left\| s_{\theta}(\tilde{x}, \sigma_k) - \frac{1}{\sigma_k^2} (x - \tilde{x}) \right\|_2^2 \right].$$

等价地, 写 $\tilde{x} = x + \varepsilon$, 其中 $\varepsilon \sim \mathcal{N}(0, \sigma_k^2 I)$, 则成为

$$\mathcal{L}_{\text{MS-DSM}}(\theta) = \mathbb{E}_k \mathbb{E}_{x \sim p_{\text{data}}, \varepsilon \sim \mathcal{N}(0, \sigma_k^2 I)} \left[\left\| s_\theta(x + \varepsilon, \sigma_k) + \frac{\varepsilon}{\sigma_k^2} \right\|_2^2 \right].$$

对每个固定噪声层级, 与之前相同的回归论证依然适用。最优预测子恢复对应平滑密度的分数:

$$s_\theta^*(\tilde{x}, \sigma_k) = \nabla_{\tilde{x}} \log p_{\sigma_k}(\tilde{x}).$$

区别在于: 模型现在学的是一族分数场而非单个分数场。因此, 我们建模的不再是一个密度, 而是一个由高度带噪且简单到轻微带噪且精细的平滑密度层级。

6.4.2 退火朗之万动力学

一旦在多个噪声层级上学得了分数, 就可以用它们进行采样。这引出退火朗之万动力学 (annealed Langevin dynamics): 从大噪声尺度到小噪声尺度依次施加朗之万更新。

设

$$s_\theta(x, \sigma_k) \approx \nabla_x \log p_{\sigma_k}(x), \quad k = 1, \dots, K,$$

其中

$$\sigma_1 > \sigma_2 > \dots > \sigma_K.$$

我们从一个宽分布的噪声分布初始化, 例如

$$x^{(0)} \sim \mathcal{N}(0, \sigma_1^2 I),$$

然后, 对每个尺度 σ_k , 执行若干次形如

$$x \leftarrow x + \epsilon_k s_\theta(x, \sigma_k) + \sqrt{2\epsilon_k} \xi, \quad \xi \sim \mathcal{N}(0, I).$$

的更新。在尺度 σ_k 上执行若干步后, 过程转入下一个更小的尺度 σ_{k+1} 。

其中的逻辑很简单。在大噪声层级, 分数给出朝向数据大区域的粗糙引导; 在更小的噪声层级, 分数给出更锐利的局部修正。因此, 采样以渐进精炼的方式进行:

$$\text{random noise} \longrightarrow \text{coarse data region} \longrightarrow \text{local structure} \longrightarrow \text{fine detail}.$$

退火朗之万动力学把多尺度分数学习变成一个明确的生成过程。它也提示了下一步概念推进。当噪声层级数量变得非常大、相邻层级之间的间隔变得非常小时, 这一离散精炼过程开始类似于一个连续时间的扩散过程。

退火朗之万动力学已经是一个生成过程, 但它还不是 DDPM 意义上的扩散模型。它使用一组带噪密度 p_{σ_k} , 并在每个尺度上施加朗之万精炼。扩散模型则把中间带噪分布组织成单一前向加噪过程的边缘分布。在 DDPM 中, 这个过程是一条离散马尔可夫链; 而在连续时间基于分数的观点中, 它由一个随机微分方程描述。

6.4.3 从离散噪声层级到连续扩散过程

多尺度构造用有限多个噪声层级来近似从数据到噪声的平滑过渡。当层级数量变得很大、且相邻层级彼此接近时，把离散指标 σ_k 换成连续时间变量 t 是很自然的。我们不再考虑彼此分离的平滑密度

$$p_{\sigma_1}, p_{\sigma_2}, \dots, p_{\sigma_K},$$

而是考虑连续密度族

$$p_t(x), \quad 0 \leq t \leq T.$$

这一连续时间描述应被理解为 DDPM 章节中离散加噪路径的类比：有限的中间带噪变量序列被替换为一个连续索引的带噪分布族。

在一端， p_0 是数据分布或其理想化版本。在另一端， p_T 被设计为简单的类噪声分布，通常近似为高斯。

分数模型随之从一个噪声条件场

$$s_\theta(x, \sigma_k) \approx \nabla_x \log p_{\sigma_k}(x)$$

变成一个时间相关的场

$$s_\theta(x, t) \approx \nabla_x \log p_t(x).$$

于是，多尺度分数学习的图景成为

finite noise scales $\longrightarrow$ continuous family of noisy densities $\longrightarrow$ a forward diffusion process.

这正是多尺度分数学习与扩散模型绑定之处。在许多噪声层级上学得分数给了我们一族向量场，但这本身尚未构成一个扩散模型。当带噪密度被组织成单一前向加噪过程的时间边缘分布时，才得到一个扩散模型。换言之，必须存在一个随机动力学，其演化分布恰为 p_t 。学到的分数 $s_\theta(x, t)$ 随之不仅被用作孤立的去噪场，而是被用作反向运行该加噪过程所需的修正项。

一个连续加噪过程可以由形如

$$dX_t = f(X_t, t) dt + g(t) dW_t.$$

的随机微分方程描述。项 $f(X_t, t) dt$ 是确定性漂移，而 $g(t) dW_t$ 注入布朗噪声。函数 $g(t)$ 控制时刻 t 噪声的强度。

这正是上一章展开的“漂移加噪声”结构。若 $p_t(x)$ 表示 X_t 的密度，则其演化由福克-普朗克方程

$$\partial_t p_t(x) = -\nabla_x \cdot (p_t(x) f(x, t)) + \frac{1}{2} g(t)^2 \Delta p_t(x),$$

支配（针对标量、各向同性的扩散系数 $g(t)$ ）。漂移项在空间中输运概率质量，而扩散项铺展并平滑密度。

在生成建模中，前向过程并不直接用于生成新数据。它的作用是定义一条从数据到噪声的受控路径：

$$p_0(x) \approx p_{\text{data}}(x), \quad p_T(x) \approx \text{simple noise distribution}.$$

于是生成问题便是把这一过程反向运行：从噪声出发，恢复出有结构的样本。

6.4.4 反向时间动力学与分数的角色

前向扩散过程容易模拟。从一个数据样本出发，按所选随机微分方程不断加噪，得到越来越带噪的状态。但生成需要相反的方向。我们希望从一个简单的噪声样本出发，向数据分布方向移动回去。

乍看之下，反转一个带噪过程似乎不可能，因为扩散似乎破坏信息。然而，在适当的正则条件下，扩散过程的反向时间演化同样可以由一个随机微分方程描述。关键事实是：反向漂移依赖于中间密度 p_t 的分数。

对本章考虑的标量扩散情形下的前向过程

$$dX_t = f(X_t, t) dt + g(t) dW_t,$$

反向时间动力学形如

$$dX_t = [f(X_t, t) - g(t)^2 \nabla_x \log p_t(X_t)] dt + g(t) d\bar{W}_t.$$

这里方程采用惯用的反向时间记号：过程从 $t = T$ 模拟到 $t = 0$ ，因此时间增量按反方向理解。布朗运动 $\bar{W}_t$ 表示与这一反向过程相伴的噪声。

这个方程正是学到的分数在生成中变得可操作的那一点。前向 SDE 定义了带噪密度族 p_t ，而反向漂移需要依赖分数的修正

$$-g(t)^2 \nabla_x \log p_t(X_t).$$

由于真实分数未知，我们学习一个以时间为条件的模型：

$$s_\theta(x, t) \approx \nabla_x \log p_t(x), \quad 0 \leq t \leq T.$$

图 6.4 概括了这些部分如何拼合在一起。




图 6.4: **The score supplies the correction needed to reverse diffusion.** The forward SDE defines the time-indexed marginals p_t , while a time-conditioned model learns $s_\theta(x, t) \approx \nabla_x \log p_t(x)$. For the scalar, state-independent diffusion coefficient used here, the reverse drift differs from the forward drift by $-g(t)^2 \nabla_x \log p_t(x)$. Replacing the unknown score by $s_\theta(x, t)$ gives the practical reverse-time SDE, simulated from T down to 0 .

因此，模型学到的是中间带噪分布的分数，而不仅仅是数据分布的分数。这些局部场提供了从简单的终端噪声律回到有结构数据所需的修正。

一旦这些分数已知或得到良好逼近，就可以通过模拟反向时间动力学来生成。从

$$X_T \sim p_T,$$

开始，其中 p_T 是简单的噪声分布，然后利用学到的分数 $s_\theta(x, t)$ 从 T 反向演化到 0。最终状态随后被视为数据分布的一个近似样本。

至此完成了从分数学习到基于分数扩散的概念过渡。去噪分数匹配说明了如何学习带噪分布的分数；多尺度分数学习把这一点扩展到许多噪声层级；前向扩散过程把这些带噪分布组织成一条以时间为索引的路径，而反向时间 SDE 说明学到的分数如何被用来沿这条路径回溯。

因此，扩散模型不只是一个分数估计器，分数匹配本身也还不是完整的生成模型。前向扩散过程定义了一条从数据到噪声的结构化路径，而分数学习提供了反向这条路径所需的局部信息。生成由二者结合获得：从一个简单的噪声分布出发，沿一条学习得到的、由分数引导的反向动力学走向数据分布。

6.5 经由分数视角看离散扩散模型

上面的讨论展开的是扩散的连续时间基于分数观点。我们现在把它与本书此前介绍的离散 DDPM 形式联系起来。目的不是重复潜变量推导，而是通过基于分数的视角重新解读 DDPM 的一个熟悉部分：噪声预测目标。

在 DDPM 章节中，扩散模型是通过一条前向加噪马尔可夫链、一条学习得到的反向马尔可夫链以及一个化简为噪声预测损失的变分训练目标引入的。这里我们说明，那个噪声预测损失为何也可以被理解为携带关于中间带噪分布的类分数信息。

6.5.1 噪声预测与条件分数

回忆 DDPM 前向过程通过添加高斯噪声逐步破坏干净数据样本 x_0 。该过程的一个关键性质是：带噪变量 x_t 可以直接由 x_0 采样得到，即

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I),$$

其中 $\bar{\alpha}_t$ 控制时刻 t 残存的信号强度。等价地，

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I).$$

从基于分数的观点看，相关的对象是关于带噪变量 x_t 的对数密度梯度。对条件高斯 $q(x_t | x_0)$ ，有

$$\log q(x_t | x_0) = -\frac{1}{2(1 - \bar{\alpha}_t)} \|x_t - \sqrt{\bar{\alpha}_t} x_0\|_2^2 + \text{constant}.$$

对 x_t 求导得

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{1}{1 - \bar{\alpha}_t} (x_t - \sqrt{\bar{\alpha}_t} x_0).$$

利用重参数化

$$x_t - \sqrt{\bar{\alpha}_t} x_0 = \sqrt{1 - \bar{\alpha}_t} \varepsilon,$$

它变为

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{1}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon.$$

这个恒等式解释了为什么噪声预测与分数估计密切相关。若一个模型预测所加噪声 ε ，那么在已知缩放因子

$$-\frac{1}{\sqrt{1 - \bar{\alpha}_t}},$$

的意义下，它同时预测了带噪高斯分布 $q(x_t | x_0)$ 的条件分数。

准确把握这个含义很重要。上面的表达式是条件分数，其中干净样本 x_0 被视为已知。而反向过程所需的分数是边缘分数

$$\nabla_{x_t} \log q_t(x_t),$$

其中 $q_t(x_t)$ 是时刻 t 带噪样本的完整分布。与去噪分数匹配中一样，边缘分数通过对可能产生同一带噪观测 x_t 的各种干净样本 x_0 取平均而得到。

因此，DDPM 噪声预测为获得分数模型所需的那类信息提供了一条实用的回归途径：即告诉一个带噪样本应如何修正才能变得更像数据的局部方向。

6.5.2 基于分数扩散的统一图景

现在我们可以把不同的观点并排放在一起。

从 DDPM 潜变量的视角看，一个扩散模型由离散前向加噪过程

$$x_0 \rightarrow x_1 \rightarrow \cdots \rightarrow x_T,$$

连同一条学习得到的反向过程

$$x_T \rightarrow x_{T-1} \rightarrow \cdots \rightarrow x_0.$$

构成。训练可以由一个变分目标表达，并且在标准参数化下，这导出一个在每个时间步预测所加噪声的神经网络。

从基于分数的视角看，同一带噪变量序列定义了一族中间带噪分布

$$q_t(x_t), \quad t = 0, \dots, T.$$

在每个时间步，反向过程都需要关于如何把带噪样本移向对应中间分布下更高概率区域的局部信息。这一局部信息由分数

$$\nabla_{x_t} \log q_t(x_t).$$

编码。

因此两种观点是互补的。DDPM 观点强调概率潜变量结构与离散反向马尔可夫链；基于分数的观点强调中间带噪密度的几何与反转加噪所需的局部去噪方向。

在连续时间下，这一几何图景尤为清晰。离散族

$$q_0, q_1, \dots, q_T$$

被一条连续的密度路径

$$p_t(x), \quad 0 \leq t \leq T,$$

取代，而反向动力学显式地包含分数

$$\nabla_x \log p_t(x).$$

因此，基于分数的连续时间形式可以被视为 DDPM 中同一去噪原理的光滑类比。

主要的概念信息并不是所有形式化在细节上都相同。DDPM、退火朗之万动力学与连续时间基于分数的扩散以不同方式组织生成过程。但它们共享同一个核心思想：

learn how noisy samples should be locally corrected,

并利用这些学到的修正把噪声转化为数据。

从这个意义上说，扩散模型是时间相关去噪的结构化形式。前向过程创建一个带噪分布的层级；学习问题估计沿该层级回溯所需的信息；采样过程从简单噪声出发，反复施加学到的修正，直到得到类数据样本。

至此完成了离散 DDPM 观点与本章所展开的基于分数观点之间的衔接。DDPM 章节说明了扩散模型如何作为潜变量生成模型被推导出来；本章则说明了它们的去噪行为为何也能从几何上理解：它们在各噪声层级学习类分数信息，并用它来引导从噪声到数据的反向变换。

总结与参考文献

本章展开了生成建模的基于分数观点，并用它构建了扩散的连续时间解释。此前的 DDPM 章节通过离散潜变量与变分学习引入扩散，而本章则通过局部概率几何来逼近同一去噪思想。

核心对象是分数函数， $\nabla_x \log p(x)$ ，它把一个密度变成一个向量场。我们首先把分数解释为概率漂移方向，并说明它与布朗噪声结合后如何导出朗之万动力学。借助福克-普朗克方程的平稳性计算解释了为什么目标密度的分数能够支撑一个以该目标为平稳分布的采样动力学。

随后我们转向学习问题。由于真实数据密度未知，其分数无法直接求值。分数匹配通过最小化 Fisher 散度目标并利用分部积分从训练损失中移除未知数据分数来应对这一问题。去噪分数匹配则通过用高斯噪声破坏数据、经由一个回归问题学习平滑密度的分数，使这一思想更加实用。在这一视角下，模型学习的是带噪样本应当如何移回干净数据分布。

接着，本章从单一噪声层级走向一族带噪分布。多尺度分数学习在大噪声层级提供粗糙的全局引导，在小噪声层级提供精细的局部修正。退火朗之万动力学把这些分数场变成一个采样过程，而连续时间形式把带噪分布组织成前向随机微分方程的边缘分布。相应的反向时间动力学说明了为什么时间相关的分数 $\nabla_x \log p_t(x)$ 是把噪声变回数据所需的关键修正项。

最后，我们把这一基于分数的观点回接到 DDPM。DDPM 的噪声预测目标可以被理解为学习关于带噪中间分布的类分数信息。因此，DDPM 观点与基于分数的观点并非相互竞争的解釋，而是互补的：DDPM 强调离散潜变量构造，而基于分数的扩散强调反转噪声的几何与动力学。

基于分数的扩散的发展汲取了若干重要的研究脉络。分数匹配原理由 Hyvärinen [19] 提出，他说明了如何在要求密度归一化常数的情况下，通过匹配对数密度的梯度来估计模型。Vincent [43] 后来把分数匹配与去噪联系起来，说明了去噪目标可以恢复受扰数据分布的分数信息。这些思想构成了本章所用的分数学习与去噪分数匹配推导的基础。

基于分数的生成建模由 Song 与 Ermon [38] 引入现代深度生成建模的语境，他们在多个高斯噪声层级上学习分数，并利用退火朗之万动力学进行采样。这项工作明确揭示了多尺度分数场的重要性，尤其是当数据集中在低维结构附近时。连续时间形式随后由 Song et al. [39] 统一并推广，他们通过随机微分方程、反向时间 SDE 以及相关采样过程来刻画基于分数的生成建模。连同 Ho et al. [16] 的 DDPM 形式，这些工作为“扩散模型既是概率去噪模型也是分数引导的生成动力学”这一现代理解提供了主要的概念基础。

第 7 章 7

精确密度模型：归一化流与自回归分解

概述

前面几章展开了通向现代生成模型（generative model）的若干条主要路线。变分自编码器（autoencoder）引入了潜变量（latent variable）建模与近似推断；去噪扩散概率模型将视角转向随机加噪与去噪过程；连续时间与基于分数的章节则进一步通过密度演化、随机微分方程与学习到的分数场发展了这一思路。

本章转向另一种不同的范式：精确密度建模。这里的目标是构造这样一类生成模型：观测数据点的概率密度可以直接通过设计加以精确计算。这改变了建模哲学。我们不依赖难以解析求解的潜变量边缘分布，也不去学习如何逆转一个随机的损坏过程，而是从一开始就施加能够保持似然（likelihood）计算可行的数学结构。

第一条路线由归一化流（normalising flows）提供。归一化流从一个简单的基础分布（例如标准高斯分布）出发，并施加一系列可微、可逆的变换。换元公式通过雅可比行列式刻画局部拉伸或压缩，从而精确地告诉我们密度在每次变换下如何变化。只要这些变换是可逆的，且它们的雅可比行列式是易于计算的，那么似然计算与采样就都是精确的模型操作。

第二条路线由自回归模型（autoregressive models）提供。自回归模型并不通过可逆映射来变换一个基础分布，而是直接利用概率链式法则构造联合密度。一个高维数据点被分解为一个有序的分量序列，每个分量都在给定其之前分量的条件下被建模。这样无需潜变量、变分界或雅可比行列式即可得到精确似然，但采样通常变成顺序式的。

这两种方法在现代生成建模中仍然重要，因为它们展示了基于精确似然的建模可以走多远。归一化流为可逆密度估计、不确定性建模以及概率分布的可计算变换提供了一个清晰的框架。而自回归模型则支撑着许多有影响力的序列、音频、语言以及像素级图像生成系统。即使较新的系统融合了多种建模思想，本章发展的原理——换元、可计算的雅可比、条件分解与有序生成——仍然作为核心构件不断重现。

概念图

本章将精确密度建模作为与前面介绍的潜变量、扩散与基于分数的方法相对照的范式来展开。核心问题是：灵活的高维生成模型如何能够保持精确的似然计算。


→ 我们首先通过换元公式引入归一化流。归一化流使用可微、可逆的变换，把一个简单

的基础变量 z 映射为数据变量 $x = f(z)$ 。换元公式通过雅可比行列式追踪由此产生的密度变化。

- 接着我们研究平面流，将其作为第一个非线性流层。平面流通过一个残差式的秩一扰动引入非线性。这使雅可比行列式保持解析可算，同时说明了可逆性约束的重要性。
- 接下来，我们转向仿射耦合层，作为一种实用的流构造。仿射耦合层只变换输入的一部分，而以其余部分作为条件。这带来了闭式逆以及高效的对数行列式计算，使它们适合实用的流模型。
- 然后我们把流层组合成完整的生成模型。堆叠许多可逆层，可以让简单的局部形变累积成富有表达力的全局变换。似然计算把数据映射回基础空间，而采样则把基础噪声正向映射到数据空间。
- 接下来，我们引入自回归分解，作为获得精确似然的第二条路线。自回归模型使用链式法则 $p(x) = \prod_{i=1}^d p(x_i | x_{<i})$ 构造精确似然，无需潜变量、变分界或雅可比行列式。
- 最后，我们解释条件参数化、训练、采样与掩码。一个共享的模型可以参数化所有条件分布。训练时完整的数据向量是可观测的，因此各似然项通常可以并行计算。采样时，各分量则按顺序生成。掩码强制施加有序的信息流，使自回归分解保持可行。

本章发展的两条路线，以及使二者皆可行的结构性原理，总结于下面的可视化概览之中。

Exact density models at a glance



Common design principle: tractability by structure

triangular Jacobians in coupling flows $\longleftrightarrow$
triangular dependency masks in autoregressive models

7.1 归一化流：通过可逆变换实现精确密度

归一化流通过在一个简单的参考分布与数据分布之间构造显式映射，同时始终保持精确的似然计算，为生成建模提供了一条直接的、完全概率化的路线 [34]。归一化流一词指的是这一更广泛的可逆密度模型家族，而非某个特定的变换；平面流、仿射耦合层以及相关架构都是设计此类变换的不同方式，目的是让它们既富有表达力、可逆，又在计算上可行。

归一化流背后的核心数学工具是换元公式。该公式精确刻画了概率密度在可微、可逆映射下如何变换。归一化流不引入潜变量或辅助随机过程，而只依赖确定性变换，其对密度

的作用可以精确计算。通过把许多这样的变换串联起来，一个简单的基础分布——通常是标准高斯分布——可以逐步被重塑为一个高度结构化的数据分布。

从几何视角看，每个变换都是对空间的一次受控形变，以雅可比行列式明确记录的方式在局部拉伸或压缩体积。只要每个变换都可逆且其雅可比行列式保持可算，所得到的模型就支持精确的似然计算与精确采样。这种表达力与数学透明性的结合，使归一化流区别于其他生成建模范式，也使其成为我们研究精确密度模型的自然起点。

7.1.1 重温换元公式

虽然换元公式在第 5 章已从更一般的确定性密度输运视角介绍过，这里仍值得再次回顾，因为它是归一化流的建模原理。

设 X 具有已知的密度 $p_X(x)$ ，我们施加一个可微、可逆的函数 $Y = f(X)$ 。我们的目标是确定 Y 的密度，记作 $p_Y(y)$ 。直观上， Y 的密度需要反映两件事。

第一，它必须说明概率质量来自何处。由于 $y = f(x)$ ，观测到 y 的似然取决于其对应的原像 $x = f^{-1}(y)$ 在原始分布下出现的可能性。

第二，它必须说明变换如何拉伸或压缩空间。把点散布得更开的变换应当降低密度，而把点压缩得更紧的变换则应当提高密度。密度始终是单位长度、面积或体积上的概率，因此局部间距至关重要。

在一维情形，这些思想汇合为换元公式

$$p_Y(y) = p_X(f^{-1}(y)) \left| \frac{df^{-1}(y)}{dy} \right|.$$

第一项告诉我们是哪个 x 的取值生成了 y 。第二项是一个缩放因子，说明 x 附近的邻域映射到 y 时被拉伸或压缩的程度。

一个简单的几何例子。设 $X \sim \text{Uniform}(0, 1)$ ， $Y = f(X) = 2X$ 。

该变换将每个点加倍，并把区间 $[0, 1]$ 拉伸为 $[0, 2]$ 。其逆为

$$x = f^{-1}(y) = \frac{y}{2},$$

于是

$$\frac{df^{-1}(y)}{dy} = \frac{1}{2}.$$

应用公式可得

$$p_Y(y) = p_X\left(\frac{y}{2}\right) \frac{1}{2}.$$

在新的定义域 $[0, 2]$ 内，原始密度满足 $p_X(y/2) = 1$ ，因此

$$p_Y(y) = \frac{1}{2}, \quad 0 \leq y \leq 2.$$

这与直觉完全吻合：同样多的总概率现在充满了一个宽一倍的区间，因此其密度减半。这一简单逻辑可以推广到更高维度。

高维情形：从拉伸长度到拉伸体积。 在多维情形，导数被一个体积缩放行列式取代。对于简单的线性映射

$$f(x) = Ax, \quad A = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix},$$

局部面积被乘以 $|\det A| = 6$ ，因此

$$p_Y(y) = p_X(A^{-1}y) \frac{1}{|\det A|}.$$

同样的概率质量占据了更大的局部体积，于是密度按倒数因子下降。

雅可比矩阵：局部线性透镜。 为推广到线性变换之外，我们使用雅可比矩阵。对于可微函数

$$f: \mathbb{R}^d \rightarrow \mathbb{R}^d,$$

其雅可比矩阵定义为

$$[J_f(x)]_{ij} = \frac{\partial f_i(x)}{\partial x_j}.$$

雅可比矩阵可以看作一个局部线性透镜。在点 x 附近，一个微小位移 δx 的变换近似为

$$f(x + \delta x) \approx f(x) + J_f(x)\delta x.$$

因此 $J_f(x)$ 告诉我们 x 周围一个无穷小邻域在映射到 $y = f(x)$ 时如何被扭曲。其行列式量化了相应局部体积扩张或收缩的程度。

对于一般的可微、可逆变换 $y = f(x)$ ，多元换元公式变为

$$p_Y(y) = p_X(f^{-1}(y)) |\det J_{f^{-1}}(y)| = p_X(x) \frac{1}{|\det J_f(x)|}, \quad y = f(x).$$

这就是归一化流的数学核心：如果每个变换都可逆且其雅可比行列式可算，那么即使整体映射变得极具表达力，我们仍能精确表达变换后变量的密度。图 7.1 展示了该公式的几何内涵：固定数量的概率质量占据一个被局部拉伸或压缩的区域，密度按体积的倒数因子变化。




图 7.1: **Change of variables corrects density for local volume change.** The same probability mass occupies a different local area after an invertible transformation. In the linear example, the determinant gives the area scaling; for a nonlinear flow, the Jacobian gives the corresponding local scaling point by point. This is the geometric origin of the log-determinant correction.

为什么标准归一化流保持维度不变

标准归一化流使用如下形式的可微、可逆变换

$$f: \mathbb{R}^d \rightarrow \mathbb{R}^d.$$

这一相等的维度是标准换元公式所要求的：雅可比矩阵必须是方阵， $\det J_f(x)$ 才有定义并能够度量局部体积变化。如果映射把 $\mathbb{R}^d$ 送到更低维的空间，信息会被压缩，不同的输入可能映射到同一个输出。如果它把 $\mathbb{R}^d$ 送入更高维的空间，其像会落在一个更低维的流形（manifold）上，若没有额外结构便无法定义普通的全维密度。因此，标准归一化流保持维度不变。没有这种全维可逆性，就无法用换元公式精确追踪概率质量。

7.1.2 平面流

上面的例子有意保持简单。它们展示了换元公式如何在线性拉伸与体积缩放下追踪密度。然而，线性变换的表达能力有限。它们可以拉伸、旋转或剪切空间，却无法以丰富的非线性方式弯曲或扭曲空间。为了逼近复杂分布，我们需要引入受精细控制的非线性、同时保持归一化流两个核心要求的变换：可逆性与易于计算的雅可比行列式。

平面流是这种权衡的经典例子，最初由 Rezende 与 Mohamed 作为其归一化流框架的一部分引入 [34]。一个基础的非线性流层定义为

$$f(x) = x + u h(w^\top x + b),$$

其中 $x \in \mathbb{R}^d$, $u, w \in \mathbb{R}^d$, $b \in \mathbb{R}$, 且

$$h: \mathbb{R} \rightarrow \mathbb{R}$$

是一个光滑的激活函数，例如 $\tanh$ 或 sigmoid 。这里 x 表示该单个流层的输入；在堆叠的流中，它通常是某个中间变量。

项

$$w^\top x + b$$

充当输入的仿射投影，把高维向量 x 降为单个标量。就其自身而言，这个投影只贡献一个线性量。为了引入曲率与更丰富的行为，我们将该标量传入非线性激活 $h(\cdot)$ 。诸如 $\tanh$ 与 sigmoid 之类的函数把输入压入有界范围，因此 h 的输出可以解释为一个软门控值，控制该变换对输入的修改强度。

将这个门控后的标量乘以向量 u ，便得到一个带方向缩放的扰动。形变总是沿着 u 的方向发生，但其幅度以非线性方式依赖于投影 $w^\top x + b$ 。把该扰动加回 x ，既保证了输出仍处于完整的 d 维空间，又引入了灵活的非线性调整。

残差结构与动机

平面流遵循深度学习中残差连接的思想：

$$f(x) = x + \text{learned perturbation.}$$

这在保留恒等映射的同时加入了一次受控形变。

如果只用非线性项

$$x \mapsto u h(w^\top x + b),$$

输出会塌缩到 u 的一维方向上，因为 $h(\cdot)$ 产生一个标量。这将破坏归一化流所需的全维结构。

通过把扰动加回 x ，平面流保持完整的 d 维空间可达，同时引入有针对性的非线性扭曲。

雅可比推导。为计算密度在平面流下如何变换，我们推导

$$f(x) = x + u h(w^\top x + b).$$

的雅可比矩阵。为方便起见，令

$$a = w^\top x + b, \quad f(x) = x + u h(a).$$

对 x 求导并应用链式法则，得

$$\frac{\partial f(x)}{\partial x} = I + u h'(a) \frac{\partial a}{\partial x}.$$

由于 $\frac{\partial a}{\partial x} = w^\top$ ，雅可比矩阵具有紧凑形式

$$J_f(x) = I + u w^\top h'(a).$$

等价地，

$$J_f(x) = I + u \psi(x)^\top, \quad \psi(x) := h'(w^\top x + b)w.$$

这一结构极为便利。雅可比矩阵是单位矩阵加上一个秩一矩阵的扰动。行列式的计算不必求完整的 $d \times d$ 行列式（通常需要 $O(d^3)$ 的代价），而是化简为一个标量表达式。利用矩阵行列式引理

$$\det(I + uv^\top) = 1 + v^\top u,$$

我们得到

$$\det J_f(x) = 1 + \psi(x)^\top u.$$

代入 $\psi(x) = h'(w^\top x + b)w$ ，得

$$\det J_f(x) = 1 + h'(w^\top x + b) w^\top u.$$

因此平面流的对数行列式贡献为

$$\log |\det J_f(x)| = \log |1 + h'(w^\top x + b) w^\top u|.$$

这一闭式解使平面流在基于似然的训练中保持可行。

理解秩一更新

矩阵 $uw^\top$ 是 $\mathbb{R}^d$ 中两个向量的外积，这样的矩阵秩为一。

原因如下：将其作用于任意向量 v ：

$$uw^\top v = u(w^\top v).$$

标量 $w^\top v$ 随 v 变化，但输出始终是 u 的标量倍数。因此该矩阵只有一个独立的输出方向。

这也解释了行列式为何简单：平面流并不试图同时对所有维度施加任意的非线性形变。它引入的是一种可控的单方向形变，其体积变化可以解析计算。

图 7.2 展示了相应的几何图像：形变量随空间位置变化，但残差位移始终平行于单一方向 u 。




图 7.2: A planar flow is nonlinear but directionally constrained. The displacement varies with location through the scalar nonlinear response, while every residual displacement remains parallel to the same vector u . This is the geometric consequence of the rank-one structure derived in the text.

可逆性条件。除了易于计算的雅可比行列式之外，流层还必须可逆。对于平面流

$$f(x) = x + u h(w^\top x + b),$$

其逆一般没有闭式解，因此可逆性通常通过参数约束来控制。

由雅可比推导可知

$$\det J_f(x) = 1 + h'(w^\top x + b) w^\top u.$$

如果该行列式变为零，变换就会在局部压缩体积，无法局部求逆。因此，一个常用的充分条件是让行列式对所有 x 都保持为正。

对于 $\tanh$ 这类导数满足

$$0 \leq h'(a) \leq 1,$$

的激活函数，只要求

$$w^\top u > -1.$$

即可。于是对所有 a 都有

$$1 + h'(a) w^\top u > 0$$

从而平面流避免了局部体积塌缩。实践中，这一条件可以通过对 u 重参数化来强制满足。

由此可见，平面流展示了一个核心的设计权衡：它通过简单的残差扰动引入非线性，同时保持雅可比行列式解析可算，并使可逆性可以通过一个标量条件加以控制。

7.2 实践中的归一化流：耦合层与组合

上一节把归一化流介绍为基于可逆变换的精确密度模型。平面流给出了一个雅可比行列式保持可算的简单非线性流层示例，但它们也暴露了一个实用局限：其逆一般没有闭式解。

现在我们从这一教学性构造转向实用流架构背后的核心设计原则之一：耦合。耦合层每次只变换输入的一部分，同时把其余部分用作条件信号，以此保持精确可逆。这带来三角形的雅可比矩阵、闭式逆，并使该层能够高效堆叠。

本节随后展示如何将此类层组合成完整的生成模型。正是这种组合，把简单的局部变换变成了富有表达力的密度模型，同时保留归一化流的两个标志性操作：精确的似然计算，以及从学习到的模型中精确采样。

7.2.1 仿射耦合层与三角形雅可比矩阵

仿射耦合层由 NICE 与 RealNVP 等基于耦合的流模型引入 [8, 9]，它们提供了构造富有表达力、逆与对数行列式均可计算的流的最实用方式之一。

仿射耦合层首先把输入向量拆分为两部分。设 $x \in \mathbb{R}^d$ 为某个流层的输入，记

$$x = (x_1, x_2),$$

其中 $x_1 \in \mathbb{R}^{d_1}$, $x_2 \in \mathbb{R}^{d_2}$ ，且 $d_1 + d_2 = d$ 。仿射耦合变换定义为

$$\begin{aligned} y_1 &= x_1, \\ y_2 &= x_2 \odot \exp(s(x_1)) + t(x_1), \end{aligned}$$

其中 $s(\cdot)$ 与 $t(\cdot)$ 是函数（通常是神经网络）， $\odot$ 表示逐元素乘法。

输入的第一部分保持不变。第二部分被一个逐元素仿射映射变换，其尺度与平移由第一部分预测得到。于是 x_1 充当上下文变量，而 x_2 依据该上下文被缩放和平移。

尽管该变换对 x_2 是仿射的，函数 $s(x_1)$ 与 $t(x_1)$ 却可以高度非线性。这使得整体变换既富有表达力，又保持简单的代数结构。因此该层是刻意不对称的：它牺牲了单层内的完全同时混合，换取精确求逆与高效的行列式计算。

雅可比行列式。为计算雅可比矩阵，记

$$y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \odot \exp(s(x_1)) + t(x_1) \end{bmatrix}.$$

雅可比矩阵具有分块形式

$$J = \frac{\partial y}{\partial x} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} \end{bmatrix}.$$

由于 $y_1 = x_1$ ，我们有

$$\frac{\partial y_1}{\partial x_1} = I, \quad \frac{\partial y_1}{\partial x_2} = 0.$$

左下分块 $\frac{\partial y_2}{\partial x_1}$ 可能很复杂，因为它包含神经网络 $s(\cdot)$ 与 $t(\cdot)$ 的导数。但关键在于，这个分块不会影响行列式。

对于右下分块，注意 y_2 的每个分量为

$$y_{2,i} = x_{2,i} \exp(s_i(x_1)) + t_i(x_1).$$

在保持 x_1 固定的条件下对 $x_{2,j}$ 求导，得

$$\frac{\partial y_{2,i}}{\partial x_{2,j}} = \begin{cases} \exp(s_i(x_1)), & i = j, \\ 0, & i \neq j. \end{cases}$$

因此

$$\frac{\partial y_2}{\partial x_2} = \text{diag}(\exp(s(x_1))).$$

把各分块拼在一起，

$$J = \begin{bmatrix} I & 0 \\ * & \text{diag}(\exp(s(x_1))) \end{bmatrix}.$$

这是一个分块下三角矩阵。对任何三角矩阵或分块三角矩阵，其行列式等于对角分块行列式的乘积。于是

$$\det J = \det(I) \det(\text{diag}(\exp(s(x_1)))).$$

由于 $\det(I) = 1$ ，且对角矩阵的行列式是其对角元之积，

$$\det J = \prod_i \exp(s_i(x_1)).$$

取对数便得到格外简单的表达式

$$\boxed{\log |\det J| = \sum_i s_i(x_1).}$$

这就是仿射耦合层的主要可行性性质。稠密且可能复杂的分块 $\frac{\partial y_2}{\partial x_1}$ 无需为计算行列式而求值。整个体积变化都由尺度输出 $s(x_1)$ 控制。因此，尽管层内使用了非线性神经网络，对数行列式仍可在关于被变换维数的线性时间内完成计算。

三角分块结构是这一计算简化的关键：非对角分块可能很复杂，但它不进入行列式。这是精确密度建模中反复出现的原则的一个例证：通过恰当地安排非线性依赖关系，高维概率计算仍可分解为简单的项。

可逆性。 给出三角形雅可比矩阵的同一不对称结构，也给出了闭式逆。由正向变换

$$\begin{aligned} y_1 &= x_1, \\ y_2 &= x_2 \odot \exp(s(x_1)) + t(x_1), \end{aligned}$$

我们立即恢复

$$x_1 = y_1.$$

将其代入第二个方程，得

$$y_2 = x_2 \odot \exp(s(y_1)) + t(y_1).$$

由于 $\exp(s(y_1))$ 逐分量严格为正，该逐元素仿射变换可以求逆：

$$x_2 = (y_2 - t(y_1)) \odot \exp(-s(y_1)).$$

于是其逆为

$$\begin{aligned} x_1 &= y_1, \\ x_2 &= (y_2 - t(y_1)) \odot \exp(-s(y_1)). \end{aligned}$$

无需求根，也无需迭代求逆。其逆的计算代价与正向变换基本相同。这使得仿射耦合层在大规模模型中格外实用，因为采样与似然计算可能需要反复施加许多流变换。图 7.3 概括了使这两个性质得以实现的不对称信息流：一个子集原样通过，同时控制着另一个子集的变换。

Affine coupling: one-way dependence creates tractability




图 7.3: **Asymmetric information flow in affine coupling.** One subset passes through unchanged while also determining how the other subset is transformed. This one-way dependence gives both the triangular Jacobian and the closed-form inverse.

7.2.2 流的堆叠：似然计算与采样

单个流层只能产生有限的空间形变。平面流在一个学到的方向上对恒等映射施加扰动，而仿射耦合层每次只变换输入的一部分。因此，归一化流的表达力来自复合：许多简单、可逆的变换被堆叠起来，使它们的微小形变累积成一个丰富的全局映射。

设

$$f_1, f_2, \dots, f_K$$

为一列可微且可逆的变换。从基础变量

$$z_0 \sim p_Z(z_0),$$

出发，我们定义中间变量

$$z_k = f_k(z_{k-1}), \quad k = 1, \dots, K,$$

以及最终输出

$$x = z_K.$$

等价地，

$$x = f_K \circ f_{K-1} \circ \dots \circ f_1(z_0).$$

因为每一层都可逆，整个复合映射也可逆。这意味着我们可以在两个方向上移动：

$$z_0 \xrightarrow{f_1} z_1 \xrightarrow{f_2} \dots \xrightarrow{f_K} z_K = x,$$

或

$$x = z_K \xrightarrow{f_K^{-1}} z_{K-1} \xrightarrow{f_{K-1}^{-1}} \dots \xrightarrow{f_1^{-1}} z_0.$$

这种双向结构给出了流模型的两个基本操作：似然计算与采样。

似然计算：从数据空间到基础空间。 在基于似然的训练中，我们给定一个数据点 x 。按照上面的约定， x 是最终变量 z_K 。为计算其密度，我们通过逆变换将其向后映射：

$$x = z_K \xrightarrow{f_K^{-1}} z_{K-1} \rightarrow \dots \xrightarrow{f_1^{-1}} z_0.$$

如果模型拟合良好，恢复出的基础空间变量 z_0 在简单的基础密度 p_Z 下应当看起来较可能。

对每一层逐一应用换元公式，得

$$p_{Z_k}(z_k) = p_{Z_{k-1}}(z_{k-1}) |\det J_{f_k}(z_{k-1})|^{-1}.$$

从 $k = 1$ 到 K 反复应用该递推式，并利用 $z_K = x$ ，可得

$$p_X(x) = p_Z(z_0) \prod_{k=1}^K |\det J_{f_k}(z_{k-1})|^{-1}.$$

取对数得

$$\log p_X(x) = \log p_Z(z_0) - \sum_{k=1}^K \log |\det J_{f_k}(z_{k-1})|.$$

这一表达式有直接的解读。基础密度项 $\log p_Z(z_0)$ 度量逆变换后的数据点在简单参考分布下的合理程度。对数行列式项则校正由这一系列变换引入的全部体积变化。每一层都对最终的对数似然贡献一个可加的体积校正项。

乘积形式如何产生

对单个流层 $z_k = f_k(z_{k-1})$ ，换元公式给出

$$p_{Z_k}(z_k) = p_{Z_{k-1}}(z_{k-1}) |\det J_{f_k}(z_{k-1})|^{-1}.$$

反复应用这一关系，得

$$\begin{aligned} p_{Z_2}(z_2) &= p_{Z_0}(z_0) |\det J_{f_1}(z_0)|^{-1} |\det J_{f_2}(z_1)|^{-1}, \\ &\vdots \\ p_{Z_K}(z_K) &= p_{Z_0}(z_0) \prod_{k=1}^K |\det J_{f_k}(z_{k-1})|^{-1}. \end{aligned}$$

由于 $z_K = x$ ，这就给出了所观测数据点的似然。

采样：从基础空间到数据空间。 采样以相反的方向使用同样的变换。我们先从基础分布抽取一个点，

$$z_0 \sim p_Z(z_0),$$

然后施加学到的变换：

$$z_0 \xrightarrow{f_1} z_1 \xrightarrow{f_2} \dots \xrightarrow{f_K} z_K = x.$$

所得的 x 就是学习到的模型分布的一个样本。

这一过程相对于模型而言是精确的。不需要马尔可夫链 (Markov chain)、变分近似或数值积分。一旦学到了这些变换，生成就只是从基础分布采样并施加一系列确定性的可逆映射。

这也澄清了与扩散模型 (diffusion model) 的对比。扩散模型通过模拟一个从噪声到数据的、学习到的反向随机过程来生成，而归一化流则施加一个学习到的确定性可逆变换。

复合、混合与表达力。 许多流层的复合使模型富有表达力，但仅有复合还不够。各层还必须被安排得让信息能够跨维度混合。如果每一层都使用同样的拆分，某些变量就会反复充当条件变量，而自身从未被变换。

为解决这一问题，实用流模型把非线性流层与简单的可逆混合操作交替使用。这些操作可以是置换，

$$z \mapsto Pz,$$

或更一般的可逆线性变换，

$$z \mapsto Az,$$

其中 P 是置换矩阵， A 是行列式易于计算的可逆矩阵。

这些混合操作的目的是改变后续各层中相互作用的坐标。在一个耦合层中未被改变的变量，可以在下一层被移入被变换的子集。从几何上看，每个混合操作都改变了施加下一个非线性形变时所用的坐标系。

因此，现代流模型通常由一个重复的模式构成：

mix coordinates $\longrightarrow$ apply tractable nonlinear deformation $\longrightarrow$ mix again.

这种反复交替使局部的、结构化的变换能够组合成灵活的全局映射，同时保持精确可逆与可行的似然计算。

RealNVP 与 Glow 等架构正是围绕这一原则构建的。它们在耦合变换、尺度参数化以及坐标混合的细节上各有不同，但底层数学结构是相同的：复合简单的可逆层，记录每一层的体积变化，并通过精确极大似然训练整个模型。

7.3 作为生成模型的自回归分解

归一化流通过在简单的基础分布与数据分布之间构造可逆映射来实现精确密度建模。其可行性来自换元公式：只要变换可逆且其雅可比行列式可算，似然就能被精确计算。

自回归模型提供了精确密度建模的第二条路线。它们不把一个基础随机变量变换为数据，而是通过把联合密度分解为一列条件密度来直接构造它。在这里，精确似然来自概率链式法则。这改变了施加结构的位置。在归一化流中，结构施加在变换上；而在自回归模型中，结构施加在数据点各分量之间的依赖关系上。通过选定一个顺序，并让每个分量只依赖于之前的分量，一个复杂的联合密度就变成了若干较简单条件项的乘积。

于是，一个高维数据点被视为一个逐个揭示的分量序列。每个分量都在给定其之前分量的条件下被建模，由此得到的一些条件片段定义了一个似然可精确计算的合法联合分布。因此，自回归模型构成了一整套生成建模框架，无需潜变量、变分下界 (ELBO) 或全局可逆变换。它们付出的代价则不同：必须显式施加一个顺序，且采样变成顺序式的。

7.3.1 作为精确密度模型的链式法则

设

$$x = (x_1, x_2, \dots, x_d)$$

为一个 d 维随机向量。概率链式法则来自对恒等式

$$p(a, b) = p(a | b)p(b).$$

的反复应用。从完整的联合密度出发，我们可以先分离出最后一个变量：

$$p(x_1, \dots, x_d) = p(x_d | x_1, \dots, x_{d-1})p(x_1, \dots, x_{d-1}).$$

对剩下的联合项递归地应用同一恒等式，得

$$p(x_1, \dots, x_d) = p(x_d | x_1, \dots, x_{d-1})p(x_{d-1} | x_1, \dots, x_{d-2}) \cdots p(x_2 | x_1)p(x_1).$$

重排各因子，便得到标准的自回归分解：

$$p(x_1, \dots, x_d) = \prod_{i=1}^d p(x_i | x_{<i}),$$

其中

$$x_{<i} := (x_1, \dots, x_{i-1}),$$

且当 $i = 1$ 时, 项 $p(x_1 | x_{<1})$ 直接解释为 $p(x_1)$ 。

这一恒等式是精确的。它本身不作任何近似, 也不施加任何建模假设。只要选定变量的一个顺序, 任何联合分布都可以按这种方式分解。

建模的步骤来自对条件密度的参数化:

$$p_\theta(x) = \prod_{i=1}^d p_\theta(x_i | x_{<i}).$$

只要每个条件密度都是归一化的, 其乘积就定义了一个适当归一化的联合密度。这正是自回归模型在构造上就能给出精确似然的原因。

为什么自回归乘积是合法的密度

设每个条件密度 $p_\theta(x_i | x_{<i})$ 都已归一化:

$$\int p_\theta(x_i | x_{<i}) dx_i = 1.$$

那么联合密度

$$p_\theta(x_1, \dots, x_d) = \prod_{i=1}^d p_\theta(x_i | x_{<i})$$

也是归一化的。从 x_d 向后积分,

$$\int p_\theta(x_d | x_{<d}) dx_d = 1,$$

然后

$$\int p_\theta(x_{d-1} | x_{<d-1}) dx_{d-1} = 1,$$

如此继续, 直到只剩下 $p_\theta(x_1)$, 它同样积分为一。

因此, 自回归乘积不仅仅是一种便利的分解; 只要每个条件项都是合法的, 它就定义了一个合法的概率密度。

7.3.2 条件参数化与生成

一旦指定了每个条件密度的表示方式, 链式法则分解就变成了一个可学习的生成模型。一般地, 我们写

$$p_\theta(x_i | x_{<i}), \quad i = 1, \dots, d,$$

其中 θ 表示模型参数。

重要的一点是, 这些条件分布通常并不是由 d 个互不相关的模型来表示的。相反, 我们使用单个参数化函数 (通常是神经网络) 来输出所有条件分布的参数, 同时遵循自回归顺序。同一组参数在整个分解中被复用; 从一个条件到下一个条件所改变的只是条件上下文。

对于连续变量，一种常见的简单选择是高斯条件分布：

$$p_{\theta}(x_i | x_{<i}) = \mathcal{N}(x_i; \mu_i(x_{<i}), \sigma_i^2(x_{<i})),$$

其中均值与方差是先前变量的函数。更灵活的条件分布可以使用高斯混合、离散化 logistic 混合，或其他富有表达力的一维分布。

对于离散变量，模型可以输出一个类别分布的概率：

$$p_{\theta}(x_i | x_{<i}) = \text{Categorical}(\pi_i(x_{<i})).$$

无论哪种情形，模型预测的都是完整的条件分布，而不仅仅是一个点估计。

一个三变量的自回归例子

对 $x = (x_1, x_2, x_3)$ ，链式法则给出

$$p_{\theta}(x_1, x_2, x_3) = p_{\theta}(x_1) p_{\theta}(x_2 | x_1) p_{\theta}(x_3 | x_1, x_2).$$

如果使用高斯条件分布，那么每个条件分布可以由一个均值和一个方差表示。一个共享的参数生成函数 f_{θ} 可以产生这些参数：

$$(\mu_1, \sigma_1^2) = f_{\theta}(\emptyset),$$

$$(\mu_2, \sigma_2^2) = f_{\theta}(x_1),$$

$$(\mu_3, \sigma_3^2) = f_{\theta}(x_1, x_2).$$

这里 $f_{\theta}(\emptyset)$ 表示第一个条件分布没有先前的变量可作为条件，因此它为 $p_{\theta}(x_1)$ 产生无条件参数。接着 $f_{\theta}(x_1)$ 利用 x_1 的可用取值为 $p_{\theta}(x_2 | x_1)$ 产生参数，而 $f_{\theta}(x_1, x_2)$ 利用之前两个取值为 $p_{\theta}(x_3 | x_1, x_2)$ 产生参数。

于是，例如，

$$p_{\theta}(x_2 | x_1) = \mathcal{N}(x_2; \mu_2, \sigma_2^2), \quad (\mu_2, \sigma_2^2) = f_{\theta}(x_1),$$

类似地，

$$p_{\theta}(x_3 | x_1, x_2) = \mathcal{N}(x_3; \mu_3, \sigma_3^2), \quad (\mu_3, \sigma_3^2) = f_{\theta}(x_1, x_2).$$

同一组模型参数 θ 始终被复用。从一个条件分布到下一个条件分布所改变的，不是模型本身，而是该步骤可用的条件信息量。这澄清了一个常见误解：自回归分解列出了一系列条件分布，但这并不意味着我们为每个因子单独训练一个互不相关的模型。在现代自回归模型中，各条件分布通常由一个共享的、信息流受限的架构共同表示。

同一分解还给出了一个直接的采样过程。给定

$$p_{\theta}(x) = \prod_{i=1}^d p_{\theta}(x_i | x_{<i}),$$

我们可以顺序地生成一个样本：

$$x_1 \sim p_{\theta}(x_1),$$

然后

$$x_2 \sim p_{\theta}(x_2 | x_1),$$

然后

$$x_3 \sim p_\theta(x_3 \mid x_1, x_2),$$

如此继续，直到

$$x_d \sim p_\theta(x_d \mid x_1, \dots, x_{d-1}).$$

在所有分量都生成之后，所得向量

$$x = (x_1, \dots, x_d)$$

就是自回归模型的一个样本。

应当把这一过程理解为完整的生成机制。模型并不会先采样一个潜变量再将其解码，也不会运行一个随机去噪（denoising）过程。它直接一次一个分量地构造数据点，把先前生成的分量作为后续分量的上下文。

7.3.3 并行训练、顺序采样与掩码

自回归模型存在一种重要的计算不对称性：训练时的似然计算往往可以并行化，而采样天然顺序式的。

给定一个观测数据点

$$x = (x_1, \dots, x_d),$$

其对数似然为

$$\log p_\theta(x) = \sum_{i=1}^d \log p_\theta(x_i \mid x_{<i}).$$

训练时， x 的所有分量都是已知的。因此，每个条件上下文 $x_{<i}$ 都可以直接从观测数据中读取，无需任何采样。模型利用真实的前序分量来计算每个条件项。

这正是自回归似然训练精确而稳定的原因。并不需要模型先生成 x_1 ，再用生成值去计算 x_2 ，依此类推；而是让模型针对观测数据计算所有条件概率：

$$\log p_\theta(x_1), \log p_\theta(x_2 \mid x_1), \dots, \log p_\theta(x_d \mid x_{<d}).$$

依具体架构而定，这些条件项中的许多乃至全部都可以并行计算。

采样则不同。生成新样本时，未来的分量尚未产生，因而是未知的。所以我们必须按顺序进行：

$$\begin{aligned} x_1 &\sim p_\theta(x_1), \\ x_2 &\sim p_\theta(x_2 \mid x_1), \\ &\dots \\ x_d &\sim p_\theta(x_d \mid x_{<d}). \end{aligned}$$

每个新采样出的分量都会成为下一个分量的条件上下文的一部分。这使得采样在构造上就是顺序式的。

要在神经网络中实现自回归分解，我们还必须确保第 i 个条件分布的参数只依赖于 $x_{<i}$ ，而不依赖于 x_i 本身或未来的变量。这一限制通常通过掩码来实现。掩码阻断模型内部被禁止的连接，保证信息只能从较早的变量流向较晚的变量。

于是,即使网络在训练时一次性处理整个向量 x, x_i 的输出参数也无法依赖于 $x_i, x_{i+1}, \dots, x_d$ 。计算可以是并行的,但依赖结构仍保持有序。

抽象地看,掩码施加了一种下三角形的依赖模式。如果我们定义一个依赖矩阵 D ,其元素 D_{ij} 表示 x_i 的条件分布是否允许依赖于 x_j ,那么自回归顺序要求

$$D_{ij} = 0 \quad \text{whenever} \quad j \geq i.$$

例如,

$$D = \begin{pmatrix} 0 & 0 & 0 & \cdots & 0 \\ * & 0 & 0 & \cdots & 0 \\ * & * & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & 0 \\ * & * & * & \cdots & 0 \end{pmatrix},$$

其中 $*$ 表示允许的依赖。

这种三角形依赖是该模型在实践中保持可行的关键原因。它避免了循环关系: x_i 的分布可以依赖于较早的分量,但较早的分量不会同时依赖于 x_i 。其结果是,高维联合似然分解为若干条件对数似然之和。

在这个意义上,自回归模型中的三角形依赖所起的作用,类似于基于耦合的归一化流中的三角形雅可比矩阵。在这两种情形中,依赖关系都按单一方向组织,使高维概率计算得以分解为简单的项。

有了这一原则,许多著名架构都可以在结构层面加以理解。MADE 利用掩码在前馈网络中强制实现自回归结构 [11]; PixelRNN 与 PixelCNN 将自回归分解应用于图像 [30]; WaveNet 则使用因果卷积进行原始音频生成 [31]。

因此,自回归模型提供了精确密度建模的第二条主要路线。归一化流通过可逆变换与易于计算的雅可比行列式获得精确似然;自回归模型通过有序的条件分解获得精确似然。二者都表明:只要精心组织高维概率模型的依赖结构,它们就能保持可计算。

小结与参考文献

本章将精确密度建模作为对前面发展的潜变量模型与扩散模型的补充范式加以介绍,在这里,似然无需变分界、随机加噪过程或学习到的分数场即可直接计算。

我们首先研究了归一化流。其核心思想是使用可微、可逆的映射把一个简单的基础分布变换为复杂的数据分布。换元公式追踪局部体积的扩张或压缩如何改变概率密度。由此得出了流层的主要设计要求:可逆性、维度保持,以及易于计算的雅可比行列式。

接着我们考察了有代表性的流构造。平面流展示了简单的非线性秩一扰动如何保持雅可比行列式可算。仿射耦合层引入了一种更实用的机制:通过只变换输入的一部分并以其余部分为条件,它们提供了闭式逆与高效的对数行列式计算。将这些层与坐标混合操作堆叠起来,简单的局部变换就能构成具有精确似然计算与精确模型采样的、富有表达力的生成模型。

本章后半部分介绍了自回归模型,作为获得精确似然的另一条路线。自回归模型并不通过可逆映射变换密度,而是利用概率链式法则把联合密度分解为若干条件分布的乘积。这给出了无需潜变量、变分界或雅可比行列式的精确似然。其代价是必须施加一个顺序,且采样通常是顺序式的。我们还看到,掩码如何在神经网络架构中强制实现所需的有序信息流,使训练期间的似然项得以高效计算,同时保持自回归分解不变。

纵观这两个模型家族，核心信息是：精确似然之所以可能，靠的是结构性约束。在归一化流中，这些约束表现为可逆性与易于计算的雅可比行列式；在自回归模型中，它们表现为有序的条件依赖。两种方法都表明，只要精心组织高维概率模型的变换或依赖关系，它们就能保持可计算。

归一化流由 Rezende 与 Mohamed 作为通过可逆变换序列构造灵活分布的一般框架引入 [34]。重要的实用流架构包括 Dinh 等人的 NICE 与 RealNVP [8, 9]，它们发展了雅可比可算的基于耦合的变换；以及 Kingma 与 Dhariwal 的 Glow [23]，它使用可逆 1×1 卷积和可扩展的流设计扩展了这些思想。Papamakarios 等人 [32] 对归一化流及其在密度估计中的作用提供了更全面的综述。

自回归神经密度估计在现代生成建模中也发挥了重要作用。Germain 等人的 MADE [11] 展示了掩码如何在前馈神经网络中强制实现自回归结构。van den Oord 等人的 PixelRNN 与 PixelCNN [30] 发展了自回归图像模型，而 van den Oord 等人的 WaveNet [31] 则将因果自回归建模应用于原始音频。这些工作共同表明了基于精确似然的建模——无论通过可逆变换还是通过有序条件分解——持续的重要性。

第 8 章 8

超越似然：生成对抗网络与基于能量的模型

概述

在本书中，我们一直在研究以不同数学方式表示复杂数据分布的生成模型。PPCA 与 VAE 引入了潜变量建模与近似推断；扩散模型将这一视角扩展为顺序加噪与去噪过程；基于分数的模型则通过学习到的分数场和随机动力学重新诠释了去噪；归一化流与自回归模型展示了如何通过精心设计的结构化变换或因子分解来保持精确似然。

本章作为最后一章，转向一个不同的问题：当易处理的似然不再居于核心地位时，会发生什么？在许多重要的生成模型中，数据分布并不是通过一个可以逐点求值的显式归一化密度来表示的。相反，学习是通过比较、几何或未归一化的标量景观来进行的。

生成对抗网络 (Generative Adversarial Networks, GAN) 提供了这一转变的第一个例子。生成器学习产生难以与真实数据区分的样本，而判别器提供比较信号。Wasserstein GAN 对这一对抗思想进行了改进：用基于最优传输的分布间距离的几何概念，取代基于分类的比较。

基于能量的模型 (Energy-Based Models, EBM) 提供了超越显式似然的第二条路线。它们不直接定义归一化密度，而是为每个配置赋予一个标量能量。低能量标记数据空间中可信的区域，而高能量则抑制不可信的配置。于是，学习就变成了塑造能量景观的任务，而不是直接最大化某个易处理的似然。

本章的目的在于补全贯穿全书所建立的概念图景。GAN、Wasserstein GAN 和基于能量的模型表明：即使无法获得归一化概率，生成式学习依然可以推进——可以通过比较样本、度量几何差异，或者学习其梯度指引样本在数据空间中移动的景观。

概念图

本章研究不需要易处理的似然求值的生成模型。核心主题是：当概率是隐式的、未归一化的、或者被比较所取代时，学习如何进行。


- 我们首先把 GAN 介绍为通过比较进行学习。生成器把潜噪声映射为类似数据的样本，而判别器学习区分生成样本与真实数据。生成器通过努力使这种比较失败来进行学习。
- 接着，我们在分布层面解释这场对抗博弈。对于固定的生成器，最优判别器估计数据分布与生成器分布之间的局部密度比。把这个判别器代回 GAN 目标函数，便会揭示

Jensen-Shannon 散度。

- 接下来，我们考察 GAN 的优化及其局限。原始的极小极大生成器更新在判别器非常自信时可能产生微弱的梯度。非饱和损失改善了生成器的梯度，但模式坍塌和基于重叠的比较仍是重要的局限。
- 然后，我们从基于重叠的比较转向 Wasserstein 几何。Wasserstein GAN 用 1-Wasserstein 距离取代基于分类的差异度量，该距离衡量概率质量需要被搬运多远。由此引出评论者函数、Lipschitz 约束以及几何感知的训练。
- 本章随后转向作为标量景观的基于能量的模型。基于能量的模型为每个配置赋予一个标量能量 $E_\theta(x)$ 。低能量标记数据空间中可信的区域，而高能量抑制不可信的配置。该模型通常定义的是一个未归一化密度，而非易处理的似然。
- 我们随后推导 EBM 学习的对比结构。基于能量模型的极大似然会降低数据样本上的能量，并提高模型分布样本上的能量。这暴露出核心困难：学习需要从当前模型中采样。
- 最后，我们把能量、分数与扩散联系起来。在未归一化的能量模型中，低能量对应高概率，而分数正是能量的负梯度。因此，扩散模型可以被视为在多个噪声层级上学习类似能量梯度的方向，从而提供了一条超越显式似然的、稳定的多尺度路径。

本章发展的三条超越似然的路线在下图中作了可视化总结。

Beyond likelihoods at a glance



8.1 生成对抗网络：通过比较进行学习

到目前为止介绍的许多生成模型都依赖于显式概率分布。无论是通过精确似然，还是通过精心构造的近似，学习往往被表述为如何为观测数据分配高概率的问题。这提供了一个有原则的基础，但也对模型的设计与训练方式施加了很强的结构约束。

这自然引出一个更简单的问题：

为了生成逼真的数据，我们究竟需要计算概率吗？

如果目标是产生看起来像来自数据分布的样本，那么通过比较来学习也许就足够了。我们不必追问一个样本有多大的可能性，而可以追问它是否与真实数据无法区分。于是，学习通过匹配样本来进行，而不是通过求值密度来进行。

生成对抗网络 (GAN) [12] 正是围绕这一思想构建的。它们通过产生有说服力样本的能力来定义生成模型，而从不指定或求值任何概率密度。训练由比较来驱动：让生成样本与真实数据相互竞争，模型通过学习使二者越来越难以区分而不断改进。

8.1.1 作为隐式采样机制的生成器

一个 GAN 从一个生成器 (generator) 开始，它是一个参数化函数

$$x = G_\theta(z), \quad z \sim p(z),$$

其中 z 是从一个简单固定分布（如标准高斯分布或均匀分布）中抽取的潜变量。生成器 G_θ 通常由神经网络实现，它把这种简单的随机性来源映射到数据空间中。

映射

$$z \mapsto G_\theta(z)$$

把简单噪声变换为结构化的、类似数据的样本。通过采样 $z \sim p(z)$ 并将其送入 G_θ ，生成器诱导出 x 上的一个分布，记为 $p_\theta(x)$ 。至关重要的是，这个分布只是隐式地被定义：我们可以从中抽取样本，但通常无法在某一点求值其密度。

这使 GAN 有别于前面研究的基于似然的模型。与 VAE 不同，潜变量 z 不需要从数据中推断，也不学习任何后验分布。与扩散模型不同， z 并不来自某个前向加噪过程。与归一化流或自回归模型不同，生成器不必可逆，也不需要任何 Jacobian 行列式或对 $p_\theta(x)$ 的显式归一化。因此，生成器就像一个确定性模拟器：它规定的是如何生成数据，而不是某个给定数据点的可能性有多大。

一旦训练完成，从 GAN 采样非常直接。我们从潜噪声分布中抽取 $z \sim p(z)$ ，并计算 $x = G_\theta(z)$ 。判别器在生成时并不需要；它只是塑造生成器的训练信号。因此，GAN 提供的是直接采样，而不是直接的似然求值。

8.1.2 判别器与对抗博弈

如果一个模型只产生样本，一个根本性的问题立刻浮现：

我们如何判断这些样本好不好？

在基于似然的模型中，这个问题由概率来回答：如果样本在模型下获得高似然，它们就是好的。而在 GAN 中，似然无法获得，不存在可求值或可最大化的易处理函数 $p_\theta(x)$ 。

为了解决这个问题，GAN 引入了第二个可学习的组件：判别器 (discriminator)。判别器不度量概率，而是在两个样本来源之间提供一种数据驱动的比较：

$$x \sim p_{\text{data}}(x), \quad x = G_\theta(z), \quad z \sim p(z).$$

第一个来源由真实数据样本构成；第二个来源由生成样本构成。

形式上，判别器是一个函数

$$D_\phi : \mathbb{R}^d \rightarrow (0, 1),$$

由 ϕ 参数化。对于输入 x ，值 $D_\phi(x)$ 被解释为判别器对「 x 来自真实数据分布而非生成器」的置信度。于是，判别器被训练为一个二分类器：

$$D_\phi(x) \approx 1 \quad \text{对于真实数据}, \quad D_\phi(G_\theta(z)) \approx 0 \quad \text{对于生成数据}.$$

判别器本身不是目的。它既不定义概率密度，也不是我们训练完成后想要使用的最终对象。它的作用是提供真实样本与生成样本之间一个不断移动、自适应的差异度量。生成器只通过这种反馈来学习，调整自己的参数，使生成样本越来越难与真实样本区分。

这种交互被形式化为极小极大目标

$$\min_{\theta} \max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}} [\log D_\phi(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D_\phi(G_\theta(z)))].$$

判别器通过给真实样本打高分、给生成样本打低分来最大化该目标。生成器则努力最小化该目标，产生使 $D_\phi(G_\theta(z))$ 变大的样本，使判别器难以将它们判为假。

如何理解极小极大目标

表达式

$$\min_{\theta} \max_{\phi} \mathcal{L}(\theta, \phi)$$

应当被读作一个双人博弈。

对于固定的生成器参数 θ ，内层最大化在问：

面对当前的生成器，最好的判别器是什么？

这一步训练 D_ϕ 把真实样本与生成样本区分开。

然后，把判别器视为固定，外层最小化在问：

生成器应当如何改变，才能使真实样本与生成样本更难区分？

在实践中，这两步是交替进行的：我们在改进判别器与改进生成器之间轮换。

尽管这一目标函数形式上类似于分类损失，但它的作用在根本上是生成性的。判别器定义了两个分布之间的一种学习到的比较，而生成器重塑其输出分布，使这种比较逐渐消失。

8.1.3 最优判别器

要在分布层面理解对抗训练，考虑一个理想化设定：生成器 G_θ 固定。采样 $z \sim p(z)$ 并映射 $x = G_\theta(z)$ 会诱导出一个隐式的生成器分布 $p_\theta(x)$ 。在生成器固定的条件下，判别器的任务退化为在

$$p_{\text{data}}(x) \quad \text{与} \quad p_\theta(x).$$

之间进行二分类。

判别器目标于是可以写成

$$\mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{x \sim p_\theta} [\log(1 - D(x))].$$

把这些期望写成积分的形式，得到

$$\int p_{\text{data}}(x) \log D(x) dx + \int p_{\theta}(x) \log(1 - D(x)) dx.$$

由于该目标可以按 x 逐点分解，最优判别器可以逐点推导。对每个固定的 x ，我们关于标量 $D(x)$ 最大化

$$p_{\text{data}}(x) \log D(x) + p_{\theta}(x) \log(1 - D(x)).$$

对 $D(x)$ 求导得

$$\frac{p_{\text{data}}(x)}{D(x)} - \frac{p_{\theta}(x)}{1 - D(x)}.$$

令该导数为零，得

$$\frac{p_{\text{data}}(x)}{D(x)} = \frac{p_{\theta}(x)}{1 - D(x)}.$$

解出 $D(x)$ ，我们便得到最优判别器

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_{\theta}(x)}.$$

这个公式给出了一个重要解释：最优判别器是一个局部密度比对象，尽管模型并不能显式获得其中任何一个密度。图 8.1 直接展示了这一点：其输出在数据密度占优处趋向于一，在生成器密度占优处趋向于零，而在两个密度相等处等于二分之一。




图 8.1: **The optimal discriminator reflects local density balance.** For a fixed generator, $D^*(x) = p_{\text{data}}(x)/(p_{\text{data}}(x) + p_{\theta}(x))$. It approaches one where the data density dominates, zero where the generator density dominates, and equals $1/2$ where the two densities are equal.

8.1.4 从最优判别器到 Jensen–Shannon 散度

推导出固定生成器下的最优判别器之后，我们可以追问：在整体分布的层面上，这场对抗博弈究竟代表什么？为此，我们把判别器目标写成一个值函数（value function），它依据判别器区分真实样本与生成样本的能力为「生成器–判别器」这一对打分。

我们定义

$$V(G_\theta, D) = \mathbb{E}_{x \sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{x \sim p_\theta}[\log(1 - D(x))].$$

对于固定的 G_θ ，关于 D 最大化 $V(G_\theta, D)$ 给出针对该生成器的最优判别器。如果我们随后在这个最优判别器处对值函数求值，就能识别出生成器隐式最小化的分布差异。

利用

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_\theta(x)},$$

经过代数化简，我们得到

$$V(G_\theta, D^*) = -\log 4 + 2 \text{JS}(p_{\text{data}} \| p_\theta),$$

其中 $\text{JS}(\cdot \| \cdot)$ 表示 Jensen-Shannon 散度。

常数项 $-\log 4$ 不依赖于生成器，因此不影响优化。于是，在判别器为最优的理想化设定下，GAN 训练等价于最小化数据分布与生成器分布之间的 Jensen-Shannon 散度。

上面的表达式引入了概率分布之间的一种新的散度：*Jensen-Shannon* 散度。为了理解它，回顾一下 Kullback-Leibler 散度是有帮助的——它曾作为证据下界 (ELBO) 的一部分出现在 VAE 一章中。KL 散度通过

$$\text{KL}(p \| q) = \int p(x) \log \frac{p(x)}{q(x)} dx.$$

比较两个分布。它度量的是用 q 近似 p 的代价有多大。然而，KL 散度是不对称的：

$$\text{KL}(p \| q) \neq \text{KL}(q \| p),$$

而且它对支撑集不匹配很敏感。若在某个区域 $q(x) = 0$ 而 $p(x) > 0$ ，则 $\text{KL}(p \| q)$ 变为无穷大。

Jensen-Shannon 散度修改了这种比较方式：把两个分布都与一个共同的中间分布进行比较。给定两个分布 p 与 q ，定义其混合

$$m(x) = \frac{1}{2}(p(x) + q(x)).$$

这个混合可以理解为：先以等概率在 p 与 q 之间做选择，然后从被选中的分布中采样。

Jensen-Shannon 散度随后定义为

$$\text{JS}(p \| q) = \frac{1}{2}\text{KL}(p \| m) + \frac{1}{2}\text{KL}(q \| m).$$

于是，JS 散度不要求一个分布直接解释另一个分布，而是衡量每个分布距离二者共享的混合分布有多远。这使它是对称的：

$$\text{JS}(p \| q) = \text{JS}(q \| p),$$

而且是有界的：

$$0 \leq \text{JS}(p \| q) \leq \log 2.$$

这恰好就是把最优判别器代回原始 GAN 值函数后所出现的散度。在判别器为最优的理想化设定下，生成器并不是在最大化似然，而是在调整其隐式分布 p_θ ，以降低

$$\text{JS}(p_{\text{data}} \parallel p_\theta).$$

这揭示了对抗训练的分布意义。GAN 并不构造显式密度；它们执行的是通过比较进行的分布匹配。判别器估计真实分布与生成分布的可区分程度，而生成器通过努力降低这种可区分程度来学习。

全局最优在

$$p_\theta(x) = p_{\text{data}}(x).$$

时达到。此时，

$$D^*(x) = \frac{1}{2}$$

处处成立，因为真实样本与生成样本已无法区分。

8.2 几何优化与 Wasserstein GAN

前面的分析表明，在最优判别器下，原始 GAN 目标对应于最小化数据分布与生成器隐式分布之间的 Jensen-Shannon 散度。这给出了一个清晰的理论解释，但也暴露出一个局限：当 p_{data} 与 p_θ 几乎没有重叠或完全没有重叠时，JS 散度可能饱和，使判别器几乎完美地区分开真实样本与生成样本，却几乎无法给生成器指明朝数据分布移动的方向。这促使了关键的转变：从基于重叠的比较转向几何距离。Wasserstein GAN [2] 把「两个分布是否可区分」的问题，替换为「要把一个分布变成另一个分布，概率质量必须被搬运多远」的问题。

8.2.1 生成器优化与非饱和损失

在转向 Wasserstein GAN 之前，我们先讨论原始 GAN 框架内一种常见的实践做法：修改生成器的损失，以改善训练过程中的梯度信号。原始 GAN 目标写为极小极大问题

$$\min_{\theta} \max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}} [\log D_{\phi}(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D_{\phi}(G_{\theta}(z)))].$$

对判别器而言，其解释很直接：给真实样本赋高值、给生成样本赋低值会得到奖励。对生成器而言，情况要更微妙一些。

如果我们固定判别器，并关于生成器参数 θ 最小化同一个值函数，那么唯一依赖于 θ 的项是

$$\mathbb{E}_{z \sim p(z)} [\log(1 - D_{\phi}(G_{\theta}(z)))].$$

这一目标要求生成器降低判别器对「生成样本为假」的置信度。

困难出现在训练早期。在这个阶段，判别器往往能自信地识别生成样本：

$$D_{\phi}(G_{\theta}(z)) \approx 0.$$

于是

$$1 - D_{\phi}(G_{\theta}(z)) \approx 1, \quad \log(1 - D_{\phi}(G_{\theta}(z))) \approx 0.$$

因此, 生成器目标在这一区域接近平坦, 即便其样本仍然很差, 传回生成器的梯度也可能变得非常小。

正因如此, GAN 通常使用一个不同的生成器目标来训练, 称为非饱和损失(non-saturating loss):

$$\min_{\theta} \mathbb{E}_{z \sim p(z)} [-\log D_{\phi}(G_{\theta}(z))].$$

这个损失并不是把前一个表达式代数化简得到的。相反, 它把生成器的目标从降低判别器的「假」置信度改为提高其「真」置信度。

这两个目标并不相同, 但它们具有同样的理想平衡态: 生成样本应变得与真实数据无法区分。它们的差别在于梯度行为。当

$$D_{\phi}(G_{\theta}(z)) \approx 0,$$

时, 非饱和项

$$-\log D_{\phi}(G_{\theta}(z))$$

很大, 于是生成器收到强得多的学习信号。这就是实践中更常采用非饱和损失的原因, 尽管原始的极小极大目标提供了与 Jensen-Shannon 散度之间更清晰的理论联系。

这一优化行为有助于解释 GAN 的优势与弱点。从积极的一面看, 判别器会惩罚使生成样本显得不真实的特征, 因此对抗训练能够催生锐利、在视觉上有说服力的输出, 而不是模糊的平均。从消极的一面看, 这一机制可能导致模式坍塌(mode collapse)。由于生成器以欺骗判别器为目标进行训练, 它可能只令人信服地建模数据分布的一个子集。如果这个子集已足以迷惑判别器, 其他模式就可能被忽略。

基于似然的模型在未能覆盖观测模式时会受到惩罚, 因为似然依赖于为数据分配概率质量。相比之下, GAN 优化的是可区分性而非显式的概率覆盖。因此, 非饱和损失改善了生成器的梯度, 但并没有改变对抗比较的底层几何。当两个分布几乎没有重叠时, 基于分类的差异度量仍然主要只说明它们可区分, 而不能说明一个应如何向另一个移动。这就引出了分布差异的一种更具几何性的度量。

8.2.2 从重叠到 Wasserstein 几何

为了发展这一思想, 用几何方式来思考概率分布是有益的。不要把分布视为静态密度, 而要想象其概率质量是可以在空间中移动的东西。如果只需质量的微小位移就能把一个分布变换为另一个分布, 那么这两个分布应当被认为很接近。如果大量质量必须经过长距离搬运, 那么它们就应当被认为相距很远。

Wasserstein 距离将这一直觉形式化。在 Wasserstein GAN 所采用的形式中, 相关的对象是 1-Wasserstein 距离, 也称为推土机距离(Earth Mover's distance)。它度量把概率质量从一个分布搬运到另一个分布的最小代价, 代价与移动距离成正比。

一个关键的理论结果——Kantorovich-Rubinstein 对偶——给出了表达该距离的一种实用方式。对于 $\mathbb{R}^d$ 上的两个概率分布 p 与 q , 1-Wasserstein 距离可以写成

$$W(p, q) = \sup_{\|f\|_L \leq 1} (\mathbb{E}_{x \sim p}[f(x)] - \mathbb{E}_{x \sim q}[f(x)]).$$

这里, f 是一个实值打分函数, 而约束

$$\|f\|_L \leq 1$$

意味着 f 必须是 1-Lipschitz 的：其函数值相对于输入空间中距离的变化速率不能超过单位速率。

表达式

$$\mathbb{E}_{x \sim p}[f(x)] - \mathbb{E}_{x \sim q}[f(x)]$$

度量打分函数平均而言能把两个分布分得多开。上确界意味着我们选择在满足 Lipschitz 约束的前提下，能把它们分得尽可能开的打分函数。

这个约束是必不可少的。没有它，打分函数就可以给来自一个分布的样本赋任意大的值，给来自另一个分布的样本赋任意小的值，使比较失去意义。Lipschitz 约束迫使分差反映数据空间的几何：只有当对应的点相距很远时，才允许出现大的分差。

请注意，这与基于分数的扩散模型中的分数不同：在扩散模型中，分数指 $\nabla_x \log p(x)$ ，即对数密度的梯度；而在 WGAN 中，评论者 (critic) 的输出 $f_\phi(x)$ 是一个用于比较的实值标量，而非概率；评论者通过其 Lipschitz 行为受到约束，而不是通过概率归一化受到约束。

Wasserstein 距离的一个具体例子

考虑一个一维例子： p 把全部质量放在 $x = 0$ ，而 q 把全部质量放在 $x = 10$ 。从 p 采样总是返回 0，从 q 采样总是返回 10，因此

$$\mathbb{E}_{x \sim p}[f(x)] = f(0), \quad \mathbb{E}_{x \sim q}[f(x)] = f(10), \quad W(p, q) = \sup_{\|f\|_L \leq 1} (f(0) - f(10)).$$

约束 $\|f\|_L \leq 1$ 意味着

$$|f(x_1) - f(x_2)| \leq |x_1 - x_2| \quad \text{对所有 } x_1, x_2.$$

因此，每个可行的 f 都满足

$$f(0) - f(10) \leq |0 - 10| = 10.$$

这个上界由 $f(x) = -x$ 达到，因为

$$f(0) - f(10) = 0 - (-10) = 10.$$

所以 $W(p, q) = 10$ ，与搬运直觉完全吻合：全部概率质量都必须被移动距离 10。

这个例子说明了为什么 Wasserstein 距离在分布不重叠时依然能提供信息。基于重叠的散度可以检测到支撑集不相交，但未必能反映两个分布是相距一个单位还是相距十个单位。相比之下，Wasserstein 距离直接度量空间间隔。图 8.2 针对一个平移高斯分布的连续族展示了同样的区别：当重叠消失时，JS 几近饱和，而 Wasserstein 距离则持续跟踪空间间隔。




图 8.2: JS can saturate while Wasserstein remains geometric. The panels compare equal-variance Gaussian distributions as their means move apart. As overlap disappears, the JS divergence approaches its upper bound $\log 2$ and becomes insensitive to further separation. For these translated distributions, the 1-Wasserstein distance is $W_1 = \Delta$, so it continues to measure how far probability mass must move.

8.2.3 Wasserstein GAN 目标

Wasserstein 距离的对偶刻画直接导出一个实用的对抗目标。如果生成器诱导出分布 p_θ ，那么数据分布与生成器分布之间的 Wasserstein 距离可以写成

$$W(p_{\text{data}}, p_\theta) = \sup_{\|f\|_L \leq 1} (\mathbb{E}_{x \sim p_{\text{data}}} [f(x)] - \mathbb{E}_{x \sim p_\theta} [f(x)]).$$

由于 p_θ 的样本由

$$x = G_\theta(z), \quad z \sim p(z),$$

产生，我们可以写

$$\mathbb{E}_{x \sim p_\theta} [f(x)] = \mathbb{E}_{z \sim p(z)} [f(G_\theta(z))].$$

Wasserstein GAN 用一个神经网络 f_ϕ 来表示打分函数 f ，并优化

$$\min_{\theta} \max_{\phi \in \mathcal{L}} \mathbb{E}_{x \sim p_{\text{data}}} [f_\phi(x)] - \mathbb{E}_{z \sim p(z)} [f_\phi(G_\theta(z))],$$

其中 $\mathcal{L}$ 表示使 f_ϕ 满足所需 Lipschitz 约束的参数取值集合。

关于 ϕ 的最大化寻找一个尽可能强地分离真实样本与生成样本、同时尊重数据空间几何的打分函数。关于 θ 的最小化则更新生成器，使这种分离变小。

至此，术语发生了变化。在原始 GAN 中，评估样本的网络被称为判别器。其输出

$$D_\phi(x) \in (0, 1)$$

被解释为 x 为真实数据的概率。而在 Wasserstein GAN 中，对应的网络被称为评论者 (critic)。它输出一个实值分数

$$f_\phi(x) \in \mathbb{R},$$

而不是概率。这里没有 sigmoid 输出，没有二分类解释，也不要求分数被归一化。只有评论者取值的差异才是重要的。

这样看，评论者是对 Wasserstein 距离中最优打分函数的神经网络近似。它的目的不是做出非真即假的硬性判决，而是赋予分数使其平均差异反映两个分布之间的几何间隔。真实样本平均而言应获得比生成样本更高的分数，同时约束条件保证分数在数据空间中不能以任意快的速度变化。由于 Wasserstein 距离随生成器分布的移动而连续变化，即使 p_θ 与 p_{data} 不重叠，生成器仍然可以获得有用的梯度，因此优化由几何接近程度引导，而不再仅由重叠引导。

与原始 GAN 一样，评论者只在训练期间使用。一旦生成器学习完成，采样同样通过直接抽取 $z \sim p(z)$ 并返回 $G_\theta(z)$ 来完成。

8.2.4 强制施加 Lipschitz 约束

剩下的挑战是实践性的：训练时如何对评论者强制施加 Lipschitz 约束？回顾一下，该约束保证评论者的分数以受控速率变化，从而使分差反映几何距离而非任意的尺度缩放。神经网络并不会自动满足这一性质。

原始的 WGAN 通过权重裁剪 (weight clipping) 来强制该约束，即把评论者的每个参数限制在一个固定区间内。这一做法虽然简单，却是控制 Lipschitz 常数的一种粗糙方式：它可能削弱评论者的容量，并可能导致不稳定的优化。

一种更有效的替代方案是梯度惩罚 (gradient penalty)，由 WGAN-GP [13] 提出。梯度惩罚不直接约束参数，而是约束评论者的输入-输出行为。其思想是控制评论者的分数对其输入微小变化的响应速度。

在评论者的训练目标中加入形如

$$\lambda \mathbb{E}_{\hat{x}} \left[(\|\nabla_{\hat{x}} f_\phi(\hat{x})\|_2 - 1)^2 \right]$$

的惩罚项，其中 $\hat{x}$ 沿真实样本与生成样本之间的直线插值采样。

梯度

$$\nabla_{\hat{x}} f_\phi(\hat{x})$$

度量评论者的分数对输入无穷小变化的敏感程度。它的欧几里得范数因此就是评论者在 $\hat{x}$ 处的局部变化率，即局部斜率。对 $\|\nabla_{\hat{x}} f_\phi(\hat{x})\|_2$ 偏离一的值进行惩罚，可促使评论者在与比较真实样本和生成样本最相关的区域内以受控的速率平滑地变化。

插值点 $\hat{x}$ 位于真实样本与生成样本之间，恰好是评论者必须学习如何比较这两个分布的地方。沿着这些路径强制施加约束，既稳定了训练，又保持了 Wasserstein 距离的几何解释。系数 λ 控制惩罚强度：值越大，约束施加得越强；值越小，则允许更大的灵活性。

通过这种方式强制施加 Lipschitz 约束，带梯度惩罚的 WGAN 在保持 Wasserstein 距离基于搬运的含义的同时，获得了更可靠的训练动态。更广泛地说，它们表明生成式学习不

必依赖显式似然或归一化密度；它可以由一个学习到的实值函数来引导，该函数的几何把生成样本推向数据分布。

这也为基于能量的模型提供了自然的过渡。与 WGAN 一样，基于能量的模型使用实值函数来比较、排序或引导样本。但它们不是把这一点表述为一场对抗博弈，而是通过未归一化的能量景观来定义分布。下面我们转向这一视角。

8.3 基于能量的模型：基础与学习

前面几节考察的是通过比较进行学习的生成模型。在 GAN 中，判别器为区分真实样本与生成样本提供一个学习到的检验。在 Wasserstein GAN 中，这种比较被一个几何评论者取代，其取值反映概率质量必须被搬运多远。两种方法都回避了显式的似然求值，转而通过对样本的相对评估来学习。

基于能量的模型 [24] 把这一思想又推进了一步。它们不定义生成器、判别器或显式似然，而是从一个定义在数据空间上的单一标量函数出发：一个能量函数 (energy function)。该函数为每个配置 x 赋予一个值

$$E_{\theta}(x) \in \mathbb{R}$$

较低的能量表示与数据结构更相符，较高的能量表示不可信。

能量函数被有意地设计为不受约束的。它不必为正、不必有界、也不必归一化，而且它本身并不定义概率分布。因此在这一阶段，能量不应被解释为概率。最好把它理解为一种偏好、代价或兼容性的度量。类似数据的配置应位于低能区域，而不真实的配置应位于高能区域。

这给出了一种几何化的建模观。基于能量的模型在数据空间上定义了一个景观：

$$\text{低能量} \iff \text{可信的配置}, \quad \text{高能量} \iff \text{不可信的配置}.$$

于是，学习的含义就是塑造这个景观，使观测数据落在山谷之中，而远离数据的区域被赋予更高的能量。

8.3.1 能量作为建模基元

基于能量的模型中的关键建模基元是标量能量函数

$$E_{\theta} : \mathbb{R}^d \rightarrow \mathbb{R}.$$

与归一化流或自回归模型不同，这个函数不需要提供精确的密度。与 VAE 不同，它不需要显式的潜变量后验。与 GAN 不同，它不需要在对抗博弈中训练一个单独的判别器。模型直接通过一个标量景观来指定。

只有相对的能量差异是重要的。如果我们给能量函数加上一个常数 c ,

$$\tilde{E}_{\theta}(x) = E_{\theta}(x) + c,$$

那么所有配置都被移动同样的量，点从低到高的能量次序不变。由于模型的行为取决于哪些配置相对于其他配置更受偏好，这一常数平移不会产生实质影响。

这种相对性很重要。能量函数并不是要为每个点赋予一个绝对的概率值。相反，它编码的是偏好：哪些配置应被鼓励，哪些应被抑制。在这个意义上，基于能量的建模问的是与显式密度建模不同的问题：

模型应当把低能区域放在数据空间的哪些地方？

这个问题的答案从数据中学习得到。

8.3.2 从能量到未归一化分布

尽管能量函数本身不是概率分布，但可以通过 Boltzmann 形式将其与概率分布联系起来：

$$p_{\theta}(x) = \frac{1}{Z_{\theta}} \exp(-E_{\theta}(x)),$$

其中

$$Z_{\theta} = \int \exp(-E_{\theta}(x)) dx$$

是归一化常数，也叫配分函数 (partition function)。

负指数把低能量转换成大的正权重，而配分函数执行一次全局归一化。图 8.3 展示了从标量能量到未归一化权重、再到归一化密度的这一映射；它也清楚地说明了为什么给所有能量加上常数不会改变最终密度。




图 8.3: From energy to normalised density. Low-energy regions receive large unnormalised weight $\exp(-E_{\theta}(x))$, and division by Z_{θ} turns this into a density without changing its shape. Adding a constant to all energies rescales the weights and Z_{θ} by the same factor, leaving the normalised density unchanged.

困难在于， Z_θ 在高维空间中通常是难处理的。计算它需要对所有可能的配置积分：

$$Z_\theta = \int \exp(-E_\theta(x)) dx.$$

对于图像、音频、文本表示或其他高维数据，这个积分一般无法精确求值。

这就是基于能量建模的核心权衡。由于避开了精确密度模型所需的结构约束，能量函数可以非常灵活。但这种灵活性以归一化为代价：模型通常定义的是一个未归一化（unnormalised）密度

$$p_\theta(x) \propto \exp(-E_\theta(x)),$$

而不是一个易处理的归一化似然。

这把基于能量的模型与上一章研究的精确密度模型区分开来。归一化流与自回归模型经过精心设计，使 $p_\theta(x)$ 可以被精确求值。基于能量的模型则把重点放在能量景观本身。即使归一化常数未知，相对的能量差异与能量梯度也可能是有用的。

8.3.3 学习能量景观

在基于能量的模型中，学习的含义是塑造能量函数，使其反映数据的结构。假设我们观测到样本

$$x \sim p_{\text{data}}(x).$$

一个理想的能量函数应当为这些观测样本赋予低能量：

$$E_\theta(x) \text{ 对 } x \sim p_{\text{data}} \text{ 而言较小.}$$

但仅有这一条件还不够。如果只是处处降低能量，模型将无法区分类似数据的配置与不可信的配置。因此学习必须具有对比性：在数据样本上降低能量，同时在其他地方提高能量。

非正式地说，期望的行为是

$$E_\theta(x) \text{ 在数据上低, } E_\theta(x) \text{ 在远离数据处高.}$$

正是这种对比结构使基于能量的学习具有意义。模型不能仅仅奖励观测数据；它还必须学习哪些备选配置应当被抑制。

理解这一点的一个有用方式是考察能量梯度

$$\nabla_x E_\theta(x).$$

该梯度描述能量在数据空间中如何局部变化。沿方向

$$-\nabla_x E_\theta(x)$$

移动会降低能量，把一个配置引向模型认为更可信的区域。因此，能量景观不仅定义了一个标量的偏好取值，还定义了一个局部的改进方向。

这把基于能量的模型与前面为 GAN 和基于分数的模型发展的几何视角联系起来。在 Wasserstein GAN 中，评论者赋予实值分数，其差异引导生成器。在基于能量的模型中，能量函数赋予标量值，其梯度规定了配置应当如何在数据空间中移动。这两个思想相关但不相同：WGAN 的评论者被训练用于分离两个分布，而能量函数旨在定义一个可信度景观。

8.3.4 极大似然与对比梯度

尽管基于能量的模型常被当作未归一化模型来讨论，Boltzmann 形式仍能提供一个有原则的学习目标。如果

$$p_{\theta}(x) = \frac{1}{Z_{\theta}} \exp(-E_{\theta}(x)),$$

那么极大似然要求最大化

$$\mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\theta}(x)].$$

代入基于能量的密度，得到

$$\log p_{\theta}(x) = -E_{\theta}(x) - \log Z_{\theta},$$

因此

$$\mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\theta}(x)] = -\mathbb{E}_{x \sim p_{\text{data}}} [E_{\theta}(x)] - \log Z_{\theta}.$$

第一项的效果很直观：最大化它会降低数据样本的能量。第二项则防止「处处降低能量」这一平凡解，因为当过多空间被赋予低能量时，配分函数会增大。于是极大似然平衡了两种力量：

在数据上降低能量 以及 控制其他地方的能量.

对目标关于 θ 求导可以让这一点更清楚。数据项的梯度为

$$-\nabla_{\theta} \mathbb{E}_{x \sim p_{\text{data}}} [E_{\theta}(x)] = -\mathbb{E}_{x \sim p_{\text{data}}} [\nabla_{\theta} E_{\theta}(x)].$$

对于配分函数项，我们使用

$$Z_{\theta} = \int \exp(-E_{\theta}(x)) dx.$$

求导得

$$\begin{aligned} \nabla_{\theta} \log Z_{\theta} &= \frac{1}{Z_{\theta}} \nabla_{\theta} \int \exp(-E_{\theta}(x)) dx \\ &= \frac{1}{Z_{\theta}} \int \exp(-E_{\theta}(x)) (-\nabla_{\theta} E_{\theta}(x)) dx \\ &= -\mathbb{E}_{x \sim p_{\theta}} [\nabla_{\theta} E_{\theta}(x)]. \end{aligned}$$

由于对数似然中包含 $-\log Z_{\theta}$ ，它对梯度的贡献是

$$-\nabla_{\theta} \log Z_{\theta} = \mathbb{E}_{x \sim p_{\theta}} [\nabla_{\theta} E_{\theta}(x)].$$

把两项合并，极大似然梯度成为

$$\boxed{\nabla_{\theta} \mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\theta}(x)] = -\mathbb{E}_{x \sim p_{\text{data}}} [\nabla_{\theta} E_{\theta}(x)] + \mathbb{E}_{x \sim p_{\theta}} [\nabla_{\theta} E_{\theta}(x)]}.$$

这个表达式是基于能量学习的核心。它由两部分组成：

$$\text{数据项} \quad -\mathbb{E}_{p_{\text{data}}} [\nabla_{\theta} E_{\theta}(x)], \quad \text{模型项} \quad +\mathbb{E}_{p_{\theta}} [\nabla_{\theta} E_{\theta}(x)].$$

数据项降低观测样本的能量。模型项提高从当前模型分布中抽取的样本的能量。这常被描述为正相 (positive phase) 与负相 (negative phase) 之间的对比：正相使数据更受偏好，而负相则对抗模型自身目前赋予过多概率质量的那些配置。

这一对比梯度暴露了基于能量模型的核心实践困难。对数据分布的期望可以用训练集轻易近似。而对模型分布的期望

$$\mathbb{E}_{x \sim p_\theta} [\nabla_\theta E_\theta(x)]$$

则要困难得多，因为从 $p_\theta(x) \propto \exp(-E_\theta(x))$ 中抽样本身就是一个不平凡的问题。

这造成了学习与采样之间的耦合。要改进能量函数，我们需要来自当前模型的样本；但要抽到好样本，我们又需要一个已经被塑造得足够好的能量景观。这种循环依赖正是基于能量的模型功能强大却难以训练的主要原因之一。

下一节将更明确地发展这一联系。由于基于能量的模型不提供直接的采样器，生成通常被表述为在能量景观上的移动。这就自然引出能量梯度动力学、Langevin 采样，以及基于能量的建模与前面研究过的基于分数的扩散方法之间的联系。

8.4 能量梯度、分数场与扩散

上一节表明，基于能量的模型通过一个未归一化的能量景观间接地定义概率分布

$$p_\theta(x) \propto \exp(-E_\theta(x)).$$

这带来了极大的建模灵活性，但也造成了一个实践困难：模型不提供直接的采样机制。要生成样本，我们必须在能量景观本身之中移动。

这正是能量梯度变得核心的地方。标量能量 $E_\theta(x)$ 告诉我们一个配置有多可信，而其梯度

$$\nabla_x E_\theta(x)$$

告诉我们能量在数据空间中如何局部变化。沿方向

$$-\nabla_x E_\theta(x)$$

移动会降低能量，因而把一个配置移向模型认为更可信的区域。在这个意义上，能量的负梯度扮演着局部驱动力的角色。

本节把这一思想与书中前面发展的基于分数的方法联系起来。要点简单但重要：对于形如 $p(x) \propto \exp(-E(x))$ 的分布，分数恰好就是能量的负梯度，

$$\nabla_x \log p(x) = -\nabla_x E(x).$$

因此，基于能量的模型与基于分数的模型是紧密相连的。它们的差别不在于所使用的局部方向，而更多在于这一方向如何被参数化、学习和用于生成。

8.4.1 作为能量引导动力学的采样

基于能量的模型为可信的配置赋予低能量，但它并不直接告诉我们如何从对应分布中抽取独立的样本。与归一化流不同，这里不存在从基础分布到数据空间的逆映射。与自回归模型不同，这里不存在可以顺序采样的从左到右的条件乘积。取而代之的是，采样通常被表述为一个迭代式的动力学过程。

基本思想是初始化一个配置 x_0 ，并反复更新它，使其向低能区域移动。一个纯确定性的更新会具有如下形式

$$x_{t+1} = x_t - \eta \nabla_x E_\theta(x_t),$$

其中 $\eta > 0$ 是步长。这类似于梯度下降，只是现在的下降是在数据空间而非参数空间中进行。被移向低能的是配置 x_t 本身。

然而，仅靠确定性下降不足以完成采样。它可能陷入能量景观的局部极小值，而无法探索多个可信的区域。为了得到采样过程，需要加入随机性：

$$x_{t+1} = x_t - \eta \nabla_x E_\theta(x_t) + \sqrt{2\eta} \xi_t, \quad \xi_t \sim \mathcal{N}(0, I).$$

这就是与该能量函数相关联的离散 Langevin 式更新。

确定性项

$$-\eta \nabla_x E_\theta(x_t)$$

把当前配置移向更低的能量。噪声项

$$\sqrt{2\eta} \xi_t$$

注入随机性，防止动力学简单地坍缩到单个极小值，使其能够探索更广阔的能量景观。在适当条件下并采用恰当的时间解释，这种「梯度加噪声」的动力系统能够以基于能量的分布作为其平稳分布。

这与基于分数的一章中研究过的 Langevin 思想相同。唯一的改变在于漂移场的写法。在那里，漂移用分数 $\nabla_x \log p(x)$ 表达；在这里，它用能量的负梯度 $-\nabla_x E_\theta(x)$ 表达。下一小节将明确给出这一联系。

8.4.2 能量梯度与分数

回顾一下，密度 $p(x)$ 的分数是

$$s(x) = \nabla_x \log p(x).$$

对于基于能量的模型，

$$p_\theta(x) = \frac{1}{Z_\theta} \exp(-E_\theta(x)).$$

取对数得

$$\log p_\theta(x) = -E_\theta(x) - \log Z_\theta.$$

现在关于 x 求导。由于配分函数 Z_θ 依赖于 θ 而不依赖于 x ，我们有

$$\nabla_x \log Z_\theta = 0.$$

因此，

$$\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x).$$

这一恒等式是基于能量的建模与基于分数的建模之间的桥梁。基于能量分布的分数场恰好是其能量函数的负梯度。因此，移向更高概率所使用的局部方向，与移向更低能量所使用的方向是同一个。

差别在于这一对象是如何表示的。在经典的基于能量模型中，我们参数化一个标量函数 $E_\theta(x)$ ，再通过求导得到驱动向量场：

$$x \longmapsto -\nabla_x E_\theta(x).$$

在基于分数的模型中，我们常常直接参数化向量场本身：

$$s_{\theta}(x) \approx \nabla_x \log p(x).$$

于是，能量模型从标量景观出发导出向量场，而分数模型往往直接学习向量场本身。

这一区分是有用的。标量能量自动给出一个守恒的梯度场：向量场来自单个底层函数的梯度。直接学习的分数网络作为向量场更加灵活，但除非施加额外结构，它未必总能被显式表示为某个标量能量的梯度。不过，就生成建模而言，二者的概念联系依然紧密：两种方法学习的都是引导样本移向数据密度更高区域的局部方向。

8.4.3 分数匹配作为能量梯度学习

上一节表明，基于能量模型的极大似然导出一个涉及模型分布样本的对比梯度。由于从模型中采样本身就很难，这带来了实践上的困难。分数匹配 (score matching) [19] 提供了一条不同的路线：它不匹配归一化概率，而是匹配局部分数场。

在基于分数的一章中，我们曾借助 Fisher 散度与分部积分详细推导了分数匹配。这里只需回忆基于能量视角所需的结论。目标是学习一个模型分数

$$s_{\theta}(x) \approx \nabla_x \log p_{\text{data}}(x).$$

对于基于能量的模型，

$$s_{\theta}(x) = \nabla_x \log p_{\theta}(x) = -\nabla_x E_{\theta}(x).$$

因此，分数匹配可以解释为学习一个能量景观，其负梯度与数据分数相吻合。

经典的分数匹配目标在不依赖 θ 的常数意义下可写为：

$$J_{\text{SM}}(\theta) = \mathbb{E}_{x \sim p_{\text{data}}} \left[\frac{1}{2} \|s_{\theta}(x)\|_2^2 + \nabla_x \cdot s_{\theta}(x) \right].$$

代入

$$s_{\theta}(x) = -\nabla_x E_{\theta}(x)$$

得到能量形式的目标

$$J_{\text{SM}}(\theta) = \mathbb{E}_{x \sim p_{\text{data}}} \left[\frac{1}{2} \|\nabla_x E_{\theta}(x)\|_2^2 - \nabla_x^2 E_{\theta}(x) \right],$$

其中

$$\nabla_x^2 E_{\theta}(x) = \sum_{j=1}^d \frac{\partial^2 E_{\theta}(x)}{\partial x_j^2}$$

是能量函数的 Laplacian。

重点不在于此前已经详细推导过的具体过程，而在于被匹配的对象发生了变化。极大似然比较的是归一化概率分布，并产生一个模型期望项。分数匹配比较的是对数密度的局部梯度，并避开了配分函数，因为

$$\nabla_x \log Z_{\theta} = 0.$$

用能量的语言来说，它通过导数学习能量景观在数据样本附近的结构，而不要求对归一化密度进行精确求值。

这就是为什么分数匹配从基于能量的视角看如此自然。它不求问一个数据点的概率，而是求问概率应当沿哪个局部方向增长，或者说能量应当沿哪个方向下降。

8.4.4 扩散作为多尺度的能量梯度学习

基于能量的模型与基于分数的扩散之间的关系现在可以清楚地陈述了。基于能量的模型定义一个标量景观 $E_\theta(x)$ 。如果这个景观对应于未归一化密度

$$p_\theta(x) \propto \exp(-E_\theta(x)),$$

那么它的分数就是

$$\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x).$$

于是, Langevin 采样中所使用的局部方向, 正是基于分数的模型试图直接学习的对象: 一个指向更高概率、等价地指向更低能量的方向。

从这个角度看, 基于分数的扩散模型 [38, 39] 可以被视为在一族带噪分布的层级上学习依赖时间的、类似能量梯度的方向。因此, 差别不在于局部几何本身, 而在于这一几何如何被表示和学习。基于能量的模型参数化一个标量能量, 并通过求导导出向量场。基于分数的模型通常直接参数化向量场。扩散模型则更进一步, 学习一个依赖时间的分数场

$$s_\theta(x, t) \approx \nabla_x \log p_t(x),$$

其中 $p_t(x)$ 是数据被加噪至时间 t 后得到的分布。

从基于能量的视角看, 每个带噪分布 p_t 都可对应一个隐式的能量景观

$$E_t(x) = -\log p_t(x) + C_t,$$

其中 C_t 是任意常数。由于只有梯度是重要的, 这一常数不产生任何影响, 并且

$$\nabla_x \log p_t(x) = -\nabla_x E_t(x).$$

因此, 扩散模型可以解释为学习

$$s_\theta(x, t) \approx -\nabla_x E_t(x),$$

即以噪声水平为索引的一整族能量景观的负梯度。

这一视角之所以有用, 是因为前向加噪过程创造了一个多尺度的分布层级。在大的噪声水平下, p_t 光滑且接近一个简单分布, 对应的能量景观宽阔而规则。在小的噪声水平下, p_t 更接近数据分布, 能量景观因而包含更精细的结构。因此, 扩散训练学习的是这一序列的局部几何:

粗糙的能量景观 $\longrightarrow$ 精细的数据级能量景观.

在这个意义上, 扩散模型可以被视为多尺度能量梯度学习的一种实用且稳定的形式。它不是为数据分布学习一个结构尖锐的能量景观并直接从中采样, 而是把问题分散到许多被平滑过的分布上。高噪声水平提供全局引导, 而低噪声水平提供细致的局部修正。

这也解释了为什么扩散模型回避了基于能量学习的一些传统困难。经典 EBM 的极大似然需要来自当前模型分布的样本来估计负相。扩散模型则通过一个已知的前向损坏过程创建带噪训练对, 并学习跨噪声水平的去噪方向。其结果依然与能量梯度深刻相关, 但训练过程要稳定得多。

因此, 基于能量的模型为生成建模的这一部分提供了更宏观的景观视角。它们通过标量兼容性函数来描述分布, 而基于分数的扩散则可被视为学习并使用相应能量梯度方向的一种特别有效的现代方式, 这些方向跨越了从噪声到数据的多尺度路径。

小结与参考文献

本章走出了基于似然的生成建模，介绍了通过比较、几何和未归一化景观进行学习的模型。GAN 展示了生成器如何通过对抗比较而非似然最大化来训练。最优判别器把原始 GAN 目标与 Jensen-Shannon 散度联系起来，而实践中训练常常使用非饱和损失以提供更强的生成器梯度。

Wasserstein GAN 用分布之间的几何距离取代基于重叠的分类，从而改进了这一对抗视角。借助对偶形式，1-Wasserstein 距离可以用一个实值的 Lipschitz 评论者来估计。这个评论者不输出概率；其分差反映的是概率质量必须如何在数据空间中移动。

基于能量的模型随后提供了更宏观的景观视角。EBM 为每个配置赋予标量能量 $E_\theta(x)$ ，低能量对应可信的数据，高能量对应不可信的配置。通过 $p_\theta(x) \propto \exp(-E_\theta(x))$ ，能量定义了一个未归一化密度。因此，学习与采样都围绕能量差异和能量梯度来组织，而不是围绕易处理的归一化似然。

最后，我们通过恒等式 $\nabla_x \log p_\theta(x) = -\nabla_x E_\theta(x)$ 把 EBM 与基于分数的扩散联系起来。这表明基于能量与基于分数的模型共享同一局部几何：二者都使用把样本引向高密度、低能量区域的方向。扩散模型把这一思想扩展到一族带噪分布上，学习从粗糙噪声层级到精细数据级结构的、类似能量梯度的方向。

生成对抗网络由 Goodfellow 等人 [12] 提出，他们将生成形式化为生成器与判别器之间的极小极大博弈，并把最优判别器与 Jensen-Shannon 散度联系起来。Wasserstein GAN 由 Arjovsky 等人 [2] 提出，用基于搬运的距离取代了基于分类的比较。梯度惩罚形式则由 Gulrajani 等人 [13] 发展。

基于能量的建模在机器学习与统计物理中有着悠久的历史。LeCun 等人 [24] 提供了把学习视为塑造能量景观的宽泛教程式视角。经典例子包括 Hopfield 网络 [17] 与玻尔兹曼机 (Boltzmann machines) [1]。分数匹配由 Hyvärinen [19] 引入，作为在不求值配分函数的情况下估计未归一化统计模型的一种方法；Vincent [43] 则把分数匹配与去噪联系起来。基于分数的扩散一章详细讨论过 Song 与 Ermon [38] 以及 Song 等人 [39] 的工作；此处再次提及，是因为它们把能量梯度思想与多尺度分数学习及扩散联系了起来。

结语

本书刻意选择了一条贯穿生成式建模数学基础的特定路径。我们从线性表示出发：将矩阵视为变换，将主成分分析（Principal Component Analysis, PCA）视为保持方差的投影，将自编码器（autoencoder）视为基于重构的压缩。随后，概率 PCA 将这一确定性图景转化为一个潜变量生成模型，引入了先验、似然、边缘似然与后验作为核心建模对象。

变分自编码器将这一潜变量视角扩展到非线性情形，此时精确的边缘似然与后验不再可得。这便自然而然地引出了证据下界（Evidence Lower Bound, ELBO）、变分推断、近似后验以及重参数化技巧。扩散模型则将生成的故事从单一潜变量转变为一条含噪声潜状态的完整轨迹，把生成变成了对一个渐进加噪过程的可学习逆过程。

连续时间与基于分数的章节针对同一宽泛问题发展出了第二种视角。我们不再仅将生成描述为离散的链，而是研究了运动、密度演化、布朗噪声、刘维尔方程、Fokker-Planck 方程、朗之万动力学、分数匹配以及逆时间扩散。这表明生成式建模也可以理解为学习在概率空间中运动的方向。

后续章节考察了两条互补的路线。归一化流与自回归模型展示了如何通过设计来保持精确似然：借助雅可比矩阵易于处理的可逆变换，或借助有序的条件分解。而 GAN、Wasserstein GAN 与基于能量的模型则展示了生成式学习如何超越易于处理的似然，转而依赖比较、几何差异度量或标量能量景观。

综合来看，这些章节将生成式 AI 呈现为一组反复出现的数学思想，而非一系列互不相关的架构：表示、变换、边缘化、近似、加噪与去噪、密度演化、分数场、似然构造、分布比较以及能量塑形。这些思想在更新的生成式建模框架中持续再现。

例如，流匹配 [25] 与整流流 [26] 可以视为连续时间输运视角的进一步发展：它们学习向量场，将概率质量从简单分布搬运至数据分布。一致性模型 [40] 可以视为对扩散模型采样效率挑战的又一种回应，其目标是在减少采样步数的同时保持迭代去噪的质量。

因此，本书的目的在于构建一个紧凑的数学基础，使读者能够更有把握地接触并理解上述后续进展。一旦读者理解了潜变量、变分界、扩散路径、密度演化、分数场、精确似然模型、对抗式比较以及能量景观，许多现代扩展便更容易被纳入一张共同的概念地图之中。

附录 A

高斯代数与配方法

第 2 章通过一个直接的线性高斯论证推导了 PPCA 的边缘分布 $p(\mathbf{x})$ 。这一做法对该章的主体脉络而言是最快捷、最透明的。不过，还有另一种推导值得考察，因为同样的代数结构会在后续其他高斯潜变量模型中反复出现：配方法（completing the square）。

本附录汇集了若干依赖显式高斯代数的推导，并特别着重于精确给出正文中隐式使用的配方恒等式。在 PPCA 的情形下，这一方法的价值在于：单次推导即可同时得到两个关键的高斯量：

- 后验 $p(\mathbf{z} | \mathbf{x})$,
- 以及在将 $\mathbf{z}$ 积分掉之后的边缘分布 $p(\mathbf{x})$ 。

配方法。 高斯密度是一个二次型的指数。因此，每当某个变量的对数密度可以写成该变量的二次函数时，我们便可以尝试将其改写为标准的高斯形态。配方法正是执行这种改写的代数工具：它把一个二次表达式整理为如下形式

$$-\frac{1}{2}(\text{variable} - \text{mean})^\top (\text{precision})(\text{variable} - \text{mean}) + \text{constant},$$

由此即可直接读出高斯的均值与协方差。

为便于复用，值得将这一技巧的矩阵形式显式地陈述出来。若 A 对称正定，则

$$-\frac{1}{2}\mathbf{x}^\top A\mathbf{x} + \mathbf{b}^\top \mathbf{x} = -\frac{1}{2}(\mathbf{x} - A^{-1}\mathbf{b})^\top A(\mathbf{x} - A^{-1}\mathbf{b}) + \frac{1}{2}\mathbf{b}^\top A^{-1}\mathbf{b}.$$

之所以成立，是因为把右端展开后，我们得到

$$\begin{aligned} & -\frac{1}{2}(\mathbf{x} - A^{-1}\mathbf{b})^\top A(\mathbf{x} - A^{-1}\mathbf{b}) + \frac{1}{2}\mathbf{b}^\top A^{-1}\mathbf{b} \\ &= -\frac{1}{2}\mathbf{x}^\top A\mathbf{x} + \mathbf{b}^\top \mathbf{x} - \frac{1}{2}\mathbf{b}^\top A^{-1}\mathbf{b} + \frac{1}{2}\mathbf{b}^\top A^{-1}\mathbf{b} \\ &= -\frac{1}{2}\mathbf{x}^\top A\mathbf{x} + \mathbf{b}^\top \mathbf{x}. \end{aligned}$$

可见两个表达式完全相同；第二个只是第一个以高斯为中心的改写形式。向量 $A^{-1}\mathbf{b}$ 是该二次型的中心，而 A 是精度矩阵，其逆给出协方差。

第 1 步：从联合密度出发。 回顾 PPCA 模型：

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{z} \mid \mathbf{0}, \mathbf{I}), \quad p(\mathbf{x} \mid \mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \alpha^2 \mathbf{I}).$$

于是

$$p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x} \mid \mathbf{z}) p(\mathbf{z}).$$

由于高斯密度是二次型的指数，使用对数联合密度会更加方便：

$$\log p(\mathbf{x}, \mathbf{z}) = -\frac{1}{2\alpha^2} \|\mathbf{x} - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}\|^2 - \frac{1}{2} \|\mathbf{z}\|^2 + \text{const.}$$

第 2 步：展开关于 $\mathbf{z}$ 的二次项。 展开第一个范数项得到

$$\|\mathbf{x} - \boldsymbol{\mu} - \mathbf{W}\mathbf{z}\|^2 = (\mathbf{x} - \boldsymbol{\mu})^\top (\mathbf{x} - \boldsymbol{\mu}) - 2\mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) + \mathbf{z}^\top \mathbf{W}^\top \mathbf{W} \mathbf{z}.$$

代回原式，

$$\log p(\mathbf{x}, \mathbf{z}) = -\frac{1}{2\alpha^2} (\mathbf{x} - \boldsymbol{\mu})^\top (\mathbf{x} - \boldsymbol{\mu}) + \frac{1}{\alpha^2} \mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) - \frac{1}{2} \mathbf{z}^\top \left(\frac{1}{\alpha^2} \mathbf{W}^\top \mathbf{W} + \mathbf{I} \right) \mathbf{z} + \text{const.}$$

现在将 $\mathbf{x}$ 视为固定。此时对数联合密度是 $\mathbf{z}$ 的二次函数，因而可以通过配方将其改写为关于 $\mathbf{z}$ 的高斯形式。

第 3 步：配方。 定义

$$\mathbf{M} = \mathbf{W}^\top \mathbf{W} + \alpha^2 \mathbf{I}, \quad \mathbf{m} = \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}).$$

由于

$$\frac{1}{\alpha^2} \mathbf{W}^\top \mathbf{W} + \mathbf{I} = \frac{1}{\alpha^2} \mathbf{M},$$

对数联合密度中依赖于 $\mathbf{z}$ 的部分变为

$$-\frac{1}{2\alpha^2} \mathbf{z}^\top \mathbf{M} \mathbf{z} + \frac{1}{\alpha^2} \mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}).$$

这恰好符合上面一般恒等式的形式，其中

$$\mathbf{A} = \frac{1}{\alpha^2} \mathbf{M}, \quad \mathbf{b} = \frac{1}{\alpha^2} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}).$$

应用该恒等式得到

$$-\frac{1}{2\alpha^2} \mathbf{z}^\top \mathbf{M} \mathbf{z} + \frac{1}{\alpha^2} \mathbf{z}^\top \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2\alpha^2} (\mathbf{z} - \mathbf{m})^\top \mathbf{M} (\mathbf{z} - \mathbf{m}) + \frac{1}{2\alpha^2} \mathbf{m}^\top \mathbf{M} \mathbf{m}.$$

将其代回原式可得

$$\log p(\mathbf{x}, \mathbf{z}) = -\frac{1}{2\alpha^2} (\mathbf{z} - \mathbf{m})^\top \mathbf{M} (\mathbf{z} - \mathbf{m}) - \frac{1}{2\alpha^2} (\mathbf{x} - \boldsymbol{\mu})^\top (\mathbf{x} - \boldsymbol{\mu}) + \frac{1}{2\alpha^2} \mathbf{m}^\top \mathbf{M} \mathbf{m} + \text{const.}$$

至此，关于 $\mathbf{z}$ 的高斯结构已经显式呈现。

为何这确定了一个高斯后验。一旦 $\mathbf{x}$ 固定, 所有与 $\mathbf{z}$ 无关的项都属于归一化常数。因此, 真正起作用的、依赖于 $\mathbf{z}$ 的项只有

$$-\frac{1}{2\alpha^2}(\mathbf{z} - \mathbf{m})^\top \mathbf{M}(\mathbf{z} - \mathbf{m}),$$

而这正是关于 $\mathbf{z}$ 的高斯密度的对数核。由于 $\mathbf{M}$ 正定, 该二次型关于 $\mathbf{z}$ 是凹的, 所以它确实定义了一个正常的高斯分布。

第 4 步: 读出后验 $p(\mathbf{z} | \mathbf{x})$ 。于是,

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{m}, \alpha^2 \mathbf{M}^{-1}),$$

即

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}), \alpha^2 \mathbf{M}^{-1}), \quad \mathbf{M} = \mathbf{W}^\top \mathbf{W} + \alpha^2 \mathbf{I}.$$

可见配方法直接给出了后验: 其均值是潜变量估计 $\mathbf{m}$, 其协方差是 $\alpha^2 \mathbf{M}^{-1}$ 。

第 5 步: 将 $\mathbf{z}$ 积分掉, 得到 $p(\mathbf{x})$ 。边缘分布为

$$p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z}.$$

由配方后的形式可知, 依赖于 $\mathbf{z}$ 的部分是一个以 $\mathbf{m}$ 为中心的关于 $\mathbf{z}$ 的高斯密度。因此, 对 $\mathbf{z}$ 积分会消去该部分, 只贡献一个归一化常数。剩下的部分是 $(\mathbf{x} - \boldsymbol{\mu})$ 的二次函数, 所以边缘分布也必然是高斯的。

完成剩余的代数运算, 得到

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \mathbf{W} \mathbf{W}^\top + \alpha^2 \mathbf{I}).$$

于是, 通过一次配方, 我们同时得到了

$$p(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z} | \mathbf{M}^{-1} \mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}), \alpha^2 \mathbf{M}^{-1})$$

以及

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \mathbf{W} \mathbf{W}^\top + \alpha^2 \mathbf{I}).$$

这一推导并非 PPCA 主概念脉络所必需, 但它很有用: 此后每当需要显式处理高斯潜变量模型时, 同样的二次项配方技巧都会再度出现。

附录 B

扩散模型逆过程后验的推导

在第 4.4 节中，我们曾指出真实的逆过程后验

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$$

是高斯的，并以闭式形式给出了其均值与方差。我们在此展示的推导，源自先前在 PPCA 中使用过的同一基本代数思想：一旦所有相关项都是高斯的，我们便可以收集关于感兴趣变量的二次项并配方。

第 1 步：从贝叶斯公式出发

由前向过程可得

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} \mid \mathbf{x}_0)}{q(\mathbf{x}_t \mid \mathbf{x}_0)}.$$

由于分母不依赖于 $\mathbf{x}_{t-1}$ ，当把它视为 $\mathbf{x}_{t-1}$ 的函数时，它仅起到归一化常数的作用。因此，在相差一个比例常数的意义下，

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) \propto q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) q(\mathbf{x}_{t-1} \mid \mathbf{x}_0).$$

由于前向过程是马尔可夫链，

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t \mid \mathbf{x}_{t-1}),$$

于是两个高斯因子分别为

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t \mid \sqrt{\alpha_t} \mathbf{x}_{t-1}, (1 - \alpha_t) \mathbf{I}),$$

以及

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} \mid \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0, (1 - \bar{\alpha}_{t-1}) \mathbf{I}).$$

第 2 步：将乘积写成指数形式

忽略不依赖于 $\mathbf{x}_{t-1}$ 的归一化常数，我们有

$$\begin{aligned} q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) &\propto \exp\left(-\frac{1}{2(1 - \alpha_t)} \|\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1}\|^2\right) \\ &\times \exp\left(-\frac{1}{2(1 - \bar{\alpha}_{t-1})} \|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0\|^2\right). \end{aligned}$$

合并两个指数项得到

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \propto \exp \left(-\frac{1}{2(1-\alpha_t)} \|\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1}\|^2 - \frac{1}{2(1-\bar{\alpha}_{t-1})} \|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0\|^2 \right).$$

第 3 步：展开关于 $\mathbf{x}_{t-1}$ 的二次项

我们现在展开这两个平方范数，只保留包含 $\mathbf{x}_{t-1}$ 的项。

对于第一项，

$$\|\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_{t-1}\|^2 = \mathbf{x}_t^\top \mathbf{x}_t - 2\sqrt{\alpha_t} \mathbf{x}_t^\top \mathbf{x}_{t-1} + \alpha_t \mathbf{x}_{t-1}^\top \mathbf{x}_{t-1}.$$

对于第二项，

$$\|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0\|^2 = \mathbf{x}_{t-1}^\top \mathbf{x}_{t-1} - 2\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_{t-1}^\top \mathbf{x}_0 + \bar{\alpha}_{t-1} \mathbf{x}_0^\top \mathbf{x}_0.$$

将它们代入指数中并舍去与 $\mathbf{x}_{t-1}$ 无关的项，我们得到

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \propto \exp \left(-\frac{1}{2} \left[\frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}} \right] \mathbf{x}_{t-1}^\top \mathbf{x}_{t-1} + \left[\frac{\sqrt{\alpha_t}}{1-\alpha_t} \mathbf{x}_t^\top + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} \mathbf{x}_0^\top \right] \mathbf{x}_{t-1} \right).$$

此时它已是标准的高斯二次型

$$-\frac{1}{2} A \mathbf{x}_{t-1}^\top \mathbf{x}_{t-1} + \mathbf{b}^\top \mathbf{x}_{t-1},$$

其中

$$A = \frac{\alpha_t}{1-\alpha_t} + \frac{1}{1-\bar{\alpha}_{t-1}}, \quad \mathbf{b} = \frac{\sqrt{\alpha_t}}{1-\alpha_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_{t-1}} \mathbf{x}_0.$$

第 4 步：配方

利用标准恒等式

$$-\frac{1}{2} A \mathbf{x}^\top \mathbf{x} + \mathbf{b}^\top \mathbf{x} = -\frac{1}{2} A \|\mathbf{x} - A^{-1} \mathbf{b}\|^2 + \text{constant},$$

可以看出该后验是高斯的，其协方差系数为

$$\tilde{\beta}_t = A^{-1},$$

均值为

$$\tilde{\mu}_t = A^{-1} \mathbf{b}.$$

我们先化简 A :

$$\begin{aligned} A &= \frac{\alpha_t}{1 - \alpha_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \\ &= \frac{\alpha_t(1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t)}{(1 - \alpha_t)(1 - \bar{\alpha}_{t-1})}. \end{aligned}$$

由于 $1 - \alpha_t = \beta_t$ 且 $\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}$, 分子变为

$$\alpha_t - \alpha_t \bar{\alpha}_{t-1} + 1 - \alpha_t = 1 - \bar{\alpha}_t.$$

于是

$$A = \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})},$$

故

$$\tilde{\beta}_t = A^{-1} = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

现在计算均值:

$$\tilde{\boldsymbol{\mu}}_t = A^{-1} \mathbf{b} = \tilde{\beta}_t \left(\frac{\sqrt{\alpha_t}}{1 - \alpha_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right).$$

代入 $\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$ 以及 $1 - \alpha_t = \beta_t$, 得到

$$\begin{aligned} \tilde{\boldsymbol{\mu}}_t &= \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \\ &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0. \end{aligned}$$

于是

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t.$$

第 5 步: 最终结果

将以上各步汇总,

$$q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} \mid \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I}),$$

其中

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t,$$

以及

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

这就是 ELBO 中所要求学习的去噪转移 $p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t)$ 需要去匹配的精确局部逆向目标。

参考文献

- [1] David H. Ackley, Geoffrey E. Hinton, and Terrence J. Sejnowski. “A Learning Algorithm for Boltzmann Machines”. In: *Cognitive Science* 9.1 (1985), pp. 147–169.
- [2] Martin Arjovsky, Soumith Chintala, and Léon Bottou. “Wasserstein Generative Adversarial Networks”. In: *Proceedings of the 34th International Conference on Machine Learning*. PMLR, 2017, pp. 214–223.
- [3] Pierre Baldi and Kurt Hornik. “Neural Networks and Principal Component Analysis: Learning from Examples Without Local Minima”. In: *Neural Networks* 2.1 (1989), pp. 53–58.
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [5] Tianhua Chen. *From Classical Probabilistic Latent Variable Models to Modern Generative AI: A Unified Perspective*. 2025. arXiv: 2508.16643 [cs.LG].
- [6] Tianhua Chen. *Probabilistic Latent Variable Models: Principles and Foundations for Modern Generative AI*. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=5244929. SSRN preprint, originally posted May 2025. 2025.
- [7] A. P. Dempster, N. M. Laird, and D. B. Rubin. “Maximum Likelihood from Incomplete Data via the EM Algorithm”. In: *Journal of the Royal Statistical Society: Series B* 39.1 (1977), pp. 1–22.
- [8] Laurent Dinh, David Krueger, and Yoshua Bengio. “NICE: Non-linear Independent Components Estimation”. In: *International Conference on Learning Representations Workshop*. 2015.
- [9] Laurent Dinh, Jascha Sohl-Dickstein, and Samy Bengio. “Density Estimation using Real NVP”. In: *International Conference on Learning Representations*. 2017.
- [10] Lawrence C. Evans. *Partial Differential Equations*. 2nd ed. American Mathematical Society, 2010.
- [11] Mathieu Germain et al. “MADE: Masked Autoencoder for Distribution Estimation”. In: *Proceedings of the 32nd International Conference on Machine Learning*. 2015.
- [12] Ian Goodfellow et al. “Generative Adversarial Nets”. In: *Advances in Neural Information Processing Systems*. Vol. 27. 2014.
- [13] Ishaan Gulrajani et al. “Improved Training of Wasserstein GANs”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017.

- [14] Irina Higgins et al. “beta-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework”. In: *International Conference on Learning Representations*. 2017.
- [15] Geoffrey E. Hinton and Ruslan R. Salakhutdinov. “Reducing the Dimensionality of Data with Neural Networks”. In: *Science* 313.5786 (2006), pp. 504–507.
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. “Denoising Diffusion Probabilistic Models”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 6840–6851.
- [17] John J. Hopfield. “Neural Networks and Physical Systems with Emergent Collective Computational Abilities”. In: *Proceedings of the National Academy of Sciences* 79.8 (1982), pp. 2554–2558.
- [18] Harold Hotelling. “Analysis of a Complex of Statistical Variables into Principal Components”. In: *Journal of Educational Psychology* 24.6–7 (1933).
- [19] Aapo Hyvärinen. “Estimation of Non-Normalized Statistical Models by Score Matching”. In: *Journal of Machine Learning Research* 6 (2005), pp. 695–709.
- [20] Ian T. Jolliffe and Jorge Cadima. “Principal Component Analysis: A Review and Recent Developments”. In: *Philosophical Transactions of the Royal Society A* 374.2065 (2016), p. 20150202.
- [21] Diederik P. Kingma and Max Welling. “Auto-Encoding Variational Bayes”. In: *International Conference on Learning Representations*. 2014.
- [22] Diederik P. Kingma and Max Welling. “An Introduction to Variational Autoencoders”. In: *Foundations and Trends in Machine Learning* 12.4 (2019), pp. 307–392. DOI: 10.1561/22000000056.
- [23] Durk P. Kingma and Prafulla Dhariwal. “Glow: Generative Flow with Invertible 1x1 Convolutions”. In: *Advances in Neural Information Processing Systems*. 2018.
- [24] Yann LeCun et al. “A Tutorial on Energy-Based Learning”. In: *Predicting Structured Data*. Ed. by Gökhan Bakir et al. MIT Press, 2006.
- [25] Yaron Lipman et al. “Flow Matching for Generative Modeling”. In: *International Conference on Learning Representations*. 2023.
- [26] Xingchao Liu, Chengyue Gong, and Qiang Liu. “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow”. In: *International Conference on Learning Representations*. 2023.
- [27] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. Cambridge, MA: MIT Press, 2012.
- [28] Alexander Quinn Nichol and Prafulla Dhariwal. “Improved Denoising Diffusion Probabilistic Models”. In: *Proceedings of the 38th International Conference on Machine Learning*. 2021, pp. 8162–8171.
- [29] Bernt Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. 6th ed. Springer, 2003.

- [30] Aaron van den Oord, Nal Kalchbrenner, and Koray Kavukcuoglu. “Pixel Recurrent Neural Networks”. In: *Proceedings of the 33rd International Conference on Machine Learning*. 2016.
- [31] Aaron van den Oord et al. “WaveNet: A Generative Model for Raw Audio”. In: *arXiv preprint arXiv:1609.03499* (2016).
- [32] George Papamakarios et al. “Normalizing Flows for Probabilistic Modeling and Inference”. In: *Journal of Machine Learning Research* 22.57 (2021), pp. 1–64.
- [33] Karl Pearson. “On Lines and Planes of Closest Fit to Systems of Points in Space”. In: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 2.11 (1901), pp. 559–572.
- [34] Danilo Jimenez Rezende and Shakir Mohamed. “Variational Inference with Normalizing Flows”. In: *Proceedings of the 32nd International Conference on Machine Learning*. 2015.
- [35] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. “Stochastic Backpropagation and Approximate Inference in Deep Generative Models”. In: *Proceedings of the 31st International Conference on Machine Learning*. Vol. 32. 2. 2014, pp. 1278–1286.
- [36] Hannes Risken. *The Fokker–Planck Equation: Methods of Solution and Applications*. 2nd ed. Springer, 1996.
- [37] Jascha Sohl-Dickstein et al. “Deep Unsupervised Learning using Nonequilibrium Thermodynamics”. In: *Proceedings of the 32nd International Conference on Machine Learning*. Vol. 37. 2015, pp. 2256–2265.
- [38] Yang Song and Stefano Ermon. “Generative Modeling by Estimating Gradients of the Data Distribution”. In: *Advances in Neural Information Processing Systems*. 2019.
- [39] Yang Song et al. “Score-Based Generative Modeling through Stochastic Differential Equations”. In: *International Conference on Learning Representations*. 2021.
- [40] Yang Song et al. “Consistency Models”. In: *Proceedings of the 40th International Conference on Machine Learning*. PMLR, 2023, pp. 32211–32252.
- [41] Gilbert Strang. *Introduction to Linear Algebra*. 5th ed. Wellesley-Cambridge Press, 2016.
- [42] Michael E. Tipping and Christopher M. Bishop. “Probabilistic Principal Component Analysis”. In: *Journal of the Royal Statistical Society: Series B* 61.3 (1999), pp. 611–622.
- [43] Pascal Vincent. “A Connection Between Score Matching and Denoising Autoencoders”. In: *Neural Computation* 23.7 (2011), pp. 1661–1674.